TECNICATURA EN ANÁLISIS Y DESARROLLO DE SOFTWARE · INSTITUTO DE PROFESORADO SEDES SAPIENTIAE

Análisis y Diseño de Sistemas II
Resumen visual · 2do parcial

Temas 6 a 10 de la cátedra: Redes de Petri, *Business Intelligence*, Minería de datos y Big Data. Armado a partir de los Trabajos Prácticos (TP) 6 a 9 del grupo, las lecturas de la cátedra y los apuntes de clase. Entra solo la teoría, salvo la práctica de Redes de Petri.

6 y 7 · Redes de Petri
Lugares, transiciones, marcas, alcanzabilidad, matrices y propiedades

8 · Business Intelligence
Definición, beneficios, ROI, KPI, esquemas estrella y copo de nieve

9 · Minería de datos
Proceso KDD, limpieza, tareas, técnicas, evaluación, CRISP-DM y SEMMA

10 · Big Data
Las 3 V, Big Analytics, MAD, Hadoop, tiempo real y comparación

Grupo: Valentín Figún, Matías Valentino Morales, Paula Rocío Haunau · Docente: María Silvina Scarpin · 2026
Fuentes: carpeta de la cátedra *Análisis y Diseño de Sistemas II - 2026* (presentaciones de Redes de Petri, *Business Intelligence: competir con información*, lectura de Minería de Datos, artículo de Azevedo y Santos, guía de PowerData), TP 6 a 9 y apuntes de clase.

Antes de empezar

Cómo usar este resumen

Qué significa cada recuadro, qué entra en el parcial y los datos que conviene saber de memoria.

Clave
Definición o idea central.

Cae en el examen
Pregunta típica y cómo responderla.

Truco para recordar
Regla propia para memorizar.

Ojo
Confusión frecuente o detalle que se olvida.

Error o aclaración
Algo que está mal en un apunte o que dijo la docente.

Nota
Contexto o fuente.

No verificado: la franja amarilla marca contenido sin fuente primaria en la carpeta (sale solo de un TP o apunte del grupo, o es una propuesta armada para el resumen).

Siglas
Toda sigla se desarrolla la primera vez que aparece en cada sección. El glosario está al final. TP = Trabajo Práctico; RdP = Red de Petri.

Aclaraciones de la docente
De todos los temas entra solo la teoría. Excepción, Redes de Petri: además entran el **árbol de alcanzabilidad**, las **características y propiedades**, y **resolver una red con máquina de testigos y método matricial**. La práctica de los TP (CoffeeTime, fútbol, comercio minorista, abandono de compra, modelado del TP6) no entra y se sacó.

A Avisos antes de estudiar

1. Alcance: solo teoría de los cuatro temas, más la práctica de Redes de Petri indicada arriba. El resumen ya está recortado a eso.
2. Numeración de la cátedra: Temas 6 y 7 = Redes de Petri, 8 = BI, 9 = Minería de datos, 10 = Big Data. Big Data está incluido.
3. El apunte de Redes de Petri dice "una red viva es cíclica": es incorrecto y ninguna presentación de la cátedra lo dice.
4. El mapeo KDD, SEMMA y CRISP-DM del TP8 se corrigió según el artículo de la cátedra (Azevedo y Santos).
5. Los videos de los temas 8 y 10 no se revisaron; la guía de PowerData sí está cotejada.
6. El libro de BI desarrolla SQL como "Standard Query Language" y ODBC como "Object Data Base Connector"; lo habitual es **Structured Query Language** y **Open Database Connectivity**.

B Qué entra en el parcial

Redes de Petri 6·7
Definición, historia, representación gráfica y matricial, ejecución, árbol de alcanzabilidad y máquina de testigos, estructuras, propiedades, subclases, métodos de análisis y modelos clásicos. Práctica: árbol, propiedades, máquina de testigos y método matricial.

Business Intelligence 8
Definición, beneficios, componentes (calidad de datos, ETL, *datawarehouse*, Data Mart, OLAP), ROI, modelo de negocio, KPI, modelo de datos y experiencias. Solo teoría.

Minería de datos 9
KDD, fases, datos atípicos y faltantes, retos, tareas, técnicas, evaluación, CRISP-DM y SEMMA. Solo teoría.

Big Data 10
Las 3 V, Big Analytics, MAD, Hadoop, megatendencias, tiempo real, implementación y comparación con BI y minería. Solo teoría.

C Datos para memorizar

Siglas de esta página: C^- = matriz de incidencia previa; C^+ = matriz de incidencia posterior; KPI = indicador clave de desempeño; ROI = retorno de la inversión; NPV = valor actual neto; IDC = International Data Corporation; KDD = descubrimiento de conocimiento en bases de datos;

CRISP-DM = proceso estándar intersectorial para minería de datos; SEMMA = muestrear, explorar, modificar, modelar, evaluar; HDFS = sistema de archivos distribuido de Hadoop; ETL = extracción, transformación y carga; OLAP = procesamiento analítico en línea.

$C = (P,T,I,O)$
Estructura de una Red de Petri

$C^+ - C^-$
Matriz de incidencia (filas = transiciones)

1-acotada
Red segura = binaria

$M - Pre + Post$
Nuevo marcado al disparar t

$M \geq ej \cdot C^-$
Transición tj habilitada (método matricial)

ω
En el árbol: red no acotada

Dresner
Popularizó "Business Intelligence" (Gartner)

80 / 20
Hospitales: % preparando datos / % analizando

15 %
Directivos que confían en sus informes (IDC)

43 %
Encuesta Gartner 2005: BI = usar información para dirigir y optimizar

219 %
ROI del ejemplo (NPV 87.656 €, inversión 40.000 €, tasa 15 %)

401 %
ROI medio a 3 años (IDC 1996), *payback* 2,3 años

Codd 1970
Modelo relacional

4 franjas
9 a 11:59 · 12 a 14:59 · 15 a 17:59 · 18 a 21

1989
Primer uso del término KDD

9 pasos
Proceso KDD (6 fases o estados en la lectura)

20 meses
Se duplica la información almacenada

80 % / 100 %
Datos georreferenciables / con fecha

6 · 5
Fases de CRISP-DM · de SEMMA

Lift = 3
30 % / 10 % (ejemplo de elevación)

3 V
Volumen, velocidad, variedad

MAD
Magnética, Ágil, Detallada

4
Megatendencias: Movilidad, Cloud, Social Media, Analytics

HDFS + MapReduce
Las dos piezas de Hadoop

Temas 6 y 7 · Teoría y práctica

Redes de Petri

6

Herramienta gráfica y matemática de Carl Adam Petri para modelar sistemas con **concurrencia, sincronización, exclusión mutua y conflictos**. Lectura de Jorge Castro Monge, TP6 y apunte de clase.

Qué es

Una Red de Petri (RdP) es un **grafo dirigido** de **lugares** y **transiciones** unidos alternativamente por **arcos**. Los lugares pueden tener **marcas**; el conjunto de marcas en un momento es el **marcado** (el estado). Los marcados representan estados y las transiciones, sucesos.

Antecedente: máquinas de estado

Estados (círculos) y transiciones con entrada/salida *a/b*. **Límite:** no modelan bien **acciones simultáneas**; unir varias máquinas multiplica los estados y vuelve ilegible el diagrama.

versus

Redes de Petri

Tienen **paralelismo inherente**: representan concurrencia y sincronización de forma natural. Analizar la red revela la **estructura** y el **comportamiento dinámico** del sistema para evaluarlo y mejorarlo.

Historia

1962: tesis doctoral de Petri, *Kommunikation mit Automaten*, sobre comunicación entre componentes **asíncronos**. **1970**: Holt y Commoner ("Events and Conditions") las aplican a sistemas concurrentes.

Según la cátedra

Representaciones gráficas de sistemas con flujo de información; **generadores de lenguaje o autómatas formales** de la teoría de grafos. Se extienden con **redes temporizadas** para analizar prestaciones.

Programación concurrente

Transiciones = **procesos**; lugares = **condiciones** para ejecutarlos; marcas = la condición se verifica.

1 Elementos y representación gráfica

Lugar o plaza

Círculo. Representa una **condición** o estado.

Transición

Barra. Representa un **evento** o suceso.

Arco

Une **lugar → transición** o **transición → lugar**, nunca dos del mismo tipo. Tiene **peso**; sin número, pesa 1.

Marca o *token*

Punto negro. Indica que la condición **se cumple**. Lugar marcado = **activo**.

- Es un **multígrafo dirigido bipartito**: admite arcos múltiples, con dirección, y dos clases de nodos que solo se conectan entre sí.
- Transición **sensibilizada** (habilitada): todos sus lugares de origen tienen marca. **Validada**: además ocurre el evento asociado.
- La representación **gráfica** y la **matricial** son equivalentes: de una se obtiene la otra y es única.

2 Definición formal

Estructura C = (P, T, I, O)

- **P**: conjunto finito y no vacío de lugares.
- **T**: conjunto finito y no vacío de transiciones.
- **I**: función de entrada (lugares de entrada de cada transición).
- **O**: función de salida (lugares de salida).

Marcado y red marcada

Marcado μ: función de P en los enteros no negativos, o vector μ = (μ1, ..., μn). Es el **estado** de la red.

Red marcada M = (C, μ). Hay infinitos marcados posibles (conjunto infinito pero numerable).

Ordinaria

Todos los arcos pesan 1.

Generalizada

Los arcos pueden pesar cualquier entero mayor o igual que cero.

Pura (no reflexiva)

Ningún lugar es entrada y salida de la misma transición.

Notación del apunte: I(t) y O(t) lugares de entrada y salida de t; I'(p) y O'(p) transiciones que entran y salen de p; V(p, t) y V(t, p) pesos de los arcos.

3 Ejecución: reglas de disparo

1 · Habilitación
M(p) ≥ I(p, t) en cada lugar de entrada

2 · Disparo
Quita marcas de las entradas y pone en las salidas

3 · Nuevo marcado
M'(p) = M(p) − Pre(p, t) + Post(t, p)

Transición fuente
Sin lugares de entrada: **siempre habilitada**.

Transición sumidero
Sin lugares de salida: **elimina marcas** de la red.

Disparo arbitrario
Cuál de las habilitadas se dispara primero se decide en un nivel de abstracción inferior.

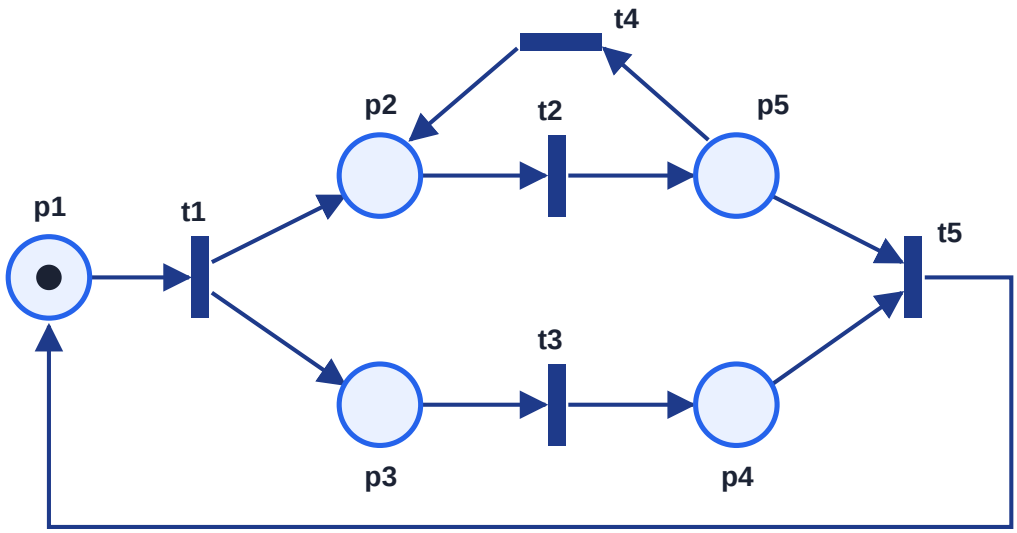
⚠ **Marcas indivisibles**
Una marca la quita una sola transición: disparar una puede **deshabilitar** a otra que comparte el lugar de entrada. Fuera de eso, los disparos son **asíncronos**. El **grado de habilitación** es cuántas veces puede dispararse de forma concurrente.

Inmediatamente alcanzable
Se llega disparando **una** transición.

Alcanzable
Existe una secuencia de disparos σ de Mi a Mk.

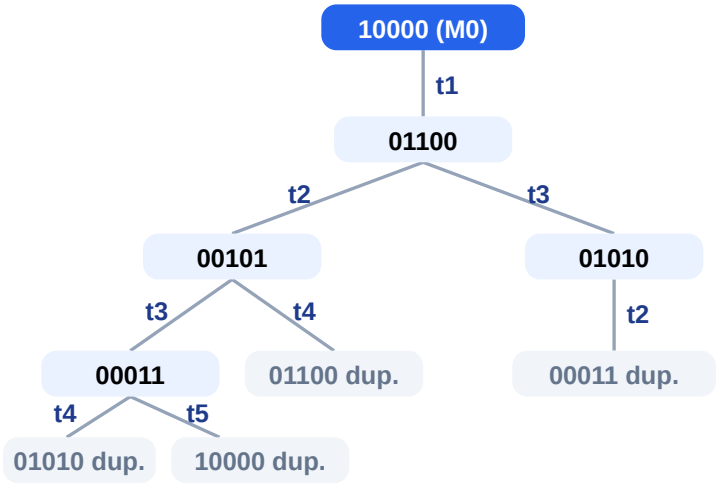
Conjunto R(M)
Todos los marcados alcanzables desde M.

4 Ejemplo resuelto de la lectura



M0 = (1, 0, 0, 0, 0). t1 reparte en p2 y p3 (distribución); t5 sincroniza p4 y p5 (conjunción); t4 devuelve de p5 a p2.

	C^- (p1 p2 p3 p4 p5)	C^+ (p1 p2 p3 p4 p5)	$C = C^+ - C^-$
t1	1 0 0 0 0	0 1 1 0 0	−1 1 1 0 0
t2	0 1 0 0 0	0 0 0 0 1	0 −1 0 0 1
t3	0 0 1 0 0	0 0 0 1 0	0 0 −1 1 0
t4	0 0 0 0 1	0 1 0 0 0	0 1 0 0 −1
t5	0 0 0 1 1	1 0 0 0 0	1 0 0 −1 −1



Árbol de alcanzabilidad: se corta en los nodos duplicados (gris).

Conclusiones

- **5 marcados** alcanzables, ninguno muerto → **viva**.
- Ningún lugar pasa de 1 marca → **segura**.
- t5 vuelve siempre a M0 → **cíclica**.
- t2 y t3 son **concurrentes**.
- En 00011, t4 y t5 están en **conflicto** (comparten p5).

Verificado por computadora.

Representación matricial

C^- (matriz de incidencia previa) = función de entrada; C^+ (matriz de incidencia posterior) = función de salida; $C = C^+ - C^-$. Según la lectura, **filas = transiciones** y **columnas = lugares**. Cada transición tj es un vector **ej**: está habilitada si $M \geq ej \cdot C^-$ y al dispararla $M' = M + ej \cdot C$. Para una secuencia σ: $M' = M + f(\sigma) \cdot C$, con **f(σ)** el **vector de disparo** (cuántas veces se dispara cada transición). Ejemplo de la cátedra: σ = t1, t2, t3 → f(σ) = (1 1 1 0 0) → M' = (0 0 0 1 1).

5 Árbol de alcanzabilidad

Representa **todos los marcados alcanzables** desde M0: cada nodo es un marcado y cada arco, la transición disparada. Para que sea finito, se deja de expandir en los **nodos frontera**:

a) Marcado muerto

No hay ninguna transición habilitada.

b) Nodo duplicado

El marcado ya apareció en el árbol.

c) Marcado con w

Solo tiene **más marcas** en algún lugar que otro anterior y habilita lo mismo: se escribe **w** (infinito). Indica red **no acotada**.

Truco para recordar

"Mu-Du-W": el árbol se corta en marcados **Mu**ertos, **Du**plicados o con **W**. **"Más menos menos"**: $C = C^+ - C^-$ y $M' = M - Pre + Post$. **"Lu-Tra-Ar-Ma"**: Lugares, Transiciones, Arcos, Marcas.

Máquina de testigos (MT)

Versión **más compacta** del árbol: cada estado se escribe con los **nombres de los lugares marcados** (repetidos tantas veces como marcas tengan), en **óvalos** unidos por arcos con el nombre de la transición. Conviene con **muchos lugares y pocas marcas**.

6 Estructuras básicas

Secuencial

t2 solo se dispara después de t1.

Selección

Se elige qué proceso ejecutar (un lugar, dos transiciones de salida).

Atribución

Un proceso se ejecuta desde dos procesos distintos (dos transiciones llegan al mismo lugar).

Distribución

Lanza procesos **paralelos** (una transición, varios lugares de salida).

Conjunción

Sincroniza procesos paralelos (una transición, varios lugares de entrada).

Sincronización

t1 se habilita solo si **todos** sus lugares de entrada tienen marca.

Concurrencia

t2 y t3 se disparan a la vez e independientemente.

Conflicto

t1 y t2 habilitadas; disparar una **deshabilita** a la otra.

7 Propiedades

Estructurales

Dependen de la topología, no del marcado inicial.

- **Pura**.
- **Estructuralmente acotada**: acotada para **cualquier** marcado inicial finito.
- **Estructuralmente viva**: existe **algún** marcado inicial con el que es viva.
- **Completamente controlable**: cualquier marcado es alcanzable desde cualquier otro.
- **Estructuralmente conservativa**.

versus

De comportamiento

Dependen del marcado inicial M0.

- **Alcanzabilidad**.
- **Vivacidad**.
- **Acotamiento** y seguridad.
- **Ciclicidad** (reversibilidad).
- **Conservación**.
- Conflicto y exclusión mutua.

Propiedad	Definición	Qué garantiza
Alcanzabilidad	Mn es alcanzable si existe σ que lleva de M0 a Mn	Base para estudiar las demás
Viva	Desde cualquier marcado alcanzable, **todas** las transiciones pueden volver a dispararse	No hay bloqueo total (*deadlock*)
Parcialmente viva	Siempre hay alguna transición disparable, pero alguna no es viva	Evoluciona aunque algo se bloquee
No viva	Se llega a un marcado muerto	Hay bloqueo total
k-acotada	Ningún lugar supera k marcas en ningún marcado alcanzable	Número **finito** de estados
Segura	**1-acotada** = binaria: un lugar está marcado o no	No se excede la capacidad (por ejemplo, de un registro)
Cíclica / reversible	Desde cualquier marcado alcanzable se vuelve a M0	Sin subconjuntos finales de los que no se vuelve
Conservativa	La cantidad total de marcas es constante	Recursos que no se crean ni destruyen
Conflicto	Dos habilitadas comparten entrada; disparar una deshabilita la otra	Hay una decisión no determinista
Exclusión mutua	Dos procesos no usan el recurso a la vez	Acceso ordenado a un recurso compartido

Error del apunte de clase

El apunte dice "una red viva es cíclica": **es falso**. Vivacidad y ciclicidad son **independientes**. Tampoco hay que confundir **segura** (1-acotada) con **viva** (sin bloqueos). Conflicto **estructural**: dos transiciones comparten un lugar de entrada; **efectivo**: además las dos están habilitadas.

Conflicto estructural y efectivo

Estructural: un lugar tiene **más de una transición de salida**.
Efectivo (para M0): un marcado alcanzable habilita a las dos a la vez y disparar una **deshabilita a la otra**.

Exclusión mutua, limitación y conservación

Dos **lugares** en exclusión mutua nunca están marcados a la vez. Una red k-limitada se implementa con **recursos finitos**. La conservación suele medirse **respecto de un vector peso**.

Truco para recordar

"VACCa": **V**ivacidad, **A**cotamiento, **C**iclicidad, **C**onservación, **a**lcanzabilidad. La lectura lo resume así: **supervivencia** = sin estancamientos; **seguridad** = memoria limitada.

8 Modelos clásicos de concurrencia

Exclusión mutua (semáforo)

Un lugar "recurso libre" con **una marca**. El primero que lo toma quita la marca y los demás esperan. Vale para cualquier cantidad de procesos y **no tiene prioridades**.

Productor y consumidor

Un lugar "depósito con producto" (*buffer*) comunica los procesos. Sin límite, crece sin fin. Con **capacidad finita**: lugares "llenos" y "vacíos" que **siempre suman la capacidad** (por ejemplo, 3).

Lectores y escritores

Lecturas concurrentes, escritura **excluyente**. Semáforo con **m marcas** y arcos de peso **m**: leer toma 1, escribir toma las m.

Cinco filósofos

Plato y tenedor a la izquierda; para comer hacen falta los dos de al lado. Si todos toman el mismo lado: **estancamiento**. Solución viva: "comer" toma **los dos tenedores a la vez** (conjunción) o un lugar "sillas" con **4 marcas**.

No verificado con el TP: las soluciones de los filósofos son las habituales; la del grupo está en una imagen que no se puede leer.

9 Ventajas, desventajas y verificación

Ventajas

- Fáciles de interpretar.
- Tratan procesos independientes y concurrentes.
- Más exactas que un diagrama de estados.
- Modelan recursos compartidos (una impresora).
- Se construyen *top-down* o *bottom-up*.

versus

Desventajas

- No modelan **prioridades**.
- Hay muchas **subclases** para problemas específicos.
- El análisis se complica con sistemas complejos.
- A mayor modelo, mayor consumo de recursos.

Verificación frente a validación

Ejecutar la red **simula** el sistema: se logra una **verificación**. Una **validación** exige un lenguaje más formal. Para redes grandes hacen falta simuladores como **HPetriSim**.

Ambientes

Gráficos: visión global rápida, pero tediosos y confusos en redes grandes. **Estructurales** (intérprete): pierden lo visual, pero el "pseudocódigo" se acerca al código (ADA, Modula).

10 Aplicaciones, subclases y métodos de análisis

Aplicaciones (presentación de la cátedra): tiempo real, sistemas operativos y compiladores, *hardware* y *software*, producción industrial, DFD (Diagrama de flujo de datos) (diagramas de flujo de datos), protocolos de comunicación y bases de datos.

Subclase	Regla	Qué modela
Grafo de estados o máquina de estados (GE o ME)	Cada **transición**: una entrada y una salida	Conflictos; **no** paralelismo ni sincronización. Estrictamente conservativa
Grafo marcado (GM)	Cada **lugar**: una entrada y una salida	Paralelismo, concurrencia y sincronización; **no** conflictos
Red de libre elección (RLE)	Si un lugar es entrada de varias transiciones, es su única entrada	Concurrencia y conflicto restringido: las transiciones en conflicto están habilitadas todas o ninguna
Red simple (RS)	Cada transición: como máximo un lugar de entrada compartido	—

Árbol de alcanzabilidad

Información detallada del comportamiento: validar el modelo, verificar un diseño, elegir entre propuestas, predecir. **Desventaja**: puede volverse grande e inmanejable.

versus

Ecuaciones matriciales

La matriz C **no refleja toda la estructura**; f(σ) **no dice el orden** de los disparos; que M' = M + f(σ)·C tenga solución es **necesario pero no suficiente** para que el marcado sea alcanzable.

La presentación termina con **modelos de redes** de investigación operativa: ruta más corta, árbol de expansión mínima, flujo máximo y flujo de costo mínimo.

11 Práctica que entra: resolver una red paso a paso

Alcance de la docente

De Redes de Petri entran, además de la teoría, el **árbol de alcanzabilidad**, las **características y propiedades**, y **resolver una red con máquina de testigos y método matricial**. Los tres ejemplos están verificados por computadora.

1 · Leer la red
P, T, pesos, M0; I(t) y O(t)

2 · Matrices
C^-, C^+ y $C = C^+ - C^-$; filas = transiciones

3 · Árbol
Cortar en muerto, duplicado u ω

4 · Máquina de testigos
Unir duplicados: grafo de marcados

5 · Matricial
M' = M + f(σ)·C; habilitación M ≥ ej·C^-

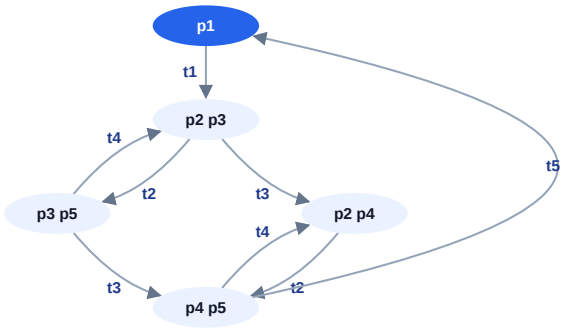
6 · Propiedades
Leerlas del árbol y del grafo

Con ω (infinito; el apunte lo escribe w) vale ω + 1 = ω y ω − 1 = ω. La ecuación de estado no dice el orden: verificá que cada transición esté habilitada en su momento.

Propiedad	Cómo se lee en el árbol o en la máquina de testigos
Viva	Sin marcados muertos y, desde cualquier estado del grafo, se puede volver a disparar cada transición
Parcialmente viva	Sin marcados muertos, pero alguna transición deja de poder dispararse
No viva	Aparece un marcado muerto (bloqueo total)
Acotada (k-acotada)	No aparece ω; k = máximo de marcas en un lugar
Segura	k = 1
No acotada	Aparece ω en algún lugar
Cíclica (reversible)	Desde todos los estados del grafo se puede volver a M0
Conservativa	La suma de marcas (o la ponderada con un vector peso) es igual en todos los marcados
Conflicto	Estructural: un lugar con dos o más transiciones de salida. Efectivo: en algún marcado las dos están habilitadas y disparar una deshabilita la otra
Concurrencia	Dos transiciones habilitadas a la vez que no comparten lugares de entrada
Exclusión mutua de lugares	Dos lugares nunca marcados a la vez
Pura	Ningún lugar es entrada y salida de la misma transición

Ejemplo 1 — red acotada (la de la lectura)

M0 = (1, 0, 0, 0, 0). t1: p1 → p2, p3; t2: p2 → p5; t3: p3 → p4; t4: p5 → p2; t5: p4, p5 → p1. Matrices y árbol: arriba, en la representación matricial.



Máquina de testigos: 5 estados y 8 arcos.

Método matricial

σ = t1 t3 t2 t5 → f(σ) = (1 1 1 0 1). f(σ)·C = suma de las filas t1, t2, t3 y t5 = (0 0 0 0 0) → **M' = M0**. Habilitación de t5 en (0 0 0 1 1): e5·C⁻ = (0 0 0 1 1) ≤ M.

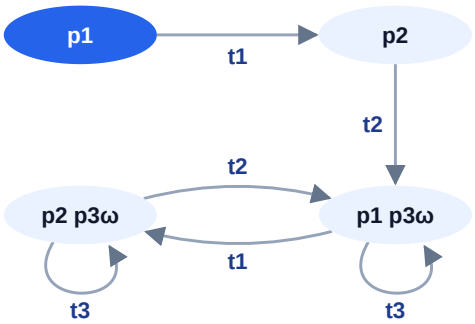
- **Viva**, **segura**, **cíclica**, **pura**.
- No estrictamente conservativa (1 marca en M0, 2 en el resto); sí con el vector peso (2 1 1 1 1).
- **Conflicto** estructural en p5 (t4 y t5), efectivo en (0 0 0 1 1).
- **Concurrencia**: t2 y t3; t3 y t4.
- **Exclusión mutua**: p2 y p5, p3 y p4, p1 con todos.

Ejemplo 2 — red no acotada (con ω)

M0 = (1, 0, 0). t1: p1 → p2; t2: p2 → p1, p3; t3: p3 → nada (transición sumidero).

	C⁻ (p1 p2 p3)	C⁺	C
t1	1 0 0	0 1 0	−1 1 0
t2	0 1 0	1 0 1	1 −1 1
t3	0 0 1	0 0 0	0 0 −1

```
M0 (1,0,0)
└─ t1 → M1 (0,1,0)
   └─ t2 → (1,0,1) cubre a M0 → M2 (1,0,ω)
      ├─ t1 → M3 (0,1,ω)
      │  ├─ t2 → (1,0,ω)  duplicado de M2
      │  └─ t3 → (0,1,ω)  duplicado de M3
      └─ t3 → (1,0,ω)  duplicado de M2
```



Máquina de testigos con ω.

Método matricial y propiedades

σ = t1 t2 t1 t2 t3 → f(σ) = (2 2 1) → M' = (1 0 0) + 2·(−1 1 0) + 2·(1 −1 1) + (0 0 −1) = **(1 0 1)**.

- **No acotada** (p3 llega a ω; p1 y p2 son 1-acotados).
- **Viva** y **cíclica**: desde (1, 0, k), t3 k veces vuelve a M0 (con ω hay que razonarlo).
- No conservativa, pura, **sin conflicto**.
- **Exclusión mutua**: p1 y p2.

Ejemplo 3 — exclusión mutua de dos procesos (semáforo)

a1, a2 = proceso esperando; b1, b2 = usando el recurso; s = recurso libre. M0 = (a1 b1 a2 b2 s) = (1 0 1 0 1). t1: a1, s → b1; t2: b1 → a1, s; t3: a2, s → b2; t4: b2 → a2, s.

	C^- (a1 b1 a2 b2 s)	C^+	C
t1	1 0 0 0 1	0 1 0 0 0	−1 1 0 0 −1
t2	0 1 0 0 0	1 0 0 0 1	1 −1 0 0 1
t3	0 0 1 0 1	0 0 0 1 0	0 0 −1 1 −1
t4	0 0 0 1 0	0 0 1 0 1	0 0 1 −1 1

Resolución

Árbol: M0 → t1 → M1 (0 1 1 0 0) → t2 → duplicado de M0; M0 → t3 → M2 (1 0 0 1 0) → t4 → duplicado de M0. Máquina de testigos: a1 a2 s ⇄ b1 a2 (t1, t2) y a1 a2 s ⇄ a1 b2 (t3, t4). σ = t1 t2 t3 → f(σ) = (1 1 1 0) → M' = **(1 0 0 1 0)**.

- **Viva**, **segura**, **cíclica**, **pura**; conservativa con el vector peso (1 2 1 2 1).
- **Conflicto** estructural y efectivo en s (t1 y t3 en M0).
- **Exclusión mutua**: b1 y b2.

Errores típicos al resolver

Seguir expandiendo un nodo **duplicado**. Poner ω sin compararlo con un **antecesor** del mismo camino. Armar la matriz con **filas = lugares**. Creer que si M' = M + f(σ)·C tiene solución la secuencia se puede disparar (es **necesario, no suficiente**). En la máquina de testigos, no repetir el nombre de un lugar con **dos marcas**.

Tema 8 · Trabajo Práctico N°7 (TP7)

Business Intelligence

Business Intelligence (BI, inteligencia de negocio): convertir **datos → información → conocimiento** para decidir. Capítulos 1 a 4 de *Business Intelligence: competir con información*, experiencias de BI, guías del grupo y caso CoffeeTime.

Definición de Gartner (la más ajustada)

BI es un **proceso interactivo** para **explorar** y **analizar información estructurada** sobre un **área** (normalmente en un ***datawarehouse***, almacén de datos), para descubrir **tendencias o patrones**, derivar ideas y extraer conclusiones. Incluye **comunicar** los descubrimientos y **efectuar los cambios**. Áreas: clientes, proveedores, productos, servicios y competidores.

Proceso interactivo

Análisis **continuado en el tiempo**: muestra tendencias, cambios y variabilidad.

Explorar

Primer acceso: entender qué pasa y descubrir relaciones desconocidas.

Analizar

Relaciones entre variables, tendencias y patrones.

Información estructurada

Tablas relacionadas, con registros y atributos, en un *datawarehouse*.

Área de análisis

Objeto concreto (clientes, productos) y objetivo (bajar costos, subir ventas).

Comunicar y cambiar

Lo descubierto llega a quien hace los cambios.

Truco para recordar

"Pi-E-A-Info-Á-Co": **P**roceso **i**nteractivo, **E**xplorar, **A**nalizar, **Info**rmación estructurada, **Á**rea, **Co**municar y cambiar.

Origen y otras definiciones

Lo popularizó **Howard Dresner** (consultor de Gartner). **TDWI** (The Data Warehousing Institute): término paraguas de procesos, herramientas y tecnologías; incluye el ***back end*** ("trastienda": *datawarehousing*) y el ***front end*** ("mostrador": consultas, informes, análisis).

Encuesta Gartner 2005 (150 personas)

43 %: uso de información para dirigir, decidir, medir, gestionar y optimizar. 16 % y 16 % otras definiciones; menos de 5 %: solo herramientas. El valor va **más allá de distribuir información**.

Tres preguntas del autor a los directivos: más información y menos tiempo (sí); ¿los sistemas ayudan a decidir rápido? (depende; a veces se pregunta a sistemas **transaccionales**); ¿quienes generan información están desbordados? (sí). Hay que **"industrializar"** los sistemas y dejar los **"artesanales"**.

1 Ejemplo del ticket de supermercado

Datos del ticket	Información operativa	Decisiones	Estrategia
Número, fecha, hora, cajero, artículos, precio, pago	Ventas del día, tickets por hora y cajero, ticket medio	Reponer, turnos, más vendidos, medios de pago	¿Bajan los tickets o el ticket medio?

Cae en el examen

Si **bajan las ventas**: ¿bajó la **cantidad de tickets** (afluencia → promocionar el local) o el **ticket medio** (compran menos → que compren más)? Las acciones son distintas: es una decisión **estratégica**. Con el tiempo se ven días de más venta (sábados) y de menos (miércoles) y relaciones entre productos (espaguetis y tomate).

2 Quién lo necesita y beneficios

Todo el que decide: compras, ventas, entidades financieras, marketing y personal. Las decisiones pueden ser **operativas o estratégicas**.

80 % / 20 %

Hospitales de Estados Unidos: tiempo preparando datos en Excel / analizando. Debería ser al revés

15 %

Directivos que confían en sus informes (IDC, International Data Corporation)

Urgente

En estructuras complejas y con muchos clientes (IDC)

Tipo	Ejemplos
Tangibles: ingresos	Segmentación, reducir el abandono, cesta de la compra, medir y ajustar campañas, clientes rentables

Tangibles: costos	Negociar con proveedores, inventarios *just-in-time*, detectar fraude, menos incobrables, "una sola versión de la verdad"
Intangibles	Mejor atención y satisfacción, información más actualizada y precisa, integración, ventaja competitiva
Estratégicos	Formular la estrategia: qué clientes, mercados y productos; decisiones rápidas basadas en hechos

Truco para recordar
"Tan-In-Es": beneficios **Tan**gibles, **In**tangibles y **Es**tratégicos.

3 Componentes básicos de un proyecto de BI

Caso de la empresa de distribución: suben los **gastos de distribución**. Se copian a un *datawarehouse* los **pedidos** (importe, líneas, artículos) y las **expediciones** (costo, bultos, peso, transportista); aparecen los pedidos **urgentes** con sobrecosto; se agrega el cliente y las **tarifas externas** para simular cambiar de transportista; al final se construyen **modelos con alertas**.

1	2	3	4	5	6
Problemática empresarial	Equipo o persona que analiza	Información interna	Información externa	*Datawarehouse*	Aplicación de BI

Nota técnica 1: sistemas de información

Se necesita información para **soportar transacciones**, **tomar decisiones y controlar**, y para **nuevos negocios**. Los sistemas sirven para **controlar, coordinar y decidir** en la **planificación, la gestión y las operaciones**. Preguntas **estructuradas** (¿entregamos a tiempo?) frente a **no estructuradas** (¿lanzamos el producto Y en Z?). Un **ERP** (*Enterprise Resources Planning*, planificación de recursos empresariales) integra módulos con el **dato único**; si no hay integración, se usan **interfases**.

4 Retorno de la inversión (ROI)

Fórmulas

ROI (*Return on Investment*) simple = **valor para el negocio / costo del proyecto**.

ROI = NPV / inversión inicial × 100. **NPV** (*Net Present Value*, valor actual neto) = flujos de caja (CF, *Cash Flow*) descontados a la tasa r, menos la inversión.

TCO (*Total Cost of Ownership*, costo total de propiedad): *hardware*, *software*, consultoría, personal, lanzamiento, mantenimiento y formación.

Ejemplo del supermercado

Objetivo: **una línea más por ticket** en el 25 % de los tickets (150.000 de 600.000). Margen año 1: 52.920 €; luego 75.000 € y 90.000 €.

Inversión **40.000 €**, mantenimiento **15.000 €/año**, tasa **15 %** → **NPV 87.656 €** y **ROI 219 %**. El seguimiento mostró desvíos en marzo y abril: hay que analizar por segmentos y tener **KPI**.

1 Problema y objetivos → 2 Requerimiento → 3 Construir → 4 Beneficios → 5 Punto de partida → 6 TCO → 7 ROI → 8 Seguimiento

Pasos de Bill Whittemore. Objetivos específicos, medibles, alcanzables, adecuados y con plazo.

401 %	**2,3 años**	**17 % a 2.000 %**	**42,9 %**
ROI medio a 3 años (IDC 1996)	*Payback* (período de recuperación)	ROI en IDC 2002; 49 % recupera en menos de un año	Proyectos aprobados por prototipo (Watson)

Paul Westerman (Wal-Mart): "el estudio del ROI no es una opción, es una necesidad"; estos proyectos nunca terminan.

5 Modelización del negocio

Modelo de negocio
"Aquello que no se mide, no se puede gestionar." Es una **simplificación de la realidad** que permite **documentar, probar y desarrollar teorías** sobre cómo funciona el negocio y **experimentar** cómo afectan los cambios al resultado. Debe estar **vivo**.

Empresa de paquetería

¿Conviene tener camiones propios? (comparar con lo que costaría subcontratar). ¿Qué rutas son rentables? ¿Cuáles potenciar? → las de **baja ocupación**. El resultado depende del **precio** y la **ocupación**.

Silos de información

Departamentos entre los que no fluye la información (falta de integración o razones políticas). Lo mejor para uno no es lo mejor para todos (atención al cliente subutiliza camiones).

Wal-Mart

Informe por tienda del distrito: superficie, ventas de este año y del anterior, ventas por metro cuadrado, cantidad de ventas y gasolina.

Cómo se crea: contabilidad analítica o de costos, **EFQM** (*European Foundation for Quality Management*), Six Sigma, análisis de procesos, modelos financieros, análisis de ratios; identificando áreas críticas y factores del resultado.

6 Indicadores clave (KPI)

Qué son

KPI (*Key Performance Indicators*, indicadores clave de desempeño): evalúan si la organización **alcanza sus objetivos**. Deben **reflejar los objetivos**, ser **críticos**, **cuantificables y comparables** y **permitir acciones correctivas**. Pocos, alineados y definidos con cada área. Cada uno tiene **nombre, definición, cálculo y objetivo**.

Truco

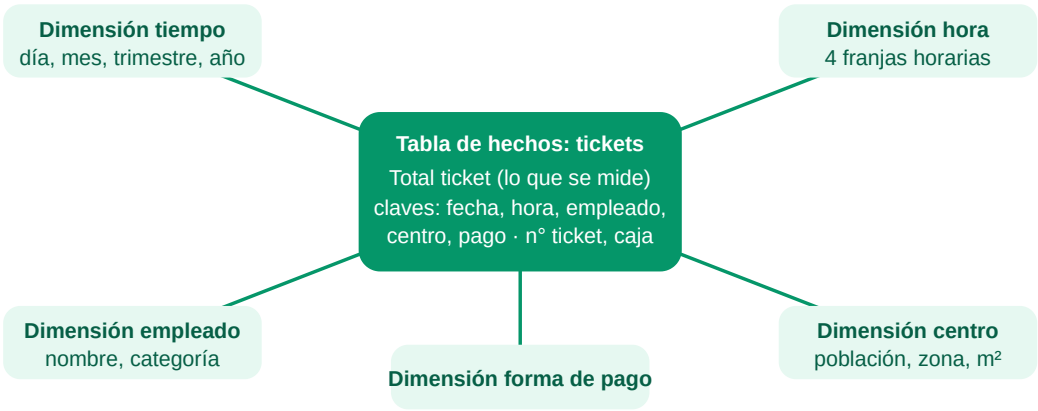
"Re-Crí-Cuan-Co": **Re**flejar objetivos, **Crí**ticos, **Cuan**tificables, **Co**rrectivos.

Ejemplo del libro	Repetición de ventas a clientes
Definición	Ventas a clientes que ya lo eran el trimestre anterior
Cálculo	Esas ventas / ventas totales
Objetivo	**Mejorar 3 % por trimestre desde el 48 %**

Otro ejemplo: venta telefónica, % de llamadas atendidas antes de **20 segundos**. En un KPI de ventas hay que decidir: dinero o unidades, cuándo se restan las devoluciones y qué objetivo fijar.

7 Modelo de datos

- **Modelo relacional** (E. F. **Codd**, **1970**): tablas y relaciones. **PK** (*Primary Key*, clave primaria) y **FK** (*Foreign Key*, clave externa). Se consulta con **SQL** (*Structured Query Language*, lenguaje de consulta estructurado).
- Primero el modelo de negocio; después qué se **mide (hechos)** y **cómo (dimensiones)**. Las dimensiones responden **qué, quién, por qué, dónde y cuándo**.
- **Dimensiones degeneradas**: no necesitan tabla (número de ticket, identificador de caja).
- **Dimensión tiempo**: día de la semana, del mes, del año, mes, trimestre, año, vacaciones, fin de semana (hay que agregarlos: no están en el transaccional). **Dimensión hora**: 4 franjas.



Esquema estrella de los tickets del supermercado (capítulo 3).

	Esquema estrella	Esquema copo de nieve (*snowflake*)
Dimensiones	**Una tabla por dimensión**, desnormalizada	**Normalizadas**, tablas relacionadas (Zona aparte de Centro)
Relaciones	Solo hechos ↔ dimensiones	También dimensión ↔ dimensión
Redundancia	Sí (la zona se repite por centro)	No
A favor / en contra	Simple y rápido / ocupa más	Menos espacio / más complejo

Granularidad

Nivel de detalle. Líneas de ticket = **mayor** granularidad que tickets. Cada nivel responde unas preguntas y no otras; **al agregar se pierde información**. Conviene el máximo detalle si el volumen lo permite.

Multidimensionalidad

Analizar por **varias dimensiones a la vez**: ventas de un artículo por centro y por mes. **Jerarquías**: año → trimestre → mes → día; familia → subfamilia → artículo.

Constelación y metadata

Constelación o **galaxia**: estrellas que comparten dimensiones. **Metadata** o diccionario de datos: misma terminología para todos.

Ojo

Cada modelo responde un número limitado de preguntas. El fabricante va en una dimensión distinta del artículo para poder cruzarlos. La lectura escribe "Standard Query Language"; el desarrollo habitual de SQL es **Structured Query Language**.

Sector	Hechos	Dimensiones
Distribución	Unidades e importe vendidos	Tienda, código postal, producto, familia, día
Telecomunicaciones	Duración y cantidad media de llamadas	Origen, destino
Banca	Saldo medio	Cliente, cuenta, oficina, producto
Seguros	Importe de reclamaciones	Tipo de póliza, cliente

8 Componentes de BI (capítulo 4)



En un proyecto real el orden es otro: primero se definen los **objetivos, el alcance y los modelos de negocio**.

Fuentes de información

Operacionales (aplicaciones a medida, ERP, CRM (Gestión de la relación con clientes), SCM (Gestión de la cadena de suministro)), **departamentales** (previsiones, presupuestos, hojas de cálculo) y **externas** (estudios de mercado, población). En promedio se cargan **8 bases** (hasta 50). Hay información estructurada, semiestructurada y no estructurada.

Calidad de datos

Los errores se **propagan por toda la organización** y desprestigian el proyecto. Vienen de los transaccionales, del ETL o del *datawarehouse*: conviene corregirlos **en el origen**. Es un problema **de negocio**. El **48 %** no tenía plan de calidad (TDWI 2001). Características: **precisión, integridad, coherencia, totalidad, validez, disponibilidad y accesibilidad**.

Proceso ETL: 60 % a 80 % del tiempo de un proyecto de BI

Subproceso	Qué hace
1. Extracción	Recupera los datos de las fuentes: datos **en bruto**. Manual (rutinas) o con herramientas ETL (lo más rentable)
2. Limpieza	Calidad, duplicados, corrige y completa: datos **limpios**. Etapas: depurar (*parsing*), corregir, estandarizar, relacionar (*matching*) y consolidar
3. Transformación	Estructura y **sumariza** según los modelos (formatos, códigos, derivados, **agregados**); ajusta la granularidad
4. Integración	Valida consistencia con el *datawarehouse* y carga (los totales deben coincidir con el origen)
5. Actualización	Define la **periodicidad** de las cargas

Almacén intermedio (*data staging*): paso entre la extracción y la carga mientras se limpian los datos; **los usuarios finales nunca acceden**. Datos "sucios": valores por defecto (código 999), ausentes, crípticos, contradictorios, claves reutilizadas.

Datawarehouse

Información **consistente, integrada, histórica y preparada**. Watson: "colección de información creada para soportar la toma de decisiones". **Inmon**: **orientado a un área, integrado, indexado en el tiempo, no volátil**. Kimball: incluye las herramientas de consulta y es "donde publicamos la información". Se actualiza mensual, semanal o diariamente (*right time*).

Data Mart

Para una **comunidad de usuarios** y pocas áreas; **más chico** que el *datawarehouse*. **Dependiente**: se alimenta del *datawarehouse*. **Independiente**: directo de las fuentes; puede perpetuar los **silos**.

Inmon

Datawarehouse **corporativo** primero y de él salen los Data Marts (de arriba hacia abajo). Integrado y escalable, pero caro, lento y propenso al fracaso.

versus

Kimball

Data Marts por área sin *datawarehouse* central. Barato, fácil, el más común; riesgo de silos. Según Watson, **las dos son válidas**.

Metadata

"Información de la información": significado, origen y transformaciones de cada tabla y atributo. Obliga a usar **la misma terminología** en toda la organización.

ODS (almacén de datos operacional)

Consolida fuentes para decisiones **operativas**; datos **volátiles**, en **tiempo real**, de hasta dos o tres meses. Suele alimentar al *datawarehouse*.

OLAP (procesamiento analítico en línea)

Análisis **multidimensional** en distintos niveles de agregación. **FASMI**: *Fast, Analysis, Shared, Multidimensional, Information* (resumen de las 12 reglas de Codd). Se representa con **cubos**: cada celda guarda un **hecho** (unidades de un libro vendidas a un cliente en un año).

Rotar

Slicing: cambia el orden de las dimensiones.

Seleccionar

Dicing: toma solo algunas celdas.

Agregar

Roll-up: sube al máximo nivel de agregación.

Bajar al detalle

Drill-down: baja por una jerarquía.

Tipo	Cómo accede	Ventaja / desventaja
ROLAP (OLAP relacional)	Base relacional, normalmente modelo estrella	Sin límite de tamaño / más lento
MOLAP (OLAP multidimensional)	Base multidimensional	Muy rápido / si cambian las dimensiones hay que recargar el cubo
HOLAP (OLAP híbrido)	Agregados en la multidimensional, detalle en la relacional	Combina ventajas
DOLAP (OLAP de escritorio)	Cubo en la memoria de la computadora del usuario	Solo lo que le interesa al usuario

Herramientas de BI: generadores de informes, consultas del usuario final, OLAP, ***dashboards*** (operativos o tácticos) y ***scorecards*** (estratégicos, como el *Balanced Scorecard*), planificación y simulación, minería de datos y de texto, visualización y GIS (sistemas de información geográfica). Alternativa al OLAP: **lógica asociativa** (QlikView).

Usuarios (Eckerson y Howson)

Productores (alrededor del **20 %**): estadísticos, autores de informes, usuarios avanzados. **Consumidores** (la mayoría): directivos y gestores con cuadros de mando e informes, cada vez más vía web.

Ojo

Se diferencian **roles, no individuos**: el mismo ejecutivo usa un informe estático y un cuadro de mando en tiempo real. Hay que conocer qué necesita cada rol antes de elegir la herramienta.

9 Guías del TP7

Pregunta	Respuesta modelo
¿Momento adecuado para aplicar BI?	**De forma continua**; sobre todo con mercados que cambian rápido, ante anomalías o cuando los responsables están desbordados
¿A qué organizaciones va dirigida?	A cualquiera que decida; urgente en estructuras complejas, con muchos clientes o procesos "artesanales"
¿Cómo unificar información de distintos entornos?	Copiarla a un *datawarehouse* sin afectar a los transaccionales y cruzarla: "una sola versión de la verdad"
¿Cómo crear un modelo de negocio?	Con contabilidad analítica, EFQM, Six Sigma, análisis de procesos o ratios
Factores del modelado de datos	Partir del modelo de negocio, definir hechos y dimensiones, ver qué datos faltan (calendarios, feriados)
¿Qué son las tablas de dimensiones?	El contexto para agrupar y filtrar los hechos (tiempo, centro, empleado, pago)

10 Experiencias desarrolladas

Empresa	Sector	Proyecto	Para qué se usó BI
Cavas Castillo de Perelada	Vinos y cavas	*Dashboard* sobre *datawarehouse*	Crecer en **margen**, no en facturación
Embega (Mondragón)	Embellecedores metálicos	Ventas y análisis financiero	Seguimiento **diario** de ventas y calidad de servicio

Sage SP	*Software* para pymes	*Datawarehouse* y *reporting*	**Calidad de datos** de clientes
De Blas y Cía	Transporte de pasajeros	Gestión del rendimiento corporativo	Entender Tráfico y Taller
Grupo Cortefiel	Moda	*Datawarehouse* y CRM	**Predicción** de abandono y venta cruzada; campañas por segmento
Contifarma	Parafarmacia	Cuadro de mando	Reemplazar un análisis **artesanal**
Loterías y Apuestas del Estado	Entidad pública	Microsoft Dynamics NAV	Contabilidad y *reporting*
Grupo Codorníu	Bodegas	Información corporativa sobre SAP	**Una única versión de la verdad**

Tema 9 · Trabajo Práctico N°8 (TP8)

Minería de datos

Minería de datos (DM, *Data Mining*) y proceso **KDD** (*Knowledge Discovery in Databases*, descubrimiento de conocimiento en bases de datos). Lectura "Minería de Datos", apuntes del 14/9 y TP8 (primera parte e integrador de fútbol).

Qué es

Métodos y algoritmos para la **extracción automática** de información sintetizada que caracteriza **relaciones escondidas** en grandes volúmenes de datos, con capacidad **predictiva**. Reúne estadística y **aprendizaje automático**. Analogía: una **montaña** de datos con **diamantes** escondidos.

Datos

Registros de observaciones o sucesos.

Información

Lo que se obtiene al detectar la utilidad de los datos.

Conocimiento

Reglas de cómo una cosa afecta a otra. "El conocimiento es poder".

No confundir con monitoreo

La minería trabaja con **datos estáticos** (un estado pasado que no cambia mientras se analiza). El **monitoreo** opera sobre datos **cambiantes en tiempo real** y reconoce patrones; no descubre.

1 Proceso KDD

Definición

Término usado desde **1989**. Extracción **no trivial** de información **implícita**, **previamente desconocida** y **potencialmente útil** a partir de un conjunto de datos. Es una **inducción no supervisada**: buscar regularidades y formular leyes que las describan.

KDD frente a minería

El **KDD es el proceso completo**; la minería es **solo la etapa de descubrimiento**. Fundamental, pero **subordinada**.

Idea del KDD	Qué exige
Lenguaje de alto nivel	Conocimiento **inteligible para un humano**. Quedan afuera las **redes neuronales** (bajo nivel), aunque sean un método válido de minería
Precisión	Los datos tienen ruido; se mide el **grado de certidumbre**. Con certeza baja no hay conocimiento
Interés	Solo lo **nuevo, potencialmente útil y no trivial**
Eficiencia	Tiempo y memoria que crecen de forma **polinomial** con los datos

Truco para recordar

"Le-Pre-In-E": **Le**nguaje de alto nivel, **Pre**cisión, **In**terés, **E**ficiencia.

Los 9 pasos del proceso KDD

1 Dominio — Objetivos del usuario
2 Datos objetivo — Selección, muestreo
3 Preprocesado — Ruido, ausentes
4 Transformación — Paso crítico
5 Tipo de sistema — Tarea
6 Algoritmo
7 Minería — Búsqueda de patrones
8 Interpretación — Puede volver al paso 1
9 Consolidación — Incorporar o documentar

Diagrama: BD → Selección → Datos objetivo → Preprocesado → Transformación → Minería → Patrones → Interpretación / Evaluación → Conocimiento. Truco: "Do-Ob-Pre-Trans | Sis-Al-Mi | In-Con".

Potencia

Computadoras más potentes y almacenamiento más barato.

Ritmo de datos

La información almacenada se duplica cada **20 meses**; satélites: cerca de un petabyte por día.

Nuevos métodos

Aprendizaje de la inteligencia artificial, estadística y física.

Aprendizaje automático frente a minería: el primero usa un conjunto **chico y seleccionado**; la minería, una base **grande** generada para **otros propósitos**.

2 Fases del KDD según la lectura (6 estados)

1. **Recolección**: fuentes internas y externas; mejor una fuente **unificada, accesible y desconectada** del trabajo transaccional. Depende de la fuente (OLAP (Procesamiento analítico en línea) u **OLTP**, *On-Line Transaction Processing*; **ROLAP (OLAP relacional)** o **MOLAP (OLAP multidimensional)**) y del usuario: **picapedreros o granjeros** (informes periódicos) y **exploradores** (patrones nuevos).
2. **Selección, limpieza y transformación**: **limpieza** (erróneos o inconsistentes) y **criba** (irrelevantes), con histogramas, muestreo y redefinición de atributos.
3. **Minería**: **dirigida** (se sabe qué buscar, predecir) o **no dirigida** (no se sabe).
4. **Evaluación y validación**: banco de ejemplos **independiente**, después una **experiencia piloto** (un *mailing*).
5. **Interpretación y difusión**: cervezas y congelados se compran juntos → ponerlos en **estantes distantes**.
6. **Actualización y monitorización**: el modelo envejece si cambia el contexto; hay que revalidarlo.

3 Datos atípicos y faltantes

Acción	Atípicos (*outliers*)	Faltantes (*missing values*)
Ignorar	Algoritmos robustos (árboles)	Algoritmos robustos (árboles)
Filtrar la columna	Extremo; mejor una columna "normal / atípico"	Extremo; mejor una columna booleana "existía / no"
Filtrar la fila	**Sesga los datos**: las causas suelen ser casos especiales	
Reemplazar	Por nulo, máximo, mínimo o media; o predecirlo	Por la media; o predecirlo
Discretizar	Muy alto ... muy bajo: el atípico cae en un extremo	—
Segmentar	—	Modelos por segmento que luego se combinan
Esperar	—	Cambiar la política de calidad de datos

Faltante relevante

No dar el teléfono = no quiere ser molestado.

Faltante no existente

Un cliente nuevo no tiene consumo de 12 meses.

Faltante incompleto

Al unir fuentes distintas se suman campos.

4 Evolución histórica

Etapa	Pregunta típica	Tecnología	Característica
Recolección (años 60)	Beneficios de los últimos 4 años	Computadoras, cintas	Retrospectivo, estático
Acceso (años 80)	Ventas en Cataluña la última Navidad	Relacionales (SQL (Lenguaje de consulta estructurado)), ODBC (Conectividad abierta de bases de datos)	Retrospectivo, por registro
Datawarehouse (años 90)	Ventas en Andalucía hasta la tienda	OLAP, multidimensionales	Retrospectivo, varios niveles
Minería de datos	Tendencia en Castilla el año próximo	Algoritmos avanzados	**Prospectivo, proactivo**

5 Qué no es minería de datos

Minería de datos

- Modelo **automático**.
- **Exploratoria**.
- Incorpora **inteligencia artificial**.
- Mejor con **muchas variables**.
- **Menos restrictiva** en supuestos.
- Trabaja con **toda la base** (clase).

versus

Estadística clásica

- La maneja un **estadístico**.
- **Confirmatoria** (prueba hipótesis).
- Teoría de la probabilidad.
- Difícil con muchas variables.
- Los datos deben cumplir requisitos.
- Toma **muestras** e infiere (clase).

No es OLAP

OLAP **navega** los datos de forma asistida (análisis multidimensional) pero **no genera información nueva**. **MOLAP**: bases multidimensionales, datos precompilados, soluciones departamentales chicas. **ROLAP**: sobre bases relacionales, traduce a SQL; más flexible.

6 Los tres retos

1. Falsa interpretación

Es fácil engañarse con la estadística (vale para grupos, no individuos); con software de minería, más fácil aún "hacer creíble una falsedad".

2. Correlación no es causalidad

Florida tiene la edad al fallecer más alta de Estados Unidos porque allí se mudan los jubilados (**efecto de selección**), no porque alargue la vida. La minería es **explorativa, no explicativa**: hay que validar con datos nuevos.

3. Tiempo, espacio y privacidad

Variables que cambian en el período; **granularidad del tiempo** (con datos mensuales no se predice por semana); **privacidad** al combinar bases (teléfono, banco, supermercado).

Se estima que el **80 %** de los datos se puede georreferenciar y el **100 %** ubicar en el tiempo.

7 Tareas de la minería

Supervisadas / predictivas

- **Clasificación**: asigna a una de varias **clases predefinidas**.
- **Regresión**: predice un **valor real**.

Dos fases: **entrenamiento** y **prueba**. Ejemplo: árbol "*Play Tennis*" (soleado, caluroso, humedad alta, viento fuerte → No).

versus

No supervisadas / descriptivas

- **Agrupamiento** (*clustering*).
- **Condensación**: descripción compacta.
- **Detección de desviaciones**.
- **Modelado de dependencias**.

Ejemplo: **K-means** agrupa 15 empleados en **3 grupos**.

Preprocesado → **Selección de características** → **Algoritmo de extracción** → **Evaluación y validación**

Proceso de minería en 4 estados (capítulo 2 de la lectura).

Taxonomía

Interpolación, predicción secuencial, supervisado, no supervisado y abducción. **Clasificación** (clases disjuntas) frente a **categorización** (se solapan); clase de dos valores = *concept learning*; clase continua = **estimación**.

Reglas de asociación

Confianza = casos con antecedente y consecuente / casos con antecedente. **Soporte** = casos donde se aplica. **Apriori**: fase A, conjuntos frecuentes; fase B, reglas con confianza suficiente. Hay asociaciones **negativas** (pizza congelada y lentejas).

Combinar hipótesis: *boosting* (el **mismo** algoritmo sobre particiones distintas) y *voting* (**distintos** algoritmos sobre todos los datos).

8 Métodos y técnicas

Métodos: agrupamiento, asociación, **secuenciamiento** (el tiempo es clave), reconocimiento de patrones, **previsión** (series temporales), simulación (CAD-CAM (Diseño y fabricación asistidos por computadora)), optimización y clasificación (*scoring*).

Supervisados	No supervisados
Árboles de decisión	Detección de desviaciones
Inducción neuronal	Segmentación
Regresión	Agrupamiento (*clustering*)
Series temporales	Reglas de asociación · Patrones secuenciales

Estadísticas

ANOVA (análisis de la varianza), **Ji cuadrado** (independencia), **componentes principales** (reduce variables), clusters, **discriminante** (grupos ya definidos), regresión **lineal** (continuas) y **logística** (admite discretas).

Árboles de decisión

CART (Árboles de clasificación y regresión) divide en **2** (validación cruzada, índice de Gini). **CHAID (Detector automático de interacciones por Ji cuadrado)** divide en **más de 2** (test Ji cuadrado). La raíz es todo el conjunto.

Redes neuronales

Inspiradas en el cerebro (desde 1930), capas de neuronas. Inconveniente: **no dan una ecuación que explique el modelo** (caja negra).

Algoritmos genéticos

Mutación y cruce para **optimizar**; se usan al principio para **elegir variables**.

Redes bayesianas

Dependencias y causalidad, combinan conocimiento y datos, evitan el sobreajuste, toleran datos incompletos.

Otras

Reglas de asociación (cesta), lógica difusa, series temporales, inducción de reglas y sistemas expertos (motor de inferencia).

9 Evaluación

Precisión
Modelo lo más preciso posible.

Explicación
Que el usuario entienda cómo funciona.

Integración
Incrustado en el negocio, sin copias de datos.

Medida	Qué es
Precisión	% de predicciones correctas
Tasa de error	Complemento; de 99 % a 99,5 % el error se reduce a la mitad
Error en rechazo	Se descartan las predicciones con poca confianza
Error cuadrático medio	Variables continuas; pesa más los errores grandes
Elevación (*lift*)	Mejora frente al azar: 30 % / 10 % = **3**
Beneficio / ROI (Retorno de la inversión)	La mejor medida

10 Apuntes de clase y CRISP-DM

Aplicaciones
Retención de clientes, patrones de compra, fraude, riesgo (a quién prestar), segmentación.

Bodega de datos
Base orientada a consultas: **consolidada, consistente, temática, histórica y de solo lectura**. Punto de partida de la minería.

Comprensión del negocio → Comprensión de los datos → Preparación → Modelado → Evaluación → Implantación

CRISP-DM (*Cross-Industry Standard Process for Data Mining*): 6 fases, proceso confiable y repetible para personas con pocos conocimientos.

Eje	KDD	CRISP-DM	SEMMA (Muestrear, Explorar, Modificar, Modelar, Evaluar)
Origen	Académico (1989, Fayyad)	Consorcio DaimlerChrysler, SPSS y NCR (SPSS Clementine)	SAS Institute (SAS Enterprise Miner)
Fases	9 (5 en el núcleo de Fayyad)	6, en secuencia no rígida	5: *Sample* (opcional), *Explore, Modify, Model, Assess*
Iteración	Muy iterativo	Ciclo con retroalimentación	Más secuencial
Negocio	Foco en validez científica	**La más orientada al negocio**	Técnica; supone los objetivos
¿Negocio y despliegue?	Sí, antes y después del núcleo	Sí, explícitamente	**No explícitamente** (implícito en *Sample*)

Mapeo según el artículo de la cátedra (Azevedo y Santos)

KDD	SEMMA	CRISP-DM
Antes del KDD (dominio)	—	Comprensión del negocio
Selección	*Sample*	Comprensión de los datos
Preprocesamiento	*Explore*	
Transformación	*Modify*	Preparación de los datos
Minería de datos	*Model*	Modelado
Interpretación / evaluación	*Assess*	Evaluación
Después del KDD (consolidación)	—	Despliegue

Conclusión del artículo
SEMMA y CRISP-DM son **implementaciones del proceso KDD**. CRISP-DM parece más completo, pero SEMMA incluye implícitamente el negocio y la consolidación. **Ojo**: el TP8 del grupo asociaba el preprocesado con la preparación de los datos; según el artículo va con la **comprensión de los datos**.

11 Preguntas teóricas del TP8

Consigna	Respuesta clave
Fallo en el preprocesado	El **modelo clasificador** aprende el ruido como patrón, los faltantes sesgan, los atípicos distorsionan; la evaluación puede engañar si el banco de prueba tiene el mismo defecto
Minería sin KDD / KDD sin minería	Sin KDD es una operación **ciega** (no sabe qué buscar ni si vale); sin minería el KDD queda **inconcluso** (datos limpios sin patrones)
Minería, OLAP y monitoreo	Minería **genera** información sobre datos **estáticos** (proactiva); OLAP **navega** datos históricos agregados (*drill-down*, *roll-up*, *slice & dice*); monitoreo **verifica** datos en **tiempo real** (alertas)
Redes neuronales y KDD	Predicen bien, pero el conocimiento queda en miles de **pesos**: **caja negra** que no cumple el lenguaje de alto nivel
Sesgo de cada solución	Filtrar filas **sesga**; la media **reduce la varianza**; discretizar **pierde precisión**; segmentar puede **sobreajustar**
Ensayo	Escalabilidad + granularidad del tiempo + privacidad: más detalle y más fuentes cruzadas = perfiles más precisos. Ley 25.326 (Argentina) y GDPR (Reglamento General de Protección de Datos, Unión Europea)

Tema 10 · Trabajo Práctico N°9 (TP9)

Big Data

10

Ecosistema para **capturar, almacenar y analizar** datos de gran **volumen, velocidad y variedad**. TP9 del grupo (mapa conceptual y comparación) y apunte de clase "Ingeniería de datos".

Fuente

Cotejado con la guía de PowerData *Del bit... al Big Data* de la cátedra. **"Big" no es la clave**: el volumen es solo una parte; las empresas quieren saber **qué va a pasar** y lo más cerca posible del **tiempo real**. Hoy puede valer más detectar al **cliente que más influye** que al que más compra.

Qué es

Paradigma o ecosistema tecnológico para capturar y procesar **grandes volúmenes de información variada a alta velocidad**, que superan a los sistemas tradicionales. Es la **infraestructura base** sobre la que se construyen el análisis y la estrategia.

Volumen
Cantidad masiva de datos

Velocidad
Se generan y procesan rápido, en tiempo real

Variedad
Estructurados, semiestructurados y no estructurados

1 Mapa conceptual

Nace de nuevas necesidades

- **Personalización máxima** del cliente.
- **De la transacción a la interacción**.
- **Nuevos dispositivos**: móviles, domótica, vehículos con sensores.

Requiere Big Analytics

- Análisis **predictivo** y **clusterización** de clientes.
- Datos **en crudo, al mayor detalle**.
- Lo operan **Data Scientist** y **Data Analyst**.
- Evoluciona desde el **BI (Inteligencia de negocio) tradicional y el *Data Warehouse*** (DWH): modelos **rígidos, poco ágiles y sin tiempo real**.
- Se integra con el **ADW** (*Analytic Data Warehouse*): **modelo híbrido DWH + ADW**.

Metodología MAD (Magnética, Ágil, Detallada)

- **Magnética**: capta todo tipo de datos.
- **Ágil**: ingiere y se adapta rápido.
- **Detallada**: análisis estadístico fino.

Tecnología: Hadoop

- **HDFS** (*Hadoop Distributed File System*): archivos distribuidos.
- **MapReduce**: procesamiento paralelo.
- **Código abierto** y *commodity hardware* (equipos comunes y baratos).

4 megatendencias

Movilidad · Cloud · Social Media · Analytics

Tiempo real

- **Data Stream**: analiza datos en movimiento.
- **CEP** (*Complex Event Processing*, procesamiento de eventos complejos): detecta eventos predefinidos, como fraude con tarjetas.

Implementación

Medir el valor para el negocio; **las metas determinan la tecnología** (no al revés); perfiles de negocio con herramientas adecuadas. Bases **MPP** (*Massively Parallel Processing*) para el análisis predictivo.

Impacto y desafío

Genera innovación y ventaja competitiva. **Plantea** el desafío de **seguridad y privacidad**: equilibrio entre los datos analizados y lo que el cliente tolera.

Origen de Hadoop

Google no podía indexar la web y aplicó "divide y vencerás": muchas computadoras chicas que actúan como una. En **2006** la comunidad de código abierto crea Hadoop; lo impulsa **Yahoo** y lo adopta **Facebook**. Costo bajo y **ROI (Retorno de la inversión) muy rápido**.

Big Analytics y el ADW

El BI tradicional cargaba modelos tan lento que al terminar ya no servían. Analytics trabaja **en crudo, al nivel más bajo de granularidad**. El **ADW no reemplaza** al *data warehouse*: conviven en un **modelo híbrido**. Surge el perfil de **Data Science**.

Ejemplos de CEP

Un banco que vigila en tiempo real las **tarjetas** en cajeros y comercios; **sensores de maquinaria** que avisan antes de un fallo.

Humanizando el Big Data

The Human Face of Big Data: compras por internet, autos con sensores, historiales médicos. Privacidad: en Google "no todo es gratis", el precio es la privacidad.

Megatendencias: **Movilidad** (acceso desde dispositivos que no son de la empresa), **Cloud** (sin comprar infraestructura; se puede **prever el costo del crecimiento**), **Social Media** (gustos para captar y fidelizar), **Analytics** (cualquier dato, sin patrones prefijados). **Implementación**: primero **cuantificar el valor** para el negocio; para tiempo real, **CEP**; para predicción, bases **MPP**.

Truco para recordar
3 V (Volumen, Velocidad, Variedad) · **MAD = Ma-Ág-De** · megatendencias **"MoCSA"**: **Mo**vilidad, **C**loud, **S**ocial Media, **A**nalytics.

2 BI, minería de datos y Big Data

Aspecto	BI	Minería de datos	Big Data
Pregunta	¿Qué pasó y cómo vamos?	¿Qué patrones hay?	¿Qué va a pasar y qué descubrimos con todo?
Tiempo	Pasado y presente	Pasado, para descubrir y predecir	Presente y futuro, tiempo real
Datos	Estructurados, internos	Estructurados y semiestructurados, preparados	También **no estructurados** (redes, sensores, logs)
Volumen	Moderado	Moderado a grande	**Masivo**, distribuido
Técnicas	Consultas, reportes, tableros, OLAP (Procesamiento analítico en línea), KPI (Indicador clave de desempeño)	Clasificación, agrupamiento, asociación, regresión	Big Analytics, MapReduce, Data Stream, CEP
Tecnología	*Datawarehouse*, ETL (Extracción, transformación y carga)	Algoritmos estadísticos y de aprendizaje	Hadoop, ADW, *cloud*, MPP
Perfil	Gerentes y analistas de negocio	Analistas de datos, estadísticos	Data Scientist, Data Analyst
Resultado	Informes y tableros	Modelos y patrones	Conocimiento y servicios personalizados
Limitación	Poco ágil, sin tiempo real	Depende de la calidad de los datos	Infraestructura, perfiles, privacidad

Matriz de la clase ("Ingeniería de datos")

	Big Data	Minería de datos	BI
Fin	Almacenar y procesar a escala masiva	**Descubrir patrones**	**Optimizar decisiones**
Datos	**Crudos** y variados	**Consolidados**	**Estructurados y depurados**
Perfil	Ingeniero de datos	Científico de datos	Analista de BI
Foco temporal	Presente continuo	Futuro predictivo	Pasado y presente

Big Data Captura y procesa → **Minería de datos** Descubre patrones → **BI** Indicadores y decisiones

Cómo se relacionan
No son excluyentes: conviven en un **modelo híbrido**. BI mira hacia atrás; Big Data apunta hacia adelante; la minería se aplica sobre un *datawarehouse* o sobre Big Data.

Diferencia entre el TP y la clase
el TP pone la minería en el "pasado" y la clase en el "futuro predictivo". Si preguntan: la minería **analiza datos pasados para predecir el futuro**.

Para la última pasada

Repaso final

Cómo se conectan las cuatro unidades, reglas para memorizar, errores frecuentes, preguntas integradoras y autopreguntas.

1 Mapa de relaciones

Diseño del comportamiento

Las **Redes de Petri** modelan cómo se comporta un sistema concurrente: procesos, estados y recursos compartidos.

Datos para decidir

Big Data captura y procesa → la **minería** descubre patrones → **BI (Inteligencia de negocio)** los convierte en indicadores y decisiones.

- El *datawarehouse* de BI es el **punto de partida** de la minería.
- OLAP (Procesamiento analítico en línea) aparece en BI y en minería (que **no es** OLAP).
- La **granularidad** aparece en el modelo de datos de BI y en el tercer reto de la minería.
- La **privacidad** aparece en minería (tercer reto) y en Big Data (desafío).

2 Trucos para memorizar

Lu-Tra-Ar-Ma: Lugares, Transiciones, Arcos, Marcas.

Mu-Du-W: el árbol se corta en Muertos, Duplicados o con W.

Más menos menos: $C = C^+$ (Matriz de incidencia posterior) − C^- (Matriz de incidencia previa) y $M' = M - Pre + Post$.

VACCa: Vivacidad, Acotamiento, Ciclicidad, Conservación, alcanzabilidad.

Pi-E-A-Info-Á-Co: definición de BI de Gartner.

Tan-In-Es: beneficios Tangibles, Intangibles, Estratégicos.

Re-Crí-Cuan-Co: requisitos de un KPI (Indicador clave de desempeño).

Le-Pre-In-E: ideas del KDD (Descubrimiento de conocimiento en bases de datos).

MAD y **MoCSA**: Magnética, Ágil, Detallada · Movilidad, Cloud, Social Media, Analytics.

3 Errores frecuentes

Mal: "Una red viva siempre es cíclica". **Bien:** son propiedades independientes.

Mal: "Red segura = no se bloquea". **Bien:** segura = 1-acotada; no bloquearse = vivacidad.

Mal: "$C = C^- - C^+$". **Bien:** $C = C^+ - C^-$.

Mal: "Un arco puede unir dos lugares". **Bien:** siempre une lugar y transición.

Mal: "BI es un análisis puntual". **Bien:** es un proceso continuo.

Mal: "La estrella está normalizada". **Bien:** la estrella es desnormalizada; el copo de nieve, normalizado.

Mal: "Mayor granularidad = menos detalle". **Bien:** mayor granularidad = más detalle.

Mal: "Un Data Mart es más grande que el *datawarehouse*". **Bien:** es más chico.

Mal: "KDD y minería son lo mismo". **Bien:** la minería es una etapa del KDD.

Mal: "OLAP descubre patrones". **Bien:** OLAP navega; la minería descubre.

Mal: "Correlación implica causalidad". **Bien:** no (Florida).

Mal: "La regresión es descriptiva". **Bien:** es predictiva / supervisada.

Mal: "Las redes neuronales cumplen el lenguaje de alto nivel". **Bien:** son una caja negra.

Mal: "Big Data reemplaza al *datawarehouse*". **Bien:** conviven (modelo híbrido).

Mal: "SEMMA (Muestrear, Explorar, Modificar, Modelar, Evaluar) incluye la comprensión del negocio". **Bien:** la supone resuelta.

4 Preguntas integradoras

Pregunta	Respuesta modelo
¿Por qué la minería depende del *datawarehouse* de BI?	Necesita datos **consolidados, limpios e históricos**, desconectados de los transaccionales, que provee el *datawarehouse* cargado con **ETL (Extracción, transformación y carga)**. Por eso es su punto de partida.
Compará OLAP, minería y Big Data	**OLAP** navega datos agregados sin generar información nueva; la **minería** descubre y predice automáticamente; **Big Data** es el contexto de datos masivos, veloces y variados que exige **Hadoop** y análisis en tiempo real (**CEP (Procesamiento de eventos complejos)**).
Granularidad en BI y tercer reto de la minería	El **nivel de detalle** decide qué preguntas se responden: con tickets no se analizan productos; con datos mensuales no se predice por semana. **Al agregar se pierde información**.
Dos cajeros y una impresora con una Red de Petri	Un ciclo por cajero y un **lugar "impresora libre" con una marca** (semáforo): **exclusión mutua**, transiciones en **conflicto**, red **viva y segura**, sin **prioridades**.
Bajan las ventas: ¿BI, minería o Big Data?	**BI**: cantidad de tickets frente a ticket medio (KPI). **Minería**: reglas de asociación o K-means. **Big Data**: redes, app y fidelidad para personalizar y predecir, cuidando la **privacidad**.

5 Autopreguntas

- ¿Qué es un nodo frontera y cuáles son los tres tipos?
- ¿Qué diferencia hay entre una red viva, parcialmente viva y no viva?
- En el productor-consumidor con buffer de 3, ¿cuánto suman "llenos" y "vacíos"?
- ¿Qué cuatro decisiones toma un supermercado con la información operativa del ticket?
- ¿Cuáles son los 6 componentes de un proyecto de BI?
- ¿Qué es una dimensión degenerada? Dos ejemplos.
- ¿Por qué el fabricante va en una dimensión distinta del artículo?
- ¿Cuáles son los 9 pasos del KDD y cuál es el crítico?
- ¿Qué hace un "picapedrero" y qué hace un "explorador"?
- ¿Qué es la elevación (*lift*) y cómo se calcula?
- ¿Qué es la metodología MAD?
- ¿Qué diferencia hay entre Data Stream y CEP?

Referencia

Glosario de siglas y abreviaturas

Todas las siglas y reglas para recordar usadas en el resumen y en la práctica, agrupadas por unidad.

Redes de Petri

Sigla	Desarrollo	Original
RdP	Red de Petri	—
M0	Marcado inicial	—
C^-	Matriz de incidencia previa	—
C^+	Matriz de incidencia posterior	—
MT	Máquina de testigos	—
GE	Grafo de estados	—
ME	Máquina de estados	—
GM	Grafo marcado	—
RLE	Red de libre elección	—
RS	Red simple	—
DFD	Diagrama de flujo de datos	—

Business Intelligence

Sigla	Desarrollo	Original
BI	Inteligencia de negocio	*Business Intelligence*
KPI	Indicador clave de desempeño	*Key Performance Indicator*
ROI	Retorno de la inversión	*Return on Investment*
NPV	Valor actual neto	*Net Present Value*
TCO	Costo total de propiedad	*Total Cost of Ownership*
CF	Flujo de caja	*Cash Flow*
ETL	Extracción, transformación y carga	*Extract, Transform, Load*
OLAP	Procesamiento analítico en línea	*On-Line Analytical Processing*
OLTP	Procesamiento de transacciones en línea	*On-Line Transaction Processing*
MOLAP	OLAP multidimensional	*Multidimensional OLAP*
ROLAP	OLAP relacional	*Relational OLAP*
HOLAP	OLAP híbrido	*Hybrid OLAP*
DOLAP	OLAP de escritorio	*Desktop OLAP*
FASMI	Rápido, análisis, compartido, multidimensional, información	*Fast, Analysis, Shared, Multidimensional, Information*
ODS	Almacén de datos operacional	*Operational Data Store*
CRM	Gestión de la relación con clientes	*Customer Relationship Management*
SCM	Gestión de la cadena de suministro	*Supply Chain Management*
GIS	Sistemas de información geográfica	*Geographic Information Systems*
DWH	Almacén de datos	*Data Warehouse*
ERP	Planificación de recursos empresariales	*Enterprise Resources Planning*
PK	Clave primaria	*Primary Key*
FK	Clave externa	*Foreign Key*
SQL	Lenguaje de consulta estructurado	*Structured Query Language*
ODBC	Conectividad abierta de bases de datos	*Open Database Connectivity*
DAX	Expresiones de análisis de datos	*Data Analysis Expressions*
IDC	International Data Corporation, consultora	—

TDWI	The Data Warehousing Institute	—
EFQM	Fundación Europea para la Gestión de la Calidad	*European Foundation for Quality Management*

Minería de datos

Sigla	Desarrollo	Original
DM	Minería de datos	*Data Mining*
KDD	Descubrimiento de conocimiento en bases de datos	*Knowledge Discovery in Databases*
CRISP-DM	Proceso estándar intersectorial para minería de datos	*Cross-Industry Standard Process for Data Mining*
SEMMA	Muestrear, Explorar, Modificar, Modelar, Evaluar	*Sample, Explore, Modify, Model, Assess*
ML	Aprendizaje automático	*Machine Learning*
IA	Inteligencia artificial	—
ANOVA	Análisis de la varianza	*Analysis of Variance*
CART	Árboles de clasificación y regresión	*Classification And Regression Trees*
CHAID	Detector automático de interacciones por Ji cuadrado	*Chi Squared Automatic Interaction Detector*
k-NN	k vecinos más cercanos	*k Nearest Neighbors*
IQR	Rango intercuartílico	*Interquartile Range*
PII	Información de identificación personal	*Personally Identifiable Information*
GDPR	Reglamento General de Protección de Datos, de la Unión Europea	*General Data Protection Regulation*
CAD-CAM	Diseño y fabricación asistidos por computadora	*Computer-Aided Design / Manufacturing*

Big Data

Sigla	Desarrollo	Original
ADW	Almacén de datos analítico	*Analytic Data Warehouse*
MAD	Magnética, Ágil, Detallada	—
HDFS	Sistema de archivos distribuido de Hadoop	*Hadoop Distributed File System*
CEP	Procesamiento de eventos complejos	*Complex Event Processing*
MPP	Procesamiento masivamente paralelo	*Massively Parallel Processing*

Otras siglas y reglas para recordar

Sigla	Desarrollo	Original
TP	Trabajo Práctico	—
N°	Número	—
Lu-Tra-Ar-Ma	Elementos de una Red de Petri: Lugares, Transiciones, Arcos, Marcas	—
Mu-Du-W	Dónde se corta el árbol de alcanzabilidad: Muertos, Duplicados, con W	—
VACCa	Propiedades de comportamiento: Vivacidad, Acotamiento, Ciclicidad, Conservación, alcanzabilidad	—
Tan-In-Es	Beneficios de BI: Tangibles, Intangibles, Estratégicos	—
Re-Crí-Cuan-Co	Requisitos de un KPI: Reflejar objetivos, Críticos, Cuantificables, Correctivos	—
Le-Pre-In-E	Ideas del KDD: Lenguaje de alto nivel, Precisión, Interés, Eficiencia	—
MoCSA	Megatendencias del Big Data: Movilidad, Cloud, Social Media, Analytics	—