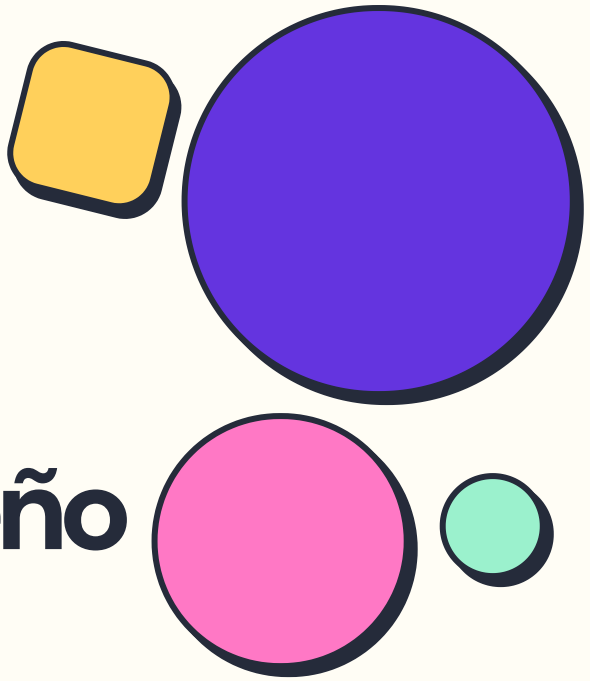
Tecnicatura en Análisis y Desarrollo de Software · Instituto de Profesorado Sedes Sapientiae



Análisis y Diseño de Sistemas II

Resumen visual · 2do parcial

Redes de Petri, *Business Intelligence* y Minería de datos para el parcial. Big Data (tema 10) queda como material para el final. Solo la teoría, salvo en Redes de Petri, donde también entran el árbol de alcanzabilidad, las propiedades, la máquina de testigos y el método matricial.

6 y 7 · Redes de Petri

Lugares, transiciones, marcas, árbol de alcanzabilidad, matrices y propiedades

8 · Business Intelligence

Definición, beneficios, ROI, KPI, modelo de datos, ETL, datawarehouse y OLAP

9 · Minería de datos

KDD, tareas, técnicas, evaluación, CRISP-DM y SEMMA

10 · Big Data (final)

3 V, Big Analytics, MAD, Hadoop, megatendencias y comparación con BI y minería

Grupo: Valentín Figún, Matías Morales y Paula Rocío Haunau · Docente: María Silvina Scarpin · Octubre 2026

Armado a partir de los Trabajos Prácticos (TP) 6 a 9 del grupo (Figún, Morales, Haunau), del material de la cátedra (carpeta compartida *Análisis y Diseño de Sistemas II - 2026*: presentaciones de Redes de Petri, capítulos del libro *Business Intelligence: competir con información*, experiencias de BI, lectura de Minería de Datos, artículo KDD-SEMMA-CRISP-DM y guía *Del bit… al Big Data* de PowerData) y de los apuntes de clase. Docente: María Silvina Scarpin. Tecnicatura en Análisis y Desarrollo de Software, Instituto de Profesorado Sedes Sapientiae.

Temas del examen

Bloque	Qué entra	Fuente principal
Temas 6 y 7	Teoría completa y práctica de árbol de alcanzabilidad, propiedades, máquina de testigos y método matricial. Redes de Petri: definición, historia, representación gráfica y matricial, ejecución, árbol de alcanzabilidad y máquina de testigos, estructuras básicas, propiedades, subclases, métodos de análisis, modelos clásicos	TP6; presentaciones de la cátedra "Redes_de_petri" y "Formalización Redes de Petri"; lectura de Jorge Castro Monge; apunte de clase
Tema 8	*Business Intelligence* (BI): definición, beneficios, componentes (fuentes, calidad de datos, ETL, *datawarehouse*, Data Mart, OLAP, herramientas, usuarios), retorno de la inversión, modelo de negocio, indicadores clave y modelo de datos. Solo teoría	TP7; capítulos 1 a 4 del libro *Business Intelligence: competir con información* ("Introducción al BI", "BI_modelos", "Componentes de BI")
Tema 9	Minería de datos y proceso KDD (descubrimiento de conocimiento en bases de datos): fases, limpieza, tareas, técnicas, evaluación, metodologías KDD, CRISP-DM y SEMMA. Solo teoría	TP8; lectura "Minería de Datos" (Beatriz Beltrán Martínez, Benemérita Universidad Autónoma de Puebla); artículo "KDD, SEMMA and CRISP-DM: a parallel overview" (Azevedo y Santos); apuntes del 14/9
Tema 10 (entra en el final, no en el parcial)	Big Data: las 3 V, nuevas necesidades, Big Analytics, metodología MAD, Hadoop, megatendencias, tiempo real, implementación, comparación con BI y minería. Solo teoría	TP9; guía *Del bit… al Big Data* (PowerData); apunte de clase "Ingeniería de datos"

Aclaraciones de la docente (vigentes)

- **De todos los temas entra solo la teoría.**
- **Big Data (tema 10) entra en el final**, no en el 2do parcial. Queda en el resumen como material para el final.
- **Excepción, Redes de Petri**: además de la teoría entran el **árbol de alcanzabilidad**, las **características y propiedades**, y **resolver una red con máquina de testigos y método matricial** (ver 1.12).
- **No entra**: la práctica de los TP (caso CoffeeTime, TP integrador de fútbol, aplicación en comercio minorista, caso de abandono de compra, modelado de las 7 tareas y demás ejercicios de modelado del TP6). Se sacaron de los tres entregables.

Cómo leer las marcas

- = sale de tus archivos (material de la cátedra, TP del grupo o apuntes de clase).
- ⚠ = no verificado: no hay fuente primaria en la carpeta, sale solo de un TP o apunte del grupo que no se pudo cotejar con el material de la cátedra, o es una propuesta armada para este resumen.
- ✔ / ✘ = correcto / incorrecto en las listas de errores frecuentes.

Siglas y abreviaturas

Toda sigla se desarrolla la primera vez que aparece en cada sección. TP = Trabajo Práctico. RdP = Red de Petri. El glosario completo está al final.

Avisos antes de estudiar

1. **Alcance.** Para el **2do parcial**: solo teoría de los temas 6 a 9 (Redes de Petri, BI y Minería de datos), más la práctica de Redes de Petri indicada arriba. **Big Data (tema 10) entra en el final.** El resumen ya está recortado a eso: no incluye ejemplos puntuales, casos de empresas ni datos sueltos de un autor o de un estudio.
2. **Numeración.** La cátedra numera así: Temas 6 y 7 = Redes de Petri, Tema 8 = BI, Tema 9 = Minería de datos, Tema 10 = Big Data. El resumen usa esa numeración; Big Data queda como material para el final.
3. **Redes de Petri, apunte de clase con errores.** El apunte dice "una red viva es cíclica": no es correcto, vivacidad y ciclicidad son propiedades independientes y ninguna presentación de la cátedra lo dice. Las definiciones de conflicto estructural y efectivo se toman de la presentación "Redes_de_petri" (ver 1.8 y "Errores frecuentes").
4. **Mapeo KDD, SEMMA y CRISP-DM.** El cuadro del TP8 del grupo difiere un poco del artículo de la cátedra (Azevedo y Santos). Se corrigió según el artículo (ver 3.13).
5. **Videos.** Los videos de los temas 8 y 10 no se pudieron revisar (solo se procesó texto). La guía de PowerData sí está cotejada.
6. **Siglas que el libro escribe distinto.** La lectura de BI dice "Standard Query Language" para SQL y "Object Data Base Connector" para ODBC; los desarrollos habituales son **Structured Query Language** y **Open Database Connectivity**. Usá los habituales y, si te lo preguntan, sabé que el libro los escribe distinto.

0. Datos para memorizar

Dato	Valor
Creador de las Redes de Petri	Carl Adam Petri (alemán), tesis doctoral de 1962 *Kommunikation mit Automaten*
Holt y Commoner	1970, "Events and Conditions": aplican las RdP a sistemas concurrentes
Estructura de una Red de Petri	C = (P, T, I, O): lugares, transiciones, función de entrada, función de salida
Red marcada	M = (C, μ)
Matriz de incidencia	$C = C^+ - C^-$ (posterior menos previa); filas = transiciones, columnas = lugares
Ecuación de disparo	M'(p) = M(p) − Pre(p, t) + Post(t, p)
Red segura	1-acotada (binaria): ningún lugar tiene más de una marca
Ecuación de estado	$M' = M + f(\sigma) \cdot C$, con f(σ) el vector de disparo (cuántas veces se dispara cada transición)
Transición habilitada (método matricial)	$M \geq e_j \cdot C^-$
ω en el árbol de alcanzabilidad	La red no es acotada
Subclases de RdP	4: grafo de estados o máquina de estados, grafo marcado, red de libre elección, red simple
Primero en usar "Business Intelligence"	Howard Dresner (consultor de Gartner)
BI según Gartner	Proceso **interactivo** para **explorar** y **analizar** información **estructurada** de un **área**, normalmente en un *datawarehouse*
ROI (fórmula simple)	Valor para el negocio / costo del proyecto
ROI (fórmula completa)	NPV / inversión inicial × 100
Proceso ETL	Consume entre el 60 % y el 80 % del tiempo de un proyecto de BI; 5 subprocesos
Características de un *datawarehouse* (Inmon)	Orientado a un área, integrado, indexado en el tiempo, no volátil
Concepto FASMI de OLAP	*Fast, Analysis, Shared, Multidimensional, Information*
Modelo relacional	E. F. Codd, 1970
Las dimensiones responden	¿Qué? ¿Quién? ¿Por qué? ¿Dónde? ¿Cuándo?
Término KDD	Empieza a usarse en 1989
Pasos del proceso KDD	9
Fases (estados) del KDD según la lectura	6
CRISP-DM	6 fases; consorcio DaimlerChrysler, SPSS y NCR
SEMMA	5 fases: *Sample, Explore, Modify, Model, Assess*; SAS Institute

Dato	Valor
KDD según Fayyad	5 etapas núcleo: selección, preprocesamiento, transformación, minería, interpretación/evaluación
Big Data	3 V: volumen, velocidad, variedad
Metodología MAD	Magnética, Ágil, Detallada
Megatendencias del Big Data	4: Movilidad, Cloud, Social Media, Analytics
Hadoop	HDFS (archivos distribuidos) + MapReduce (procesamiento paralelo); código abierto desde 2006, nace de Google

1. Redes de Petri (Temas 6 y 7)

1.1 Qué son y para qué sirven

- Teoría matemática de **Carl Adam Petri**: herramienta **gráfica y matemática** de modelado para describir formalmente sistemas con **concurrencia, sincronización, exclusión mutua y conflictos**, típicos de los sistemas distribuidos.
- **Antecedente: las máquinas de estado** (estado + transición, con entradas y salidas *a/b*). Su gran límite: modelar **acciones simultáneas**. Unir varias máquinas de estado hace explotar la cantidad de estados y vuelve ilegible el diagrama.
- Las Redes de Petri (RdP) representan la concurrencia de forma natural porque tienen **paralelismo inherente**.
- Al analizar la red se obtiene información sobre la **estructura** y el **comportamiento dinámico** del sistema, para evaluarlo y sugerir mejoras.
- **Definición de la presentación de la cátedra**: representaciones gráficas que modelan sistemas con flujo de información, mostrando su estructura y comportamiento dinámico. Pueden verse como **generadores de lenguaje o autómatas formales** asociados a la teoría de grafos; sirven para diseñar, especificar y simular sistemas de *hardware* o *software*.
- **Historia**: surgen en **1962** con la tesis doctoral de Carl Adam Petri, *Kommunikation mit Automaten* ("Comunicación con autómatas"), en Alemania: una teoría de comunicación entre componentes **asíncronos**. El proyecto "Systemics" aportó la notación. En **1970**, **Holt y Commoner** ("Events and Conditions") muestran cómo aplicarlas a sistemas con componentes concurrentes.
- **Tres ventajas de modelar con RdP** (presentación "Formalización"): el sistema es más fácil de entender por la naturaleza gráfica y precisa; el comportamiento se puede analizar con la teoría (árboles de marcados, relación entre estructura y comportamiento); y como se sintetizan *bottom-up* o *top-down*, se pueden diseñar sistemas de comportamiento conocido o verificable.
- **Extensiones**: modificaciones estructurales (más potencia o comodidad de modelado) y **redes de Petri temporizadas** (análisis cuantitativo de prestaciones).
- **En programación concurrente**: transiciones = procesos; lugares = condiciones para que un proceso se ejecute; marcas = la condición se verifica.
- Apunte de clase: se usan para modelar un sistema, ver cómo funciona, identificar sus procesos y los estados por los que pasa; se usan como **autómatas**. Cualquier proceso puede reflejarse con una RdP.

1.2 Elementos y representación gráfica

Elemento	Dibujo	Qué representa al modelar
Lugar o plaza	Círculo	Condición o estado
Transición	Barra	Evento o suceso
Arco dirigido	Flecha con peso (si no tiene número, pesa 1)	Une lugar → transición (lugar de entrada) o transición → lugar (lugar de salida). Nunca lugar con lugar ni transición con transición
Marca o *token*	Punto negro dentro del lugar	Que la condición se cumple. Un lugar con marcas está **activo**

- La red es un **multígrafo dirigido bipartito**: admite arcos múltiples, los arcos tienen dirección y los nodos se dividen en dos conjuntos (lugares y transiciones) que solo se conectan entre sí.
- Una transición está **sensibilizada** (habilitada) cuando todos sus lugares de origen están marcados; está **validada** cuando además ocurre el evento asociado.
- Representación **gráfica** y **matricial** son equivalentes: dada una se obtiene la otra, y es única.

1.3 Definición formal

- **Estructura**: C = (P, T, I, O), donde P es un conjunto finito y no vacío de lugares, T un conjunto finito y no vacío de transiciones, I la **función de entrada** (lugares de entrada de cada transición) y O la **función de salida** (lugares de salida).
- **Marcado** μ: función de P en los enteros no negativos; también se escribe como vector μ = (μ1, ..., μn) con n = cantidad de lugares. El marcado es el **estado** de la red.
- **Red marcada**: M = (C, μ). Hay infinitos marcados posibles (el conjunto es infinito pero numerable).
- **Tipos de red**:
  - **Ordinaria**: todos los arcos pesan 1.
  - **Generalizada**: los arcos pueden tener cualquier peso entero mayor o igual que cero.
  - **Pura** (no reflexiva): ningún lugar es a la vez entrada y salida de la misma transición.
- Notación del apunte: I(t) lugares de entrada a t; O(t) lugares de salida de t; I'(p) transiciones que entran al lugar p; O'(p) transiciones que salen de p; V(p, t) y V(t, p) valores (pesos) de los arcos.

1.4 Ejecución (reglas de disparo)

1. **Habilitación**: t está habilitada si cada lugar de entrada tiene al menos tantas marcas como el peso del arco hacia t: M(p) ≥ I(p, t). Una **transición fuente** (sin lugares de entrada) está siempre habilitada.
2. **Disparo**: se quitan de cada lugar de entrada tantas marcas como el peso del arco, y se agregan a cada lugar de salida tantas como el peso del arco de salida. Cuál de las habilitadas se dispara primero es **arbitrario**.
3. **Nuevo marcado**: **M'(p) = M(p) − Pre(p, t) + Post(t, p)**. Una **transición sumidero** (sin lugares de salida) elimina marcas de la red.

- Las marcas son **indivisibles**: una marca la quita una sola transición. Por eso disparar una transición puede **deshabilitar** a otra que compartía el lugar de entrada. Fuera de eso, los disparos son **asíncronos**.
- **Grado de habilitación**: cuántas veces puede dispararse una transición de forma concurrente.
- **Inmediatamente alcanzable**: se llega disparando una sola transición. **Alcanzable**: existe una secuencia de disparos σ que lleva de Mi a Mk. **Conjunto de alcanzabilidad** R(M): todos los marcados alcanzables desde M.

1.5 Árbol de alcanzabilidad

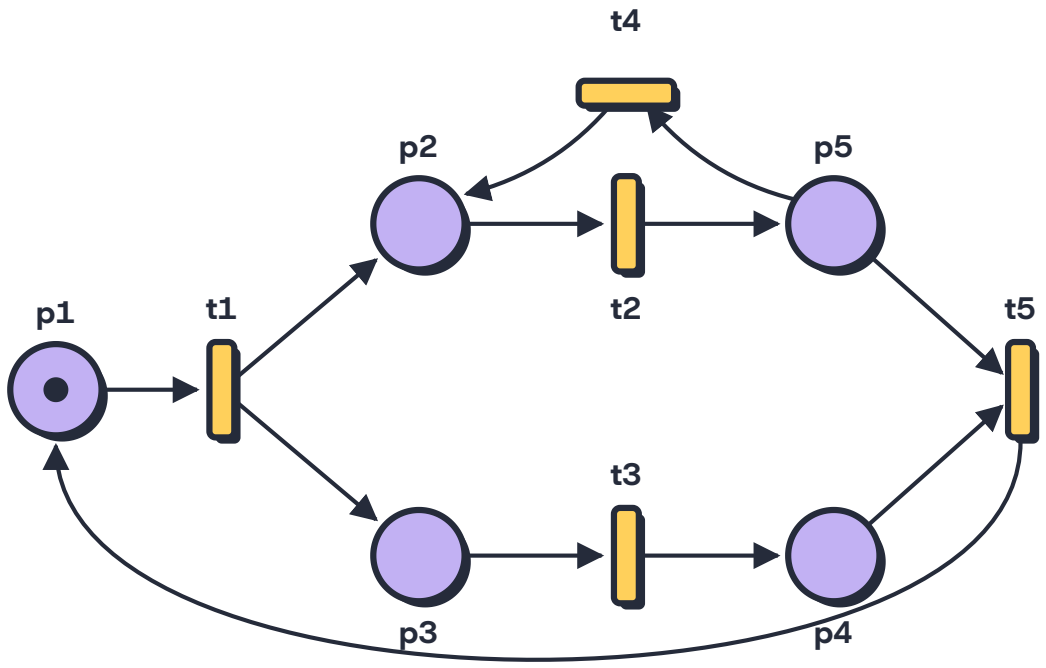
- Representa **todos los marcados alcanzables** desde M0. Cada nodo es un marcado; cada arco lleva el nombre de la transición disparada.
- Se parte de M0, se generan los marcados que se obtienen disparando cada transición habilitada, y se repite. Para que el árbol sea **finito** se deja de expandir en los **nodos frontera**:
  - a) **Marcado muerto**: no hay ninguna transición habilitada.
  - b) **Nodo duplicado**: el marcado ya apareció en el árbol.
  - c) Marcado que solo difiere de otro por tener **más marcas en algún lugar** y habilita las mismas transiciones: se escribe **w** (infinito) en ese lugar. Indica que la red **no es acotada**.
- **Máquina de testigos** (MT): versión más compacta del árbol. Cada estado se escribe con los **nombres de los lugares que tienen marcas** (un nombre repetido tantas veces como marcas tenga); los estados van en **óvalos**

unidos por arcos con el nombre de la transición. Conviene cuando hay **muchos lugares y pocas marcas**, porque no hay que enumerar todos los lugares.

1.6 Representación matricial

- **C^- (matriz de incidencia previa)**: $C^-[j, i] = I(p_i, t_j)$, las precondiciones (función de entrada).
- **C^+ (matriz de incidencia posterior)**: $C^+[j, i] = O(p_i, t_j)$, las postcondiciones (función de salida).
- **$C = C^+ - C^-$ (matriz de incidencia)**. Según la lectura: **filas = transiciones, columnas = lugares**.
- Forma matricial (presentación "Formalización"): una transición tj se representa con el vector **ej** (1 en la posición j, 0 en el resto). tj está habilitada si $\mathbf{M \geq ej \cdot C^-}$, y al dispararla $\mathbf{M' = M + ej \cdot C}$.
- Para una **secuencia** σ = tj1 tj2 … tjk: $\mathbf{M' = M + f(\sigma) \cdot C}$, donde $\mathbf{f(\sigma) = ej1 + ej2 + \ldots + ejk}$ es el **vector de disparo** (cuántas veces se dispara cada transición). Ejemplo de la cátedra: σ = t1, t2, t3 → f(σ) = (1 1 1 0 0) → M' = (0 0 0 1 1).

Ejemplo resuelto (el de la lectura) — P = {p1…p5}, T = {t1…t5}, M0 = (1, 0, 0, 0, 0). I(t1) = {p1}, O(t1) = {p2, p3}; I(t2) = {p2}, O(t2) = {p5}; I(t3) = {p3}, O(t3) = {p4}; I(t4) = {p5}, O(t4) = {p2}; I(t5) = {p4, p5}, O(t5) = {p1}.



Red del ejemplo de la lectura. M0 = (1, 0, 0, 0, 0): una marca en p1.

	C^- (p1 p2 p3 p4 p5)	C^+ (p1 p2 p3 p4 p5)	C (p1 p2 p3 p4 p5)
t1	1 0 0 0 0	0 1 1 0 0	−1 1 1 0 0
t2	0 1 0 0 0	0 0 0 0 1	0 −1 0 0 1
t3	0 0 1 0 0	0 0 0 1 0	0 0 −1 1 0
t4	0 0 0 0 1	0 1 0 0 0	0 1 0 0 −1
t5	0 0 0 1 1	1 0 0 0 0	1 0 0 −1 −1

Marcados alcanzables (verificados): (1,0,0,0,0) → t1 → (0,1,1,0,0) → t2 → (0,0,1,0,1) o t3 → (0,1,0,1,0); de ahí se llega a (0,0,0,1,1), donde t5 devuelve a M0 y t4 vuelve a (0,1,0,1,0). Son **5 marcados**, ninguno muerto, ningún lugar pasa de 1 marca: la red es **viva, segura y cíclica**. t2 y t3 son **concurrentes**; en (0,0,0,1,1) t4 y t5 están en **conflicto** (comparten p5).

1.7 Estructuras básicas

Estructura	Qué modela
Secuencial	t2 solo se dispara después de t1
Selección	Se elige qué proceso ejecutar (un lugar con dos transiciones de salida)
Atribución	Un proceso se ejecuta de forma independiente desde dos procesos distintos (dos transiciones que llegan al mismo lugar)
Distribución	Lanza procesos paralelos o concurrentes (una transición con varios lugares de salida)
Conjunción	Sincroniza procesos paralelos (una transición con varios lugares de entrada)
Sincronización	t1 se habilita solo si **todos** sus lugares de entrada tienen marca
Concurrencia	t2 y t3 pueden dispararse a la vez e independientemente
Conflicto	t1 y t2 están habilitadas, pero disparar una deshabilita a la otra

1.8 Propiedades

Estructurales (dependen solo de la topología, no del marcado inicial):

- **Pura**: ningún lugar es entrada y salida de la misma transición.
- **Estructuralmente acotada**: acotada para **cualquier** marcado inicial finito.
- **Estructuralmente viva**: existe **algún** marcado inicial para el que es viva.
- **Completamente controlable**: cualquier marcado es alcanzable desde cualquier otro.
- **Estructuralmente conservativa**: el número (ponderado) de marcas se mantiene para cualquier marcado inicial.

De comportamiento (dependen del marcado inicial M0):

Propiedad	Definición	Qué garantiza
Alcanzabilidad	Mn es alcanzable desde M0 si existe σ que lleva de M0 a Mn	Es la base para estudiar las demás
Vivacidad	Una transición es viva si, desde cualquier marcado alcanzable, se puede volver a disparar alguna vez. La red es **viva** si todas sus transiciones lo son	Ausencia de **bloqueo total (*deadlock*)**
Parcialmente viva	Desde cualquier marcado alcanzable hay al menos una transición disparable, pero hay alguna transición no viva	La red evoluciona, aunque algo se bloquee
No viva	Se llega a un marcado muerto	Hay bloqueo total
Acotamiento	Un lugar es **k-acotado** si nunca tiene más de k marcas; la red es k-acotada si todos sus lugares lo son	Número **finito** de estados; si la red genera más marcas que las permitidas, el modelo está mal
Seguridad	Red **1-acotada** = **segura** = **binaria**: cada lugar está marcado o no	No se excede la capacidad (por ejemplo, de un registro de memoria)
Ciclicidad o reversibilidad	Desde cualquier marcado alcanzable se puede volver a M0	No hay subconjuntos finales de estados de los que no se vuelve
Conservación	La cantidad total de marcas se mantiene constante	Recursos que no se crean ni se destruyen

Propiedad	Definición	Qué garantiza
Conflicto	Dos transiciones habilitadas comparten un lugar de entrada y disparar una deshabilita la otra	Hay una decisión no determinista
Exclusión mutua	Dos procesos no pueden usar el recurso a la vez	Acceso ordenado a un recurso compartido

- Lectura (forma resumida): la **supervivencia** es la ausencia de estancamientos; la **seguridad** se relaciona con la capacidad limitada de memoria.
- Ejemplo de la lectura: una red que no se bloquea con t1, t2, t1, t2 pero queda **bloqueada** con t1, t3, t4 → **no viva**. Otra red es **pseudoviva** y **no reversible** porque nunca vuelve a M0.
- **Conflictividad** (presentación "Redes_de_petri"): hay **conflicto estructural** cuando **un lugar tiene más de una transición de salida**. Dos transiciones ti y tj están en **conflicto efectivo** para M0 si existe un marcado alcanzable que **habilita a las dos a la vez** y, al disparar una, el marcado que queda **no habilita a la otra**.
- **Exclusión mutua** (misma presentación): un conjunto de transiciones es mutuamente exclusivo si disparar cualquiera **deshabilita a todas las demás**. Dos **lugares** están en exclusión mutua para M0 si **nunca pueden estar marcados a la vez** en los marcados alcanzables.
- **Limitación**: garantiza la **finitud** de los marcados alcanzables; una red k-limitada se puede **implementar con recursos finitos**.
- **Conservación**: el número de recursos no varía durante la ejecución. La forma más simple es que el total de testigos sea constante; como es muy exigente, se suele hablar de conservación **respecto de un vector peso**.
- Las propiedades sirven para **detectar fenómenos de interés o errores de funcionamiento** en el sistema modelado. La presentación las agrupa en seis: **vivacidad, ciclicidad, limitación, conservación, conflictividad y exclusión mutua**.

1.9 Modelos clásicos de concurrencia

- **Exclusión mutua (semáforo)**: un lugar "recurso libre" con una marca. El primer proceso que lo toma quita la marca y los demás esperan. Sirve para cualquier cantidad de procesos y **no tiene prioridades**.
- **Productor y consumidor**: un lugar "depósito con producto" (*buffer*) comunica a los dos procesos. Sin límite, el depósito puede crecer sin fin si el consumidor se detiene. Para un **buffer de capacidad finita** se agregan dos lugares: "buffers llenos" y "buffers vacíos"; **siempre suman la capacidad total** (por ejemplo, 3).
- **Lectores y escritores**: n lectores conocidos; las lecturas pueden ser concurrentes y la escritura es excluyente. Se usa un semáforo con **m marcas** y arcos de peso **m**: leer toma 1 marca, escribir toma las m.
- **Cinco filósofos**: cada uno tiene un plato y un tenedor a la izquierda; para comer necesita los dos tenedores de al lado. Si todos toman primero el mismo tenedor, nadie come: **estancamiento**. Solución para que la red sea viva: que la transición "comer" tome **los dos tenedores a la vez** (es una conjunción), o limitar con un lugar "sillas" con 4 marcas a cuántos intentan comer al mismo tiempo. ⚠ Las soluciones son las habituales; la del grupo está en imagen.

1.10 Ventajas, desventajas, aplicaciones, subclases y métodos de análisis

Ventajas	Desventajas
Fáciles de interpretar	No permiten modelar **prioridades**
Tratan procesos independientes	El análisis se complica con sistemas complejos
Modelan con más exactitud que un diagrama de estados	A mayor modelo, mayor consumo de recursos

Ventajas	Desventajas
Modelan recursos compartidos (exclusión mutua, por ejemplo una impresora)	
Se construyen de arriba hacia abajo (*top-down*) o de abajo hacia arriba (*bottom-up*)	Hay muchas **subclases** del modelo general para problemas específicos
Modelan procesos concurrentes	

Aplicaciones (presentación de la cátedra): sistemas en **tiempo real**, sistemas operativos y compiladores, *hardware* y *software*, ambientes industriales de producción (redes de libre elección), diagramas de flujo de datos (DFD), **protocolos de comunicación** y bases de datos.

Subclases: clases restringidas, más fáciles de analizar, que siguen modelando muchos sistemas.

Subclase	Regla	Qué puede y qué no puede modelar
Grafo de estados o **máquina de estados** (GE o ME)	Cada **transición** tiene exactamente **una entrada y una salida**	Conflictos y alternativas; **no** paralelismo, concurrencia ni sincronización. Estrictamente conservativa
Grafo marcado o de sincronización (GM)	Cada **lugar** tiene exactamente **una entrada y una salida**	Paralelismo, concurrencia y sincronización; **no** conflictos ni decisiones
Red de libre elección (RLE)	Si un lugar es entrada de varias transiciones, es su **única** entrada	Concurrencia y conflicto, de forma restringida: las transiciones en conflicto están habilitadas todas o ninguna
Red simple (RS)	Cada transición tiene como máximo **un lugar de entrada compartido** con otra	—

Métodos de análisis:

- **Árbol de alcanzabilidad**: da información detallada del comportamiento; sirve para validar el modelo, verificar un diseño, elegir entre propuestas o predecir. Desventaja: puede volverse **grande e inmanejable**.
- **Ecuaciones matriciales o de estado**: prometedoras pero con problemas: la matriz C **no refleja toda la estructura de la red**; el vector de disparo **no informa el orden** de los disparos; y que la ecuación $M' = M + f(\sigma) \cdot C$ tenga solución es condición **necesaria pero no suficiente** para que el marcado sea alcanzable.

Modelos de redes (al final de la presentación "Redes_de_petri"; son de investigación operativa): conceptos de arista, nodo, capacidad, fuente y sumidero; **ruta más corta** (trayectoria de mínima distancia entre origen y destino), **árbol de expansión mínima** (conectar todos los nodos al menor costo), **flujo máximo** (maximizar el flujo entre origen y destino respetando capacidades) y **flujo de costo mínimo** (abastecer la demanda al menor costo).

1.11 Verificación y ambientes de simulación

- Ejecutar la red permite **simular** el comportamiento: se logra una **verificación** del modelo. Una **validación** exige un lenguaje más formal (las técnicas matemáticas de análisis se acercan a una "prueba").
- Cuando el modelo crece, ejecutar a mano no sirve: hacen falta herramientas que lo ejecuten solas (por ejemplo **HPetriSim**, el simulador de los ejercicios).
- **Ambientes gráficos**: visión global rápida, pero definir la red es tedioso y en redes grandes el dibujo se vuelve confuso. **Ambientes estructurales** (intérprete): se pierde lo visual, pero la red escrita como pseudocódigo se acerca al código (lenguajes como ADA o Modula).

1.12 Práctica que entra en el parcial: resolver una red paso a paso

La docente aclaró que de Redes de Petri entran **árbol de alcanzabilidad**, **características y propiedades**, y **resolver una red con máquina de testigos y método matricial**. Los tres ejemplos de esta sección están resueltos y verificados por computadora.

Receta para el examen

1. **Leer la red**: lugares, transiciones, arcos (con su peso) y marcado inicial M0. Escribir I(t) y O(t) de cada transición.
2. **Matrices**: C^- (entradas), C^+ (salidas) y $\mathbf{C = C^+ - C^-}$, con **filas = transiciones** y **columnas = lugares**.
3. **Árbol de alcanzabilidad**: desde M0, por cada transición habilitada calcular el marcado nuevo y numerarlo (M1, M2…). Cortar en los **nodos frontera**: muerto, duplicado o con **ω** (infinito; el apunte lo escribe w). Con ω vale $\omega + 1 = \omega$ y $\omega - 1 = \omega$.
4. **Máquina de testigos**: juntar los duplicados y dibujar el **grafo de marcados**; cada estado (óvalo) lleva los nombres de los lugares marcados, repetidos tantas veces como marcas tengan.
5. **Método matricial**: comprobar una secuencia σ con $\mathbf{M' = M + f(\sigma)\cdot C}$. La ecuación no dice el orden: hay que verificar que cada transición esté habilitada en su momento ($\mathbf{M \geq ej\cdot C^-}$).
6. **Propiedades**: leerlas del árbol y del grafo con la tabla de abajo.

Propiedad	Cómo se lee en el árbol o en la máquina de testigos
Viva	No hay marcados muertos y, desde cualquier estado del grafo, se puede volver a disparar cada transición
Parcialmente viva	No hay marcados muertos, pero alguna transición deja de poder dispararse
No viva	Aparece un marcado muerto (bloqueo total)
Acotada (k-acotada)	No aparece ω; k es el máximo de marcas que llega a tener un lugar
Segura	k = 1: ningún lugar pasa de una marca
No acotada	Aparece ω en algún lugar
Cíclica (reversible)	Desde todos los estados del grafo se puede volver a M0
Conservativa	La suma de marcas es la misma en todos los marcados (o la suma ponderada con un vector peso)
Conflicto	Estructural: un lugar con dos o más transiciones de salida. Efectivo: en algún marcado las dos están habilitadas y disparar una deshabilita la otra
Concurrencia	Dos transiciones habilitadas a la vez que no comparten lugares de entrada
Exclusión mutua de lugares	Dos lugares que nunca están marcados a la vez en ningún marcado alcanzable
Pura	Ningún lugar es entrada y salida de la misma transición

Ejemplo 1 — red acotada (la de la lectura, ver 1.6)

P = {p1…p5}, M0 = (1, 0, 0, 0, 0). t1: p1 → p2, p3; t2: p2 → p5; t3: p3 → p4; t4: p5 → p2; t5: p4, p5 → p1. Las matrices están en 1.6.

Árbol de alcanzabilidad:

```
M0 (1,0,0,0,0)
└─ t1 → M1 (0,1,1,0,0)
   ├─ t2 → M2 (0,0,1,0,1)
   │  ├─ t3 → M4 (0,0,0,1,1)
   │  │  ├─ t4 → (0,1,0,1,0)  duplicado de M3
   │  │  └─ t5 → (1,0,0,0,0)  duplicado de M0
   │  └─ t4 → (0,1,1,0,0)  duplicado de M1
   └─ t3 → M3 (0,1,0,1,0)
      └─ t2 → (0,0,0,1,1)  duplicado de M4
```

Máquina de testigos (5 estados, 8 arcos):

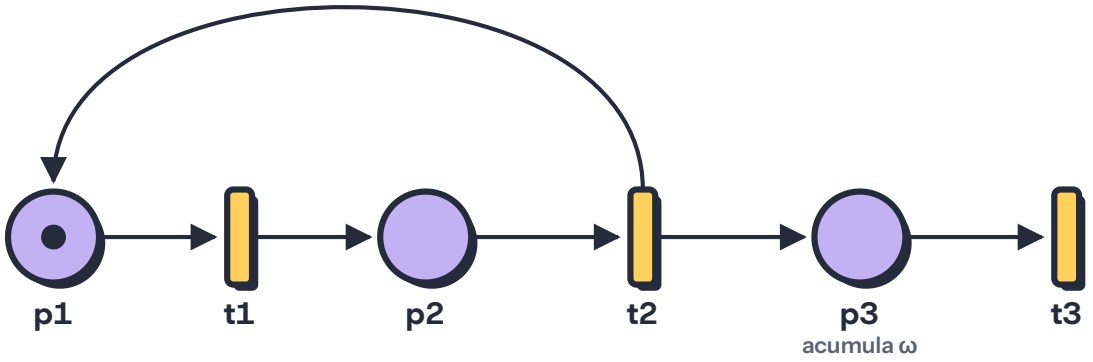
Desde	Transición	Hacia
p1	t1	p2 p3
p2 p3	t2	p3 p5
p2 p3	t3	p2 p4
p3 p5	t3	p4 p5
p3 p5	t4	p2 p3
p2 p4	t2	p4 p5
p4 p5	t4	p2 p4
p4 p5	t5	p1

Método matricial: σ = t1 t3 t2 t5 → f(σ) = (1 1 1 0 1). f(σ)·C = suma de las filas t1, t2, t3 y t5 de C = (0 0 0 0 0), entonces **M' = M0**: la secuencia vuelve al inicio. Habilitación de t5 en M4: e5·C⁻ = (0 0 0 1 1) ≤ (0 0 0 1 1).

Propiedades: **viva** (sin marcados muertos y el grafo vuelve siempre a todos los estados), **segura** (1-acotada), **cíclica**, **pura**. **No es estrictamente conservativa** (M0 tiene 1 marca y el resto 2), pero sí respecto del vector peso (2 1 1 1 1). **Conflicto** estructural en p5 (t4 y t5) y efectivo en M4. **Concurrencia**: t2 y t3 en M1; t3 y t4 en M2. **Exclusión mutua de lugares**: p2 y p5, p3 y p4, y p1 con todos los demás.

Ejemplo 2 — red no acotada (con ω)

P = {p1, p2, p3}, M0 = (1, 0, 0). t1: p1 → p2; t2: p2 → p1, p3; t3: p3 → (nada, es una transición sumidero).



Red no acotada. M0 = (1, 0, 0). t3 es una transición sumidero.

	C^- (p1 p2 p3)	C^+ (p1 p2 p3)	C (p1 p2 p3)
t1	1 0 0	0 1 0	−1 1 0
t2	0 1 0	1 0 1	1 −1 1
t3	0 0 1	0 0 0	0 0 −1

Árbol de alcanzabilidad:

```
M0 (1,0,0)
└─ t1 → M1 (0,1,0)
   └─ t2 → (1,0,1) cubre a M0 (igual en p1 y p2, más en p3) → M2 (1,0,ω)
      ├─ t1 → M3 (0,1,ω)
      │  ├─ t2 → (1,0,ω)  duplicado de M2
      │  └─ t3 → (0,1,ω)  duplicado de M3
      └─ t3 → (1,0,ω)  duplicado de M2
```

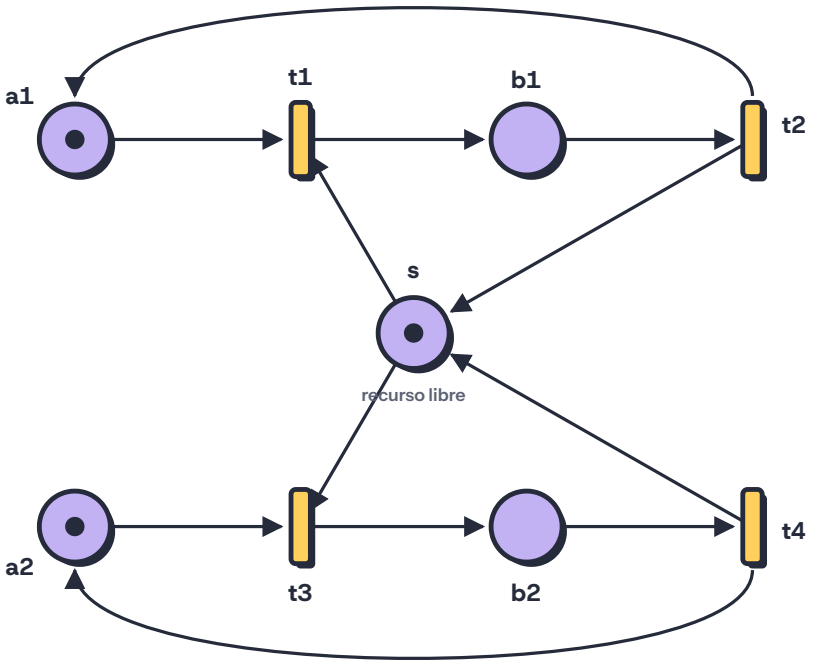
Máquina de testigos: p1 —t1→ p2 —t2→ p1 p3ω; p1 p3ω —t1→ p2 p3ω y —t3→ p1 p3ω; p2 p3ω —t2→ p1 p3ω y —t3→ p2 p3ω.

Método matricial: σ = t1 t2 t1 t2 t3 → f(σ) = (2 2 1) → M' = (1 0 0) + 2·(−1 1 0) + 2·(1 −1 1) + (0 0 −1) = **(1 0 1)**. Paso a paso: (0 1 0), (1 0 1), (0 1 1), (1 0 2), (1 0 1).

Propiedades: **no acotada** (p3 llega a ω; p1 y p2 son 1-acotados), **viva**, **cíclica** (desde (1, 0, k) se dispara t3 k veces y se vuelve a M0; el árbol con ω no alcanza para afirmarlo, hay que razonarlo), **no conservativa**, **pura**, **sin conflicto** (ningún lugar tiene dos transiciones de salida). **Exclusión mutua de lugares**: p1 y p2 (siempre p1 + p2 = 1).

Ejemplo 3 — exclusión mutua de dos procesos (semáforo)

Lugares: a1 y a2 (proceso esperando), b1 y b2 (proceso usando el recurso), s (recurso libre). M0 = (a1, b1, a2, b2, s) = (1, 0, 1, 0, 1). t1: a1, s → b1; t2: b1 → a1, s; t3: a2, s → b2; t4: b2 → a2, s.



Exclusión mutua de dos procesos. M0 = (a1, b1, a2, b2, s) = (1, 0, 1, 0, 1).

	C^- (a1 b1 a2 b2 s)	C^+ (a1 b1 a2 b2 s)	C (a1 b1 a2 b2 s)
t1	1 0 0 0 1	0 1 0 0 0	−1 1 0 0 −1
t2	0 1 0 0 0	1 0 0 0 1	1 −1 0 0 1
t3	0 0 1 0 1	0 0 0 1 0	0 0 −1 1 −1
t4	0 0 0 1 0	0 0 1 0 1	0 0 1 −1 1

Árbol: M0 (1,0,1,0,1) → t1 → M1 (0,1,1,0,0) → t2 → duplicado de M0; M0 → t3 → M2 (1,0,0,1,0) → t4 → duplicado de M0.
Máquina de testigos: a1 a2 s —t1→ b1 a2 —t2→ a1 a2 s; a1 a2 s —t3→ a1 b2 —t4→ a1 a2 s.

Método matricial: σ = t1 t2 t3 → f(σ) = (1 1 1 0) → M' = M0 + (0 0 −1 1 −1) = **(1 0 0 1 0)** = M2.

Propiedades: **viva**, **segura**, **cíclica**, **pura**; conservativa respecto del vector peso (1 2 1 2 1). **Conflicto** estructural y efectivo en s: en M0, t1 y t3 están habilitadas y disparar una deshabilita la otra. **Exclusión mutua**: b1 y b2 nunca están marcados a la vez.

Errores típicos al resolver

- Seguir expandiendo un nodo **duplicado**: se corta ahí.
- Poner ω sin comparar con un **antecesor** del mismo camino, o "restarle" marcas a ω.
- Armar la matriz con **filas = lugares**: según la lectura, filas = transiciones.
- Creer que si M' = M + f(σ)·C tiene solución, la secuencia se puede disparar: es condición **necesaria pero no suficiente**.
- En la máquina de testigos, olvidar repetir el nombre de un lugar que tiene **dos marcas**.

2. Business Intelligence (Tema 8)

2.1 Definición

- **Business Intelligence** (BI), "inteligencia de negocio": su objetivo básico es apoyar de forma **sostenible y continuada** a las organizaciones para mejorar su **competitividad**, facilitando la información para **tomar decisiones**.
- El término lo popularizó **Howard Dresner** (consultor de Gartner) como término paraguas para conceptos y métodos que mejoran la toma de decisiones usando información sobre lo que pasó (**hechos**).
- Idea central: convertir **datos → información → conocimiento**.
- **Definición de Gartner** (la que se toma como la más ajustada): BI es un **proceso interactivo** para **explorar** y **analizar información estructurada** sobre un **área** (normalmente almacenada en un ***datawarehouse***), para descubrir **tendencias o patrones**, derivar ideas y extraer conclusiones. Incluye **comunicar** los descubrimientos y **efectuar los cambios**. Las áreas incluyen clientes, proveedores, productos, servicios y competidores.

Parte de la definición	Qué significa
Proceso interactivo	Análisis **continuado en el tiempo**, no puntual: permite ver tendencias, cambios y variabilidad
Explorar	Primer acceso a la información para entender qué pasa y descubrir relaciones desconocidas
Analizar	Descubrir relaciones entre variables, tendencias y patrones (si un cliente actúa así, ¿otro parecido actuará igual?)
Información estructurada y *datawarehouse*	Tablas relacionadas, con registros y atributos, en un **almacén de datos**
Área de análisis	Todo proyecto de BI tiene un objeto concreto (clientes, productos) y un objetivo (bajar costos, subir ventas)
Comunicar y efectuar cambios	Lo descubierto tiene que llegar a quien hace los cambios

- **Definición del The Data Warehousing Institute (TDWI)**: término paraguas que abarca procesos, herramientas y tecnologías para convertir datos en información, información en conocimiento y planes para conducir los negocios. Incluye el ***back end*** (la "trastienda": *datawarehousing*) y el ***front end*** (el "mostrador": consultas, informes, análisis y visualización).

2.2 De los datos a las decisiones

- Los **datos** de las transacciones (qué se vendió, cuándo, quién, cómo se pagó) se convierten en **información operativa** (ventas del día, ticket medio, ventas por artículo), y esa información sirve para **decisiones**: **operativas** (reponer, asignar turnos) o **estratégicas** (qué hacer cuando bajan las ventas: ¿bajó la afluencia o lo que gasta cada cliente?).
- Con el tiempo aparecen **tendencias** y **relaciones entre productos**, que permiten promociones y mejor ubicación.

2.3 Quién lo necesita

- Compras (qué se vende y tendencias), ventas (ubicación según rotación), negociación con entidades financieras (flujos de efectivo y tarjetas), marketing (efectividad de promociones) y personal (turnos según afluencia). En

síntesis: **todo el que toma decisiones**; las decisiones pueden ser **operativas o estratégicas**.

2.4 Beneficios

Tipo	Ejemplos
Tangibles (generación de ingresos)	Segmentación de clientes, reducir el abandono, análisis de la cesta de la compra, medir campañas y ajustarlas, identificar clientes rentables
Tangibles (reducción de costos)	Negociar con proveedores, inventarios *just-in-time*, detectar fraude, reducir créditos incobrables, "una sola versión de la verdad"
Intangibles	Mejor atención y satisfacción del cliente, información más actualizada y precisa, mayor integración, ventaja competitiva
Estratégicos	Ayudan a formular la estrategia: a qué clientes, mercados o productos dirigirse; decisiones más rápidas, informadas y basadas en hechos

2.5 Componentes básicos

Componentes de todo proyecto de BI:

1. **Problemática empresarial** a responder.
2. **Equipo** (o persona) que hace el análisis.
3. **Información interna** de los sistemas de la organización.
4. **Información externa** a la organización (mercado, proveedores, tarifas).
5. Una **base de datos**: el *datawarehouse*.
6. Una **aplicación de BI** para trabajar, analizar y visualizar.

Nota técnica 1 — Sistemas de información: las organizaciones necesitan información para **soportar transacciones**, para **tomar decisiones y controlar** y para **nuevos negocios** (vender información). Los sistemas sirven para **controlar, coordinar y tomar decisiones** en la **planificación, la gestión y las operaciones**. Preguntas **estructuradas** (respuesta sí/no o un valor: ¿entregamos a tiempo?) frente a **no estructuradas** (¿lanzamos el producto Y en el mercado Z?). Un **ERP** (*Enterprise Resources Planning*, planificación de recursos empresariales) integra módulos con el concepto de **dato único**; si las aplicaciones no están integradas, se pasan datos con **interfases**.

2.6 Retorno de la inversión (ROI)

- **ROI simple = valor para el negocio / costo del proyecto**. El costo es fácil de medir; el valor es lo difícil.
- **Pasos de Bill Whittemore**: 1) definir el problema u oportunidad y objetivos **específicos, medibles, alcanzables, adecuados y con plazo**; 2) recoger requerimientos; 3) construir el proyecto; 4) identificar y cuantificar beneficios; 5) establecer el punto de partida de costos e ingresos; 6) calcular el **TCO** (*Total Cost of Ownership*, costo total de propiedad: *hardware*, *software*, consultoría, personal, lanzamiento, mantenimiento y formación); 7) calcular el **ROI = NPV / inversión inicial × 100**; 8) hacer seguimiento y corregir.
- **NPV** (*Net Present Value*, valor actual neto) = suma de los flujos de caja (CF, *Cash Flow*) de cada año descontados a la tasa r, menos la inversión inicial.

2.7 Modelización del negocio

- "Aquello que no se mide, no se puede gestionar". Primero se define **qué** medir y **cómo**: el **modelo de negocio** y sus métricas.

- **Modelo de negocio**: simplificación de la realidad que permite **documentar, probar y desarrollar teorías** sobre cómo funciona el negocio y **experimentar** cómo afectan los cambios al resultado. Debe estar **vivo** como el negocio.
- **Silos de información**: departamentos entre los que no fluye la información (por falta de integración o por razones políticas). Lo mejor para un departamento no siempre es lo mejor para la organización.
- **Cómo se crea**: con metodologías como **contabilidad analítica o de costos, EFQM** (*European Foundation for Quality Management*), **Six Sigma, análisis de procesos, modelos financieros, análisis de ratios**; identificando áreas críticas, factores que influyen en el resultado y la estructura organizativa.

2.8 Indicadores clave (KPI)

- **KPI** (*Key Performance Indicators*, indicadores clave de desempeño): sirven para **evaluar si la organización alcanza sus objetivos** y medir su progreso.
- Deben: **reflejar los objetivos**, ser **críticos para el éxito**, ser **cuantificables y comparables** y **permitir acciones correctivas**. Pocos, alineados entre departamentos, definidos con los responsables de cada área.
- Cada KPI tiene **nombre, definición, forma de cálculo y objetivo**.

2.9 Modelo de datos

- **Modelo relacional** (E. F. **Codd**, **1970**): tablas y relaciones. **PK** (*Primary Key*, clave primaria) identifica cada registro; **FK** (*Foreign Key*, clave externa) relaciona tablas. Se consulta con **SQL** (*Structured Query Language*; ver aviso 6). El **modelo entidad-relación** muestra las tablas y sus relaciones.
- Primero se define el modelo de negocio; después, qué se quiere **medir (hechos)** y **cómo (dimensiones)**. Las dimensiones responden **qué, quién, por qué, dónde y cuándo**.
- **Tabla de hechos** (*fact table*): lo que se mide (por ejemplo, el total del ticket) más las claves de las dimensiones. **Tablas de dimensiones**: el contexto para agrupar y filtrar (tiempo, centro, empleado, forma de pago). **Dimensiones degeneradas**: no necesitan tabla propia (número de ticket, identificador de caja).
- **Dimensión tiempo**: la fecha se descompone en día de la semana, del mes, del año, mes, trimestre, año, vacaciones y fin de semana. Esos datos (y los feriados) **no están** en el sistema transaccional: hay que agregarlos.

	Esquema estrella	Esquema copo de nieve (*snowflake*)
Dimensiones	**Una tabla por dimensión**, desnormalizada	Dimensiones **normalizadas**, con tablas relacionadas entre sí (Zona separada de Centro)
Relaciones	Solo hechos ↔ dimensiones	También dimensión ↔ dimensión
Redundancia	Sí (la descripción de zona se repite por centro)	No
A favor	Más simple y rápido de consultar	Menos espacio (a veces la diferencia es poca)
En contra	Ocupa más	Más complejo

- **Constelación de hechos** (o esquema **galaxia**): varias estrellas con distintas tablas de hechos que comparten dimensiones.
- **Granularidad**: nivel de detalle. Analizar **líneas** de ticket tiene **mayor** granularidad que analizar tickets. Cada nivel responde unas preguntas y no otras; **cada vez que se agrega, se pierde información**. Conviene construir al **máximo detalle** si el volumen lo permite.
- **Jerarquías**: año → trimestre → mes → día; familia → subfamilia → artículo; zona → centro; categoría → empleado. Permiten agregar y desagregar.
- **Multidimensionalidad**: analizar por **varias dimensiones a la vez** (ventas de un artículo por centro y por mes).
- Si fabricante y artículo están en la misma dimensión no se pueden cruzar: van en dimensiones distintas.

- **Metadata o diccionario de datos**: describe atributos, origen, definiciones y transformaciones para que todos usen la **misma terminología**.
- **Cada modelo de datos responde un número limitado de preguntas**, y cada modelo responde preguntas distintas.

2.10 Componentes de BI (capítulo 4 del libro)

Los componentes son: **fuentes de información → proceso ETL → *datawarehouse* (con su metadata) → motor OLAP → herramientas de visualización**. En un proyecto real el orden es otro: primero se definen los **objetivos, el alcance y los modelos de negocio**.

Fuentes de información

- **Sistemas operacionales o transaccionales**: aplicaciones a medida, ERP, CRM (gestión de la relación con clientes), SCM (gestión de la cadena de suministro).
- **Sistemas departamentales**: previsiones, presupuestos, hojas de cálculo.
- **Fuentes externas**, a veces compradas (estudios de mercado, datos de población).
- La información puede ser estructurada, semiestructurada o **no estructurada** (correos, cartas, informes, videos).

Calidad de datos

- Si hay errores en el *datawarehouse* se **propagan por toda la organización** y llevan a decisiones erróneas; los usuarios **desprestigian** el proyecto.
- Los errores vienen de los **sistemas transaccionales**, del **proceso ETL** o del propio ***datawarehouse***. Conviene **corregirlos en el origen** (que el usuario elija valores en vez de escribirlos libremente), no solo en el ETL.
- La calidad es un **problema de negocio, no solo de tecnología**.
- **7 características** de datos de calidad: **precisión, integridad, coherencia, totalidad, validez, disponibilidad y accesibilidad**.

Proceso ETL (*Extract, Transform, Load*, extracción, transformación y carga)

- Consume entre el **60 % y el 80 %** del tiempo de un proyecto de BI. Tiene **5 subprocesos**:

Subproceso	Qué hace
1. **Extracción**	Recupera los datos físicamente de las fuentes: datos **en bruto**. Manual (rutinas, por ejemplo en COBOL) o con herramientas ETL (la opción más rentable)
2. **Limpieza**	Comprueba la calidad, elimina duplicados, corrige errores y completa vacíos: datos **limpios**
3. **Transformación**	Estructura y **sumariza** según los modelos de análisis (cambios de formato, códigos, valores derivados y **agregados**); acá se ajusta la **granularidad**
4. **Integración**	Valida que los datos sean consistentes con las definiciones del *datawarehouse* y los carga (por ejemplo, que los totales de ventas coincidan con el origen)
5. **Actualización**	Define la **periodicidad** de las nuevas cargas

- **Almacén de datos intermedio** (*data staging*): paso entre la extracción y las etapas posteriores mientras se limpian los datos; acumula datos de varias fuentes. **Los usuarios finales nunca acceden**.
- **Datos "sucios"**: valores por defecto (código 999), ausencia de valor, valores crípticos o contradictorios, campos con varios usos, claves reutilizadas, identificadores no únicos.
- **Etapas de la limpieza**: **depurar** (*parsing*: separar nombre y apellido), **corregir** (*correcting*), **estandarizar** (*standardizing*), **relacionar** (*matching*: encontrar duplicados) y **consolidar** (*consolidating*: unir registros relacionados).

Datawarehouse (almacén de datos)

- Responde a la necesidad de información **consistente, integrada, histórica y preparada** para analizar. Usar hojas de cálculo en su lugar genera errores, trabajo repetido, "entornos paralelos" y **distintas versiones de la misma realidad**.
- **Hugh J. Watson**: "una colección de información creada para soportar las aplicaciones de toma de decisiones". ***Datawarehousing***: el proceso completo de extraer, transformar y cargar, más el acceso de los usuarios.
- **Bill Inmon** (4 características): **orientado a un área** (un problema de negocio), **integrado** (medidas, códigos y formatos comunes), **indexado en el tiempo** (guarda historia) y **no volátil** (no lo mantienen los usuarios; se actualiza periódicamente).
- **Ralph Kimball**: da acceso a la información, es consistente, se puede separar y combinar por cada medida, incluye las herramientas de consulta y es "el lugar donde publicamos la información".
- Guarda los datos para **maximizar flexibilidad, facilidad de acceso y administración**. Se actualiza en forma **mensual, semanal o diaria**; el concepto *right time* dice que cada situación de negocio requiere su propio plazo.

Data Mart y estrategias de construcción

- **Data Mart**: para una **comunidad de usuarios** (un departamento, un nivel o un grupo con objetivos comunes) y pocas áreas (por ejemplo, marketing y ventas). **Más chico** que el *datawarehouse*: menos datos, menos modelos y menos usuarios. Surgieron porque el *datawarehouse* corporativo era caro, lento e inflexible.
- **Dependiente**: se alimenta del *datawarehouse* corporativo. **Independiente**: se alimenta directo de las fuentes; puede perpetuar los **silos de información**.

	Inmon	Kimball
Estrategia	*Datawarehouse* **corporativo** primero y de él salen los Data Marts (de arriba hacia abajo)	Construir **Data Marts** por área, sin un *datawarehouse* central
A favor	Integrado y escalable	Barato y fácil de implementar; la más común
En contra	Caro, lento, propenso al fracaso	Riesgo de silos y de posponer la definición de criterios

Según Watson, **las dos son válidas** bien desarrolladas. También existen la **híbrida** y la **federada**.

- **Metadata**: repositorio central de "información de la información" (significado de cada tabla y atributo, origen, transformaciones). Obliga a que toda la organización use **la misma terminología** ("margen bruto" debe estar definido).
- **ODS** (*Operational Data Store*): consolida datos de varias fuentes para decisiones **operativas**; su información es **volátil**, se actualiza en **tiempo real** y tiene como máximo dos o tres meses. Suele alimentar al *datawarehouse*.

OLAP (*On-Line Analytical Processing*, procesamiento analítico en línea)

- Es la tecnología más extendida para analizar el *datawarehouse*: análisis **multidimensional** en distintos **niveles de agregación**, desde el máximo resumen hasta el máximo detalle.
- **FASMI** (resumen de las 12 reglas de Codd según el OLAP Council): ***Fast*** (rápido), ***Analysis*** (lógica de negocio y estadística), ***Shared*** (compartido y seguro), ***Multidimensional*** e ***Information*** (manejar toda la información).
- Se representa con **cubos**: cada celda guarda un **hecho** (por ejemplo, unidades vendidas de un libro a un cliente en un año).

Operación	Qué hace
Rotar (*slicing*)	Cambia el orden de las dimensiones (de clientes a libros)
Seleccionar (*dicing*)	Toma solo algunas celdas (cliente 2, libros 1 y 2, año 1)
Agregar (*roll-up*)	Sube al máximo nivel de agregación (total de libros)

Operación	Qué hace
Bajar al detalle (*drill-down*)	Baja por una jerarquía (por materias)

Tipo	Cómo accede	Ventaja / desventaja
ROLAP (relacional)	Directo a la base relacional, normalmente sobre un modelo estrella	Sin límite de tamaño / más lento
MOLAP (multidimensional)	A una base multidimensional	Muy rápido / si cambian las dimensiones hay que recargar el cubo
HOLAP (híbrido)	Datos agregados en la multidimensional y detalle en la relacional	Combina las ventajas de ambos
DOLAP (de escritorio)	Cubo cargado en la memoria de la computadora del usuario	El usuario recibe solo lo que le interesa

- Alternativa al OLAP: herramientas de **lógica asociativa** (por ejemplo QlikView), que guardan cada valor una sola vez y consultan sin dimensiones predefinidas.

Herramientas de BI: generadores de informes; herramientas de consultas e informes para el usuario final; herramientas OLAP; ***dashboards*** (indicadores operativos o tácticos de un área) y ***scorecards*** (nivel estratégico, indicadores relacionados, toda la organización, como el *Balanced Scorecard* de Kaplan y Norton); planificación y simulación; minería de datos; minería de texto; visualización y GIS (sistemas de información geográfica).

Usuarios (Eckerson y Howson)

- **Productores** de información (alrededor del **20 %**): estadísticos con minería de datos, autores de informes y usuarios avanzados.
- **Consumidores** (la mayoría): directivos, gestores, clientes y proveedores que usan cuadros de mando, informes interactivos y estandarizados, cada vez más vía web.
- Se diferencian **roles, no individuos**: el mismo ejecutivo puede usar un informe estático y un cuadro de mando en tiempo real. Por eso hay que conocer qué necesita cada rol antes de elegir la herramienta.

2.11 Guías del TP7 — respuestas

Pregunta	Respuesta modelo
¿Definición más ajustada de BI?	La de Gartner: proceso interactivo para explorar y analizar información estructurada (en un *datawarehouse*) y descubrir tendencias o patrones; convierte datos en información y conocimiento para decidir basándose en hechos
¿Momento adecuado para aplicar BI?	**De forma continua**, no puntual. Especialmente con mercados que cambian rápido, ante anomalías del negocio o cuando quienes generan información están desbordados
¿A qué organizaciones va dirigida?	A cualquiera que tome decisiones; urgente en estructuras complejas, con muchos clientes o que dependen de procesos "artesanales"
¿Qué beneficios aporta?	Tangibles, intangibles y estratégicos (ver 2.4)
¿Cómo unificar información de distintos entornos?	Reunirla en un *datawarehouse* (copia, sin afectar a los transaccionales), en tablas relacionadas, y cruzarla con herramientas de BI: "una sola versión de la verdad"
Concepto y utilidad del modelo de negocio	Simplificación de la realidad para documentar y probar teorías; sirve para experimentar el efecto de los cambios y evitar silos

Pregunta	Respuesta modelo
¿Qué es el modelo relacional?	Tablas y relaciones (Codd, 1970) con PK y FK, consultado con SQL
Factores del modelado de datos	Partir del modelo de negocio; definir hechos y dimensiones; ver qué datos hay en los transaccionales y cuáles agregar (calendarios, feriados)
Estrella frente a copo de nieve	Ver tabla 2.9
Granularidad y multidimensionalidad	Nivel de detalle (decide qué preguntas se responden) y análisis por varias dimensiones a la vez

3. Minería de datos (Tema 9)

3.1 Datos, información y conocimiento

- **Datos**: registros de observaciones o sucesos. **Información**: lo que se obtiene al detectar la utilidad de los datos. **Conocimiento**: reglas de cómo una cosa afecta a otra. "El conocimiento es poder".
- **Minería de datos** (*Data Mining*, DM): métodos y algoritmos para la **extracción automática** de información sintetizada que caracteriza **relaciones escondidas** en grandes volúmenes de datos, con capacidad **predictiva**. Reúne técnicas estadísticas y de **aprendizaje automático** (inteligencia artificial).
- **Analogía**: una montaña (los datos) con **diamantes** escondidos entre piedras (el conocimiento).
- Trabaja sobre **datos estáticos** (un estado pasado que no cambia mientras se analiza). **No confundir con monitoreo**, que trabaja con datos cambiantes en tiempo real y se dedica a reconocer patrones, no a descubrir.
- Apunte de clase: extracción de información o patrones **no triviales, implícitos, previamente desconocidos y potencialmente útiles**, por medios automatizados; objetivo, ayudar a decidir. Diferencia con BI según la clase: BI es más estático, saca conclusiones de datos estructurados que ya se tienen.

3.2 Proceso KDD

- **KDD** (*Knowledge Discovery in Databases*, descubrimiento de conocimiento en bases de datos): término usado desde **1989**. El descubrimiento es una **inducción no supervisada** con dos procesos: buscar regularidades interesantes y formular leyes que las describan.
- **Definición**: extracción **no trivial** de información **implícita**, **previamente desconocida** y **potencialmente útil** a partir de un conjunto de datos.
- **Cuatro ideas que diferencian al KDD**:

Idea	Qué exige
Lenguaje de alto nivel	Conocimiento **inteligible para un humano**. Por eso quedan fuera del KDD las representaciones de bajo nivel como las de las **redes neuronales**, aunque sean un método válido de minería
Precisión	Los datos tienen ruido; se mide el **grado de certidumbre**. Si la certeza es baja, el patrón no es conocimiento
Interés	Solo es conocimiento lo **nuevo, potencialmente útil y no trivial** según criterios del usuario
Eficiencia	Tiempo y memoria que crecen de forma **polinomial** con el tamaño de los datos

- Es la convergencia de aprendizaje automático, estadística, reconocimiento de patrones, inteligencia artificial, bases de datos, visualización, sistemas de apoyo a la decisión y recuperación de información.
- **KDD frente a minería de datos**: el **KDD es el proceso completo**; la **minería es solo la etapa de descubrimiento** dentro del KDD. Es la parte fundamental (la única que genera patrones) pero está **subordinada**.

Los 9 pasos del proceso KDD (interactivo e iterativo):

1. **Comprensión del dominio** y de los objetivos del usuario final.
2. **Creación del conjunto de datos objetivo** (selección de variables y ejemplos, muestreo).
3. **Preprocesado**: eliminar ruido, tratar valores ausentes, normalizar.
4. **Transformación y reducción**: características útiles, menos variables, proyección a espacios más simples. **Paso crítico**: marca el éxito o fracaso.
5. **Elección del tipo de sistema** de minería (clasificación, regresión, agrupamiento, detección de desviaciones).

6. **Elección del algoritmo**.
7. **Minería de datos**: búsqueda del conocimiento. Su éxito depende de los pasos previos.
8. **Interpretación** del conocimiento extraído, con posibilidad de volver al paso 1.
9. **Consolidación**: incorporar el conocimiento al sistema o documentarlo, resolviendo inconsistencias.

- **Fayyad** (según el artículo de la cátedra) resume el núcleo del KDD en **5 etapas**: **selección, preprocesamiento, transformación, minería de datos e interpretación/evaluación**. Antes va la comprensión del dominio y después la consolidación del conocimiento: así se llega a los 9 pasos.

Diagrama: **BD → Selección → Datos objetivo → Preprocesado → Datos preprocesados → Transformación → Datos transformados → Minería de datos → Patrones → Interpretación / Evaluación → Conocimiento**.

- **Por qué creció el análisis de datos** (tres factores): **potencia de las computadoras**, **ritmo de adquisición de datos** y **nuevos métodos** de aprendizaje.
- **Aprendizaje automático frente a minería**: el aprendizaje automático usa un conjunto **chico y seleccionado**; la minería parte de una base **grande** generada para **otros propósitos**.

3.3 Fases del KDD según la lectura (6 estados)

1. **Recolección de datos**: fuentes internas y externas, muchas transaccionales. Conviene una fuente **unificada, accesible y desconectada** del trabajo transaccional. Depende de la fuente (**OLAP** u **OLTP**, *On-Line Transaction Processing*; *datawarehouse* o copia; **ROLAP** o **MOLAP**) y del usuario: **picapedreros o granjeros** (informes periódicos, controlan valores) y **exploradores** (buscan patrones nuevos). Información externa: censos, datos de la industria, clima, calendarios, bases compradas.
2. **Selección, limpieza y transformación**: eliminar datos erróneos o inconsistentes (**limpieza**) e irrelevantes (**criba**), casi siempre con métodos estadísticos (histogramas, muestreo vertical u horizontal, redefinición de atributos).
3. **Minería de datos**: datos en disco, muy alta dimensionalidad, evidencia positiva, datos imperfectos. **Minería dirigida** (se sabe qué se busca: predecir) frente a **no dirigida** (no se sabe qué se busca).
4. **Evaluación y validación**: 1.ª fase, probar la precisión en un **banco de ejemplos independiente**; 2.ª fase, **experiencia piloto** (por ejemplo, un *mailing* a un grupo de clientes).
5. **Interpretación y difusión**: el modelo puede requerir implementación (fraude con tarjetas en tiempo real), interpretación (zonas geográficas) o difusión (cervezas y congelados se compran juntos → ponerlos en **estantes distantes**).
6. **Actualización y monitorización**: un modelo válido deja de serlo si cambia el contexto; hay que revalidarlo con datos nuevos.

3.4 Datos atípicos y faltantes

Acción	Atípicos (*outliers*)	Faltantes (*missing values*)
Ignorar	Algoritmos robustos (árboles)	Algoritmos robustos (árboles)
Filtrar la columna	Solución extrema; mejor reemplazarla por una columna "normal / atípico"	Solución extrema; mejor una columna booleana "existía / no existía"
Filtrar la fila	**Sesga los datos** (las causas suelen ser casos especiales)	**Sesga los datos**
Reemplazar el valor	Por nulo, máximo, mínimo o media; o predecirlo	Por la media; o predecirlo
Discretizar	Muy alto, alto, medio, bajo, muy bajo: el atípico cae en un extremo	—

Acción	Atípicos (*outliers*)	Faltantes (*missing values*)
Segmentar	—	Modelos distintos por segmento según los datos disponibles, luego se combinan
Esperar	—	Cambiar la política de calidad y esperar los datos

- **Razones de los faltantes**: pueden ser **relevantes** (no dar teléfono = no quiere ser molestado), **no existentes** (un cliente nuevo no tiene consumo de 12 meses) o **incompletos** (al unir fuentes distintas).

3.5 Evolución histórica

Etapa	Pregunta típica	Tecnología	Característica
Recolección (años 60)	Beneficios totales de los últimos 4 años	Computadoras, cintas, discos	Retrospectivo, datos estáticos
Acceso a los datos (años 80)	Ventas en Cataluña la última Navidad	Bases relacionales (SQL), ODBC	Retrospectivo, dinámico a nivel registro
Datawarehouse y apoyo a decisiones (años 90)	Ventas en Andalucía bajando hasta la tienda	OLAP, bases multidimensionales	Retrospectivo, múltiples niveles
Minería de datos	Tendencia de venta en Castilla el próximo año	Algoritmos avanzados, multiprocesadores	**Prospectivo, proactivo**

3.6 Qué no es minería de datos

No es estadística:

Eje	Minería de datos	Estadística clásica
Automatización	Construye el modelo **automáticamente**	La maneja un **estadístico profesional**
Enfoque	**Exploratorio**	**Confirmatorio** (prueba hipótesis)
Inteligencia artificial	La incorpora	Teoría de la probabilidad
Dimensionalidad	Mejor con **muchas variables**	Difícil encontrar hipótesis con muchas variables
Supuestos	**Menos restrictiva**	Los datos deben cumplir requisitos

Apunte de clase: la estadística toma **muestras** e infiere a la población; la minería trabaja con **toda la base** y usa estadística.

No es OLAP: OLAP **navega** rápido por los datos de forma asistida (análisis multidimensional) pero **no genera información nueva**. Arquitecturas: **MOLAP** (multidimensional; datos precompilados, para soluciones departamentales chicas) y **ROLAP** (relacional; traduce las consultas a SQL sobre el *datawarehouse*; más flexible).

3.7 Los tres retos

1. **Falsa interpretación**: es fácil engañarse con la estadística (los resultados valen para grupos, no individuos); con software de minería es aún más fácil "hacer creíble una falsedad".
2. **Correlación no es causalidad — Florida**: Florida tiene la edad promedio al fallecer más alta de Estados Unidos, pero no porque vivir allí alargue la vida: allí se jubilan y mudan los mayores (**efecto de selección**). La minería **genera**

hipótesis desde los datos (es **explorativa, no explicativa**): hay que validarlas con datos nuevos. Además no puede ser experimental.

3. **Tiempo, espacio y privacidad**: variables que cambian en el período, **granularidad del tiempo** (con datos mensuales no se predice por semana) y **privacidad** (combinar las bases del teléfono, el banco y el supermercado arma un perfil completo de una persona; el marco jurídico no acompañó).

3.8 Tareas de la minería de datos

Tarea	Qué hace	Paradigma
Agrupamiento (*clustering*)	Identifica categorías o grupos para describir los datos	No supervisado / descriptivo
Clasificación	Asigna un dato a una de varias **clases predefinidas**	Supervisado / predictivo
Condensación (descripción de conceptos)	Descripción **compacta** de un subconjunto	No supervisado / descriptivo
Detección de desviaciones	Cambios significativos respecto de valores pasados o normales	No supervisado / descriptivo
Modelado de dependencias	Dependencias entre variables, a nivel estructural y cuantitativo	No supervisado / descriptivo
Regresión	Predice un **valor real** (continuo)	Supervisado / predictivo

Proceso de minería (4 estados): **preprocesado** → **selección de características** (las variables más influyentes) → **algoritmo de extracción** (modelo de conocimiento) → **evaluación y validación**.

3.9 Predictivo frente a descriptivo

- **Predictivo (supervisado)**: predice una **etiqueta** conocida en datos históricos. Dos fases: **entrenamiento** (subconjunto con etiqueta) y **prueba** (el resto).
- **Descriptivo (no supervisado)**: descubre patrones en los datos actuales.
- **Taxonomía**: interpolación, predicción secuencial, aprendizaje supervisado, aprendizaje no supervisado y abducción. En lo supervisado: **clasificación** (clases disjuntas) frente a **categorización** (pueden solaparse); clase con dos valores = ***concept learning***; clase continua = **estimación**.
- **Reglas de asociación**: **confianza** = casos que cumplen antecedente y consecuente / casos que cumplen el antecedente; **soporte** = casos (o porcentaje) donde se aplica la regla. Algoritmos tipo **Apriori** en dos fases: **A**, buscar conjuntos frecuentes (*large itemsets*) con soporte suficiente; **B**, partirlos en reglas y quedarse con las de confianza suficiente. También hay asociaciones entre jerarquías, **negativas** ("80 % de quienes compran pizza congelada no compra lentejas") y con valores continuos (se discretizan).
- **Combinación de hipótesis**: ***boosting*** (el **mismo** algoritmo sobre distintas particiones) y ***voting*** (**distintos** algoritmos sobre todos los datos).

3.10 Métodos y técnicas

Métodos: agrupamiento (segmentación estática o dinámica), asociación, **secuenciamiento** (asociación donde el **tiempo** es clave), reconocimiento de patrones, **previsión** (*forecasting*, series temporales), simulación (por ejemplo CAD-CAM), optimización (maximizar beneficios o minimizar costos con restricciones) y clasificación (*scoring*).

Supervisados	No supervisados
Árboles de decisión	Detección de desviaciones
Inducción neuronal	Segmentación
Regresión	Agrupamiento (*clustering*)
Series temporales	Reglas de asociación
	Patrones secuenciales

Técnicas:

- **Estadísticas**: **ANOVA** (análisis de la varianza: diferencias de medias entre grupos), **Ji cuadrado** (independencia entre variables), **componentes principales** (reduce variables), análisis de **clusters**, **análisis discriminante** (clasifica en grupos ya definidos), **regresión lineal** (la más básica; variables continuas) y **logística** (admite discretas).
- **Árboles de decisión**: dividen los datos en subconjuntos; **CART** parte en **2** (validación cruzada, índice de Gini), **CHAID** (*Chi Squared Automatic Interaction Detector*) parte en **más de 2** (test Ji cuadrado).
- **Reglas de asociación**: "cesta de la compra", reglas SI ... ENTONCES.
- **Redes neuronales**: inspiradas en el cerebro (estudios desde 1930), capas de neuronas, aprenden patrones; supervisadas o no. Inconveniente: **no generan una ecuación que explique el modelo** (caja negra).
- **Algoritmos genéticos**: mutación y cruce para **optimizar**; se usan al principio para **elegir variables**.
- **Lógica difusa**: fronteras suaves entre grupos.
- **Series temporales**: ciclos, tendencias y estacionalidades para predecir, si no hay cambios estructurales.
- **Redes bayesianas**: aprenden dependencias y causalidad, combinan conocimiento con datos, evitan el sobreajuste, manejan datos incompletos.
- **Inducción de reglas** y **sistemas expertos** (con motor de inferencia).

3.11 Evaluación de la minería

- **Tres medidas clave** de una herramienta: **precisión**, **explicación** (que el usuario entienda cómo funciona) e **integración** (que se incruste en el proceso de negocio, sin copias de datos).

Medida de precisión	Qué es
Precisión	% de predicciones correctas
Tasa de error	Complemento de la precisión; útil con precisiones muy altas (pasar de 99 % a 99,5 % reduce el error a la mitad)
Tasa de error en rechazo	Se descartan las predicciones con poca confianza (rechazando 80 % se puede duplicar la precisión)
Error cuadrático medio	Para variables continuas; pesa más los errores grandes
Elevación (*lift*)	Cuánto mejora la respuesta respecto del azar: 30 % / 10 % = **3**
Beneficio / ROI	La mejor medida: cuánto gana el negocio

- **Explicación**: generación automática de reglas, OLAP integrado, evaluación automática del modelo. **Integración**: usar los datos como están, guardar el modelo como metadatos, preprocesar predictores, manejar datos sucios, valores perdidos y **escalabilidad**.

3.12 Apuntes de clase (14/9)

- **Aplicaciones**: retención de clientes, patrones de compra, detección de fraude, manejo del riesgo (a quién prestar), segmentación.
- **Ciclo de un proyecto** (9 pasos): aprender sobre el negocio, recolectar, limpiar y transformar, definir la meta y el modelo, elegir algoritmos, generar reportes, generar predicciones, aplicar los resultados, actualizar los modelos.
- **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*): proceso confiable y repetible para personas con pocos conocimientos; **6 fases**: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implantación.
- **Bodega de datos**: base orientada a consultas, **consolidada, consistente, orientada a un tema, histórica y de solo lectura**; es el punto de partida de la minería y no cambia mientras se mina.
- **Minería frente a análisis de datos**: el análisis no suele ser automatizado ni con tanto volumen. **Frente a aprendizaje automático**: es el área de la inteligencia artificial que hace programas que aprenden; la minería lo usa para predecir.

3.13 Preguntas teóricas del TP8 (respuestas del grupo)

Consigna	Respuesta clave
1. Cuadro de los 9 pasos con insumo y producto; impacto de fallar el preprocesado	Cada paso toma el producto del anterior. Si falla el **preprocesado**, el **modelo clasificador** aprende el ruido como patrón, los faltantes mal tratados sesgan la muestra y los atípicos distorsionan; la evaluación puede parecer buena si el banco de prueba tiene el mismo defecto. Invalida el modelo
2. Minería fundamental pero subordinada al KDD	"Minería sin KDD es una operación algorítmica **ciega**" (no sabe qué buscar, con qué calidad ni si lo hallado es válido); "KDD sin minería es un proceso **inconcluso**" (datos limpios sin patrones)
3. Minería frente a estadística; Florida	Ver 3.6 y 3.7
4. Minería frente a OLAP frente a monitoreo	Minería **genera** información nueva sobre datos **estáticos** con descubrimiento **proactivo**; OLAP **navega** de forma asistida sobre datos **históricos agregados** con consulta del usuario (*drill-down*, *roll-up*, *slice & dice*); monitoreo **verifica** datos en **tiempo real** de forma reactiva (alertas)
5. Mapa de tareas	Supervisado: clasificación y regresión. No supervisado: agrupamiento, dependencias, desviaciones y condensación
6. Redes neuronales y lenguaje de alto nivel	Predicen bien, pero el conocimiento queda en miles de **pesos numéricos**: es una **caja negra** que no se puede explicar; choca con la exigencia de conocimiento **inteligible** del KDD
7. Árbol de faltantes y atípicos con sesgo	Ver 3.4: filtrar filas **sesga**; la media **reduce la varianza**; discretizar **pierde precisión**; segmentar puede **sobreajustar**
8. Ensayo	Escalabilidad del *hardware* + granularidad del tiempo + privacidad: más detalle temporal y más fuentes cruzadas = perfiles más precisos de las personas. Marco legal: Ley 25.326 de Protección de Datos Personales (Argentina) y GDPR (Reglamento General de Protección de Datos, Unión Europea)
9. KDD, CRISP-DM y SEMMA	Ver tabla abajo

Eje	KDD	CRISP-DM	SEMMA
Origen	**Académico** (1989, Fayyad)	**Consorcio de empresas**: DaimlerChrysler, SPSS y NCR; ligado al *software* SPSS Clementine	**SAS Institute**; ligado al *software* SAS Enterprise Miner
Fases	9 (5 en el núcleo de Fayyad)	6, en una secuencia **no rígida**	5: *Sample, Explore, Modify, Model, Assess*; el muestreo es **opcional**
Iteración	Muy iterativo, vuelve desde cualquier fase	Ciclo con fuerte retroalimentación	Más secuencial, con ajustes técnicos
Orientación al negocio	Empieza por el dominio, foco en validez científica	**La más orientada al negocio**	Técnica; supone los objetivos ya definidos
¿Incluye negocio y despliegue?	Sí (antes y después del núcleo)	Sí, explícitamente	**No explícitamente**; según Azevedo y Santos queda implícito, porque no se puede muestrear sin entender el negocio

Mapeo de fases según el artículo de la cátedra (Azevedo y Santos, "KDD, SEMMA and CRISP-DM: a parallel overview"):

KDD	SEMMA	CRISP-DM
Antes del KDD (comprensión del dominio)	—	Comprensión del negocio
Selección	*Sample*	Comprensión de los datos
Preprocesamiento	*Explore*	Comprensión de los datos
Transformación	*Modify*	Preparación de los datos
Minería de datos	*Model*	Modelado
Interpretación / evaluación	*Assess*	Evaluación
Después del KDD (consolidación)	—	Despliegue

- **Conclusión del artículo**: SEMMA y CRISP-DM son **implementaciones del proceso KDD**. CRISP-DM parece más completo, pero SEMMA también incluye implícitamente el negocio y la consolidación.
- **Ojo:** el cuadro del TP8 del grupo puso "preparación de los datos" junto al preprocesado; según el artículo, el preprocesado corresponde a **comprensión de los datos** y la transformación a **preparación de los datos**.

4. Big Data (Tema 10, entra en el final)

4.1 Mapa conceptual

- **Definición**: ecosistema o paradigma para **capturar, almacenar y analizar** datos de **gran volumen, velocidad y variedad** que superan lo que manejan los sistemas tradicionales. Es la infraestructura base sobre la que se construyen el análisis y la estrategia (apunte de clase).
- **Las 3 V**: **volumen, velocidad, variedad**. La guía de PowerData advierte: **"Big" no es la clave**; el volumen es solo una parte del rompecabezas. Las empresas quieren saber no solo qué pasa, sino **qué va a pasar**, y lo más cerca posible del **tiempo real**.
- **Por qué importa**: impacta en la industria, el negocio y la sociedad y da **ventaja competitiva**. Hoy puede ser más valioso detectar al **cliente que más influye** sobre otros compradores que al que más compra.
- **Nace de nuevas necesidades del mercado**: **personalización máxima** del cliente, el paso **de la transacción a la interacción** y **nuevos dispositivos** (móviles, domótica, vehículos con sensores).
- **Requiere Big Analytics**: análisis **predictivo** y **clusterización** de clientes; trabaja con **datos en crudo, al mayor detalle**; lo operan el **Data Scientist** y el **Data Analyst**; evoluciona desde el **BI tradicional y el Data Warehouse**, cuyas limitaciones son **modelos rígidos, poco ágiles y sin tiempo real**; se integra con el **Analytic Data Warehouse (ADW)**, que puede convivir con el tradicional en un **modelo híbrido DWH + ADW**.
- **Metodología MAD**: **Magnética** (capta todo tipo de datos), **Ágil** (ingiere y se adapta rápido) y **Detallada** (análisis estadístico fino).
- **Origen de Hadoop**: nace cuando **Google** no puede indexar la web al ritmo que exige el mercado y aplica "divide y vencerás": muchas computadoras pequeñas que procesan cada una una porción pero actúan como una sola. En **2006** la comunidad de **código abierto** desarrolla Hadoop; luego **Yahoo** lo impulsa y lo adoptan empresas como **Facebook**. Permite, por ejemplo, una regresión lineal sobre millones de registros del histórico con un **ROI muy rápido**.
- **Tecnología: Hadoop**: **HDFS** (*Hadoop Distributed File System*, archivos distribuidos), **MapReduce** (procesamiento paralelo), **código abierto** y ***commodity hardware*** (equipos comunes y baratos).
- **4 megatendencias**: **Movilidad, Cloud, Social Media, Analytics**.
- **Tiempo real**: ***Data Stream*** (analiza datos en movimiento) y **CEP** (*Complex Event Processing*, procesamiento de eventos complejos: detecta eventos predefinidos, como operaciones sospechosas con tarjetas).
- **Megatendencias en detalle**: **Movilidad** (acceso a los datos desde cualquier lugar y desde dispositivos que no son de la empresa, lo que dificulta el control); **Cloud** (no hace falta comprar la infraestructura: baja la inversión inicial y se puede **prever el costo del crecimiento**); **Social Media** (gustos y preferencias para captar y fidelizar); **Analytics** (análisis de cualquier tipo de dato, sin patrones de búsqueda prefijados).
- **Big Analytics frente al BI tradicional**: el BI tradicional cargaba modelos tan lento que al terminar ya no servían; Analytics trabaja con los datos **en crudo, al nivel de granularidad más bajo**, con modelos más ágiles. El **Analytic Data Warehouse no reemplaza** al *data warehouse* actual: cada uno cubre necesidades distintas y conviven en un **modelo híbrido**. Aparece el perfil de **Data Science**.
- **CEP, ejemplos de la guía**: un banco que analiza en tiempo real lo que pasa con las **tarjetas de crédito** en cajeros y comercios; **sensores de maquinaria** que envían una alerta antes de que aparezca un fallo.
- **Implementación**: primero **conocer y cuantificar el valor** que puede dar al negocio (autoevaluación de límites, expectativas y restricciones); elegir la tecnología según las metas (para eventos en tiempo real, **CEP**; para análisis predictivo, bases con procesamiento **MPP**); perfiles de negocio que conozcan el sector (Data Scientist, Data Analyst); y herramientas según el tipo de análisis.
- **Privacidad**: en Google "no todo es gratis", el precio es la privacidad; las empresas deben equilibrar los datos que analizan con la **tolerancia** de sus clientes.

- **Implementación (mapa del TP)**: **medir el valor para el negocio**, **las metas determinan la tecnología** (no al revés) y perfiles de negocio con herramientas adecuadas.
- **Genera** innovación y ventaja competitiva; **plantea** el desafío de **seguridad y privacidad**: equilibrio entre los datos analizados y lo que el cliente tolera.
- Bases **MPP** (*Massively Parallel Processing*, procesamiento masivamente paralelo) para el análisis predictivo sobre todo el histórico.

4.2 BI, minería de datos y Big Data

Aspecto	BI	Minería de datos	Big Data
Qué es	Procesos y herramientas que convierten datos en información para decidir	Descubrir patrones, relaciones y tendencias ocultas	Paradigma para capturar, almacenar y analizar datos masivos
Pregunta central	¿Qué pasó y cómo vamos?	¿Qué patrones hay en los datos?	¿Qué va a pasar y qué descubrimos con todos los datos?
Enfoque temporal	Pasado y presente	Pasado, para descubrir y predecir	Presente y futuro, en tiempo real
Tipo de datos	Estructurados, internos	Estructurados y semiestructurados, ya preparados	Estructurados, semiestructurados y **no estructurados** (redes, sensores, logs)
Volumen	Moderado (lo que soporta un *datawarehouse*)	De moderado a grande	**Masivo**, infraestructura distribuida
Técnicas	Consultas, reportes, tableros, OLAP, KPI	Clasificación, agrupamiento, asociación, regresión, anomalías	Big Analytics, MapReduce, Data Stream, CEP
Tecnología	*Datawarehouse*, ETL, *reporting*	Algoritmos estadísticos y de aprendizaje automático	Hadoop, ADW, *cloud*, bases MPP
Perfil	Gerentes y analistas de negocio	Analistas de datos, estadísticos	Data Scientist, Data Analyst
Resultado	Informes y tableros	Modelos y patrones	Conocimiento nuevo y servicios personalizados casi en tiempo real
Limitación	Poco ágil, sin tiempo real	Depende de la calidad de los datos	Infraestructura nueva, perfiles caros, privacidad

Matriz de la clase ("Ingeniería de datos"):

	Big Data	Minería de datos	BI
Fin principal	Almacenar y procesar a escala masiva	**Descubrir patrones**	**Optimizar decisiones** corporativas
Tipo de datos	**Crudos** y variados	**Consolidados**	**Estructurados y depurados**
Perfil	**Ingeniero de datos**	**Científico de datos**	**Analista de BI** o consultor
Foco temporal	**Presente continuo**	**Futuro predictivo**	**Pasado y presente** descriptivo

- **Cadena de la clase**: de los datos de **Big Data** se aplica **minería de datos**, y con lo extraído se hace **BI**.
- **No son excluyentes**: conviven en un **modelo híbrido**. BI mira hacia atrás; Big Data apunta hacia adelante; la minería es una herramienta que se aplica tanto sobre un *datawarehouse* como sobre Big Data.

- El TP pone el foco temporal de la minería en el "pasado" y la clase en el "futuro predictivo": si preguntan, la minería **analiza datos pasados para predecir el futuro**.

5. Repaso final

5.1 Mapa de relaciones entre los temas

- **Redes de Petri** modelan el **comportamiento** de un sistema concurrente (procesos, estados, recursos): es **diseño**.
- **BI, minería y Big Data** tratan los **datos** que esos sistemas generan para **decidir**: Big Data captura y procesa → la minería descubre patrones → BI los convierte en indicadores y decisiones.
- **Puntos de contacto**: el *datawarehouse* (BI) es el punto de partida de la minería; OLAP aparece en BI y en minería (que no es OLAP); la granularidad aparece en el modelo de datos de BI y en el tercer reto de la minería; la privacidad aparece en minería y en Big Data.

5.2 Trucos para memorizar

- **"Lu-Tra-Ar-Ma"**: elementos de una Red de Petri: **Lu**gares (círculos), **Tra**nsiciones (barras), **Ar**cos, **Ma**rcas.
- **"Más menos menos"**: $C = C^+ - C^-$ (posterior **menos** previa) y $M' = M - Pre + Post$.
- **Árbol finito: "Mu-Du-W"**: se corta en marcados **Mu**ertos, **Du**plicados o con **W** (infinito).
- **"VACCa"**: propiedades de comportamiento: **V**ivacidad, **A**cotamiento, **C**iclicidad, **C**onservación, **a**lcanzabilidad.
- **"Pi-E-A-Info-Á-Co"**: definición de Gartner: **P**roceso **i**nteractivo, **E**xplorar, **A**nalizar, **Info**rmación estructurada, **Á**rea, **Co**municar y cambiar.
- **"Tan-In-Es"**: beneficios de BI: **Tan**gibles, **In**tangibles, **Es**tratégicos.
- **"Re-Crí-Cuan-Co"**: requisitos de un KPI: **Re**flejar objetivos, **Crí**ticos, **Cuan**tificables y comparables, **Co**rrectivos.
- **"Qué-Quién-Por qué-Dónde-Cuándo"**: las dimensiones.
- **"Le-Pre-In-E"**: ideas del KDD: **Le**nguaje de alto nivel, **Pre**cisión, **In**terés, **E**ficiencia.
- **"Do-Ob-Pre-Trans | Sis-AI-Mi | In-Con"**: los 9 pasos del KDD en tres bloques (preparar, minar, aprovechar).
- **SEMMA se deletrea**: **S**ample, **E**xplore, **M**odify, **M**odel, **A**ssess.
- **"MAD = Ma-Ág-De"**: **Ma**gnética, **Ág**il, **De**tallada.
- **3 V**: **V**olumen, **V**elocidad, **V**ariedad. **4 megatendencias "MoCSA"**: **Mo**vilidad, **C**loud, **S**ocial Media, **A**nalytics.

5.3 Errores frecuentes en el examen

- ✘ "Una red viva siempre es cíclica." ✔ Son propiedades independientes: una red puede ser viva sin volver nunca a M0.
- ✘ "Red segura = red que no se bloquea." ✔ Segura = **1-acotada**; que no se bloquee es **vivacidad**.
- ✘ "$C = C^- - C^+$." ✔ **$C = C^+ - C^-$**.
- ✘ "Un arco puede unir dos lugares." ✔ Siempre une **lugar y transición** (grafo bipartito).
- ✘ "En la matriz de incidencia, filas = lugares." ✔ Según la lectura, **filas = transiciones, columnas = lugares**.
- ✘ "BI es un análisis que se hace una vez." ✔ Es un **proceso continuo** (interactivo).
- ✘ "El esquema estrella está normalizado." ✔ La estrella es **desnormalizada**; el **copo de nieve** está normalizado.
- ✘ "Mayor granularidad = menos detalle." ✔ **Mayor granularidad = más detalle** (líneas de ticket > tickets).
- ✘ "Un Data Mart es más grande que un *datawarehouse*." ✔ Es **más chico** y para una comunidad de usuarios.
- ✘ "KDD y minería de datos son lo mismo." ✔ La minería es **una etapa** del KDD.
- ✘ "OLAP descubre patrones nuevos." ✔ OLAP **navega**; la minería **descubre**.
- ✘ "Si dos variables están correlacionadas, una causa la otra." ✔ **Correlación no es causalidad** (Florida).

- ✘ "Filtrar las filas con faltantes no tiene costo." ✔ **Sesga** los datos.
- ✘ "La regresión es una tarea descriptiva." ✔ Es **predictiva / supervisada** (predice un valor real).
- ✘ "Las redes neuronales cumplen con el lenguaje de alto nivel del KDD." ✔ Son una **caja negra**: quedan fuera de ese criterio aunque sean un método válido.
- ✘ "Big Data reemplaza al *datawarehouse*." ✔ Pueden **convivir** (modelo híbrido DWH + ADW).
- ✘ "SEMMA incluye la comprensión del negocio." ✔ SEMMA **la supone resuelta**; CRISP-DM es la más orientada al negocio.

5.4 Preguntas integradoras con respuesta modelo

1. **¿Por qué la minería de datos depende del *datawarehouse* de BI?** — Porque la minería necesita datos **consolidados, limpios e históricos**, desconectados de los sistemas transaccionales, y eso es lo que provee el **datawarehouse** cargado con **ETL**. La lectura de minería indica que el análisis es mucho más sencillo si la fuente es unificada, accesible y desconectada del trabajo transaccional. Por eso el *datawarehouse* es "el punto de partida" de la minería.
2. **Compará OLAP, minería de datos y Big Data.** — **OLAP** navega de forma asistida por datos históricos agregados en varias dimensiones, **sin generar información nueva**. La **minería** descubre de forma **automática** patrones nuevos y predice. **Big Data** es el **contexto** de datos masivos, veloces y variados (incluso no estructurados) que exige infraestructura distribuida (**Hadoop**) y análisis en tiempo real (**CEP**, **Data Stream**).
3. **¿Qué tienen en común la granularidad de un modelo estrella y el tercer reto de la minería?** — En los dos casos, el **nivel de detalle** decide qué preguntas se pueden responder. En BI, analizar tickets no permite analizar productos; en minería, con datos mensuales no se puede predecir por semana. **Cada vez que se agrega se pierde información**.

5.5 Autopreguntas

- ¿Qué es un nodo frontera y cuáles son los tres tipos?
- Dada una red, ¿podés armar C^-, C^+ y C sin mirar, con filas = transiciones?
- ¿Cuándo se escribe ω en el árbol y qué propiedad indica?
- ¿Cómo se pasa del árbol de alcanzabilidad a la máquina de testigos?
- ¿Por qué $M' = M + f(\sigma)\cdot C$ no alcanza para asegurar que una secuencia se puede disparar?
- ¿Cómo se reconoce en el grafo de marcados que una red es cíclica?
- ¿Qué diferencia hay entre una red viva, parcialmente viva y no viva?
- ¿Cuáles son los 6 componentes de un proyecto de BI?
- ¿Qué es una dimensión degenerada? Dame dos ejemplos.
- ¿Por qué el fabricante va en una dimensión distinta del artículo?
- ¿Cuáles son los 9 pasos del KDD y cuál es el crítico?
- ¿Qué hace un "picapedrero" y qué hace un "explorador"?
- ¿Qué es la elevación (*lift*) y cómo se calcula?
- ¿Qué es la metodología MAD y qué significa cada letra?
- ¿Qué diferencia hay entre Data Stream y CEP?

Glosario de siglas y abreviaturas

Redes de Petri

Sigla	Desarrollo	Original
RdP	Red de Petri	—
M0	Marcado inicial	—
C^-	Matriz de incidencia previa	—
C^+	Matriz de incidencia posterior	—
MT	Máquina de testigos	—
GE	Grafo de estados	—
ME	Máquina de estados	—
GM	Grafo marcado	—
RLE	Red de libre elección	—
RS	Red simple	—
DFD	Diagrama de flujo de datos	—

Business Intelligence

Sigla	Desarrollo	Original
BI	Inteligencia de negocio	*Business Intelligence*
KPI	Indicador clave de desempeño	*Key Performance Indicator*
ROI	Retorno de la inversión	*Return on Investment*
NPV	Valor actual neto	*Net Present Value*
TCO	Costo total de propiedad	*Total Cost of Ownership*
CF	Flujo de caja	*Cash Flow*
ETL	Extracción, transformación y carga	*Extract, Transform, Load*
OLAP	Procesamiento analítico en línea	*On-Line Analytical Processing*
OLTP	Procesamiento de transacciones en línea	*On-Line Transaction Processing*
MOLAP	OLAP multidimensional	*Multidimensional OLAP*
ROLAP	OLAP relacional	*Relational OLAP*
HOLAP	OLAP híbrido	*Hybrid OLAP*
DOLAP	OLAP de escritorio	*Desktop OLAP*

Sigla	Desarrollo	Original
FASMI	Rápido, análisis, compartido, multidimensional, información	*Fast, Analysis, Shared, Multidimensional, Information*
ODS	Almacén de datos operacional	*Operational Data Store*
CRM	Gestión de la relación con clientes	*Customer Relationship Management*
SCM	Gestión de la cadena de suministro	*Supply Chain Management*
GIS	Sistemas de información geográfica	*Geographic Information Systems*
DWH	Almacén de datos	*Data Warehouse*
ERP	Planificación de recursos empresariales	*Enterprise Resources Planning*
PK	Clave primaria	*Primary Key*
FK	Clave externa	*Foreign Key*
SQL	Lenguaje de consulta estructurado	*Structured Query Language*
ODBC	Conectividad abierta de bases de datos	*Open Database Connectivity*
DAX	Expresiones de análisis de datos	*Data Analysis Expressions*
IDC	International Data Corporation, consultora	—
TDWI	The Data Warehousing Institute	—
EFQM	Fundación Europea para la Gestión de la Calidad	*European Foundation for Quality Management*

Minería de datos

Sigla	Desarrollo	Original
DM	Minería de datos	*Data Mining*
KDD	Descubrimiento de conocimiento en bases de datos	*Knowledge Discovery in Databases*
CRISP-DM	Proceso estándar intersectorial para minería de datos	*Cross-Industry Standard Process for Data Mining*
SEMMA	Muestrear, Explorar, Modificar, Modelar, Evaluar	*Sample, Explore, Modify, Model, Assess*
ML	Aprendizaje automático	*Machine Learning*
IA	Inteligencia artificial	—
ANOVA	Análisis de la varianza	*Analysis of Variance*
CART	Árboles de clasificación y regresión	*Classification And Regression Trees*
CHAID	Detector automático de interacciones por Ji cuadrado	*Chi Squared Automatic Interaction Detector*
k-NN	k vecinos más cercanos	*k Nearest Neighbors*
IQR	Rango intercuartílico	*Interquartile Range*
PII	Información de identificación personal	*Personally Identifiable Information*

Sigla	Desarrollo	Original
GDPR	Reglamento General de Protección de Datos, de la Unión Europea	*General Data Protection Regulation*
CAD-CAM	Diseño y fabricación asistidos por computadora	*Computer-Aided Design / Manufacturing*

Big Data

Sigla	Desarrollo	Original
ADW	Almacén de datos analítico	*Analytic Data Warehouse*
MAD	Magnética, Ágil, Detallada	—
HDFS	Sistema de archivos distribuido de Hadoop	*Hadoop Distributed File System*
CEP	Procesamiento de eventos complejos	*Complex Event Processing*
MPP	Procesamiento masivamente paralelo	*Massively Parallel Processing*

Otras siglas y reglas para recordar

Sigla	Desarrollo	Original
TP	Trabajo Práctico	—
N°	Número	—
Lu-Tra-Ar-Ma	Elementos de una Red de Petri: Lugares, Transiciones, Arcos, Marcas	—
Mu-Du-W	Dónde se corta el árbol de alcanzabilidad: Muertos, Duplicados, con W	—
VACCa	Propiedades de comportamiento: Vivacidad, Acotamiento, Ciclicidad, Conservación, alcanzabilidad	—
Tan-In-Es	Beneficios de BI: Tangibles, Intangibles, Estratégicos	—
Re-Crí-Cuan-Co	Requisitos de un KPI: Reflejar objetivos, Críticos, Cuantificables, Correctivos	—
Le-Pre-In-E	Ideas del KDD: Lenguaje de alto nivel, Precisión, Interés, Eficiencia	—
MoCSA	Megatendencias del Big Data: Movilidad, Cloud, Social Media, Analytics	—

Cómo se armó

- **Material de la cátedra leído y cotejado** (carpeta *Análisis y Diseño de Sistemas II - 2026*): "Redes_de_petri" y "Formalización Redes de Petri" (presentaciones); "Introducción al BI", "BI_modelos", "Componentes de BI" y "experiencias BI_detalle" (libro *Business Intelligence: competir con información*); "NotasMD" (lectura de minería de Beatriz Beltrán Martínez, la misma que usó el grupo), "KDD-CRISP-SEMMA" (Azevedo y Santos) y "Data Mining: el arte de anticipar" (Palma y otros, 10 casos reales; no se volcó al resumen porque no aparece en los TP); "PowerData - Del bit… al Big Data".

- **Material del grupo**: TP6 a TP9 resueltos, guías de BI, caso CoffeeTime y su planilla, TP integrador de fútbol, apuntes de clase ("Redes Petri - Análisis y Diseño II", "Apuntes 14/9", "Ingeniería de datos") y el mapa conceptual de Big Data.
- **Verificado por computadora**: matrices, árboles de alcanzabilidad, máquinas de testigos, secuencias y propiedades de los tres ejemplos resueltos de Redes de Petri.
- **Recorte por alcance** (aclaración de la docente): se sacaron el TP6 de modelado (7 tareas y demás ejercicios), el caso CoffeeTime, el TP integrador de fútbol, la aplicación en comercio minorista y el caso de abandono de compra.
- **Cotejo con la cátedra**: se quitaron las marcas ⚠ de la forma matricial de Petri, de los componentes de BI y de toda la unidad de Big Data. Se agregaron historia, subclases, máquina de testigos y métodos de análisis de Petri; calidad de datos, subprocesos de ETL, Inmon y Kimball, ODS y operaciones OLAP; el mapeo oficial de KDD, SEMMA y CRISP-DM; y detalles de la guía de PowerData.
- **Depuración (30/10)**: Big Data pasa al final. Se sacaron los ejemplos y casos puntuales (supermercado, paquetería, Wal-Mart, ROI del libro, K-means de empleados, Play Tennis, experiencias de BI) y los datos sueltos de estudios o encuestas (IDC, TDWI, Watson, Gartner 2005, hospitales). Se conservaron los ejemplos resueltos de Redes de Petri, porque esa práctica entra en el parcial.
- **Descartado**: del apunte de Redes de Petri, "una red viva es cíclica". Del cuadro del TP8, la correspondencia entre preprocesado y preparación de los datos (ver 3.13). De la lectura de BI, los desarrollos "Standard Query Language" y "Object Data Base Connector".
- **No disponible**: contenido de los videos de los temas 8 y 10.