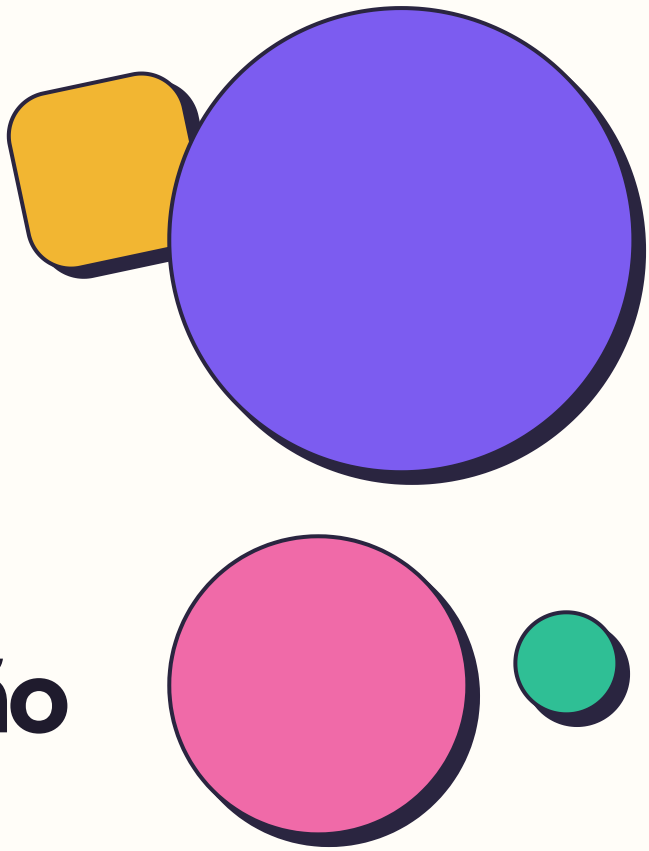
Tecnicatura en Análisis y Desarrollo de Software ·
Instituto de Profesorado Sedes Sapientiae



Análisis y Diseño de Sistemas II

Resumen visual · 2do parcial

Redes de Petri, *Business Intelligence* y Minería de datos para el parcial. Big Data (tema 10) queda como material para el final. Solo la teoría, salvo en Redes de Petri, donde también entran el árbol de alcanzabilidad, las propiedades, la máquina de testigos y el método matricial.

6 y 7 · Redes de Petri
Lugares, transiciones, marcas, árbol de alcanzabilidad, matrices y propiedades

8 · Business Intelligence
Definición, beneficios, ROI, KPI, modelo de datos, ETL, *datawarehouse* y OLAP

9 · Minería de datos
KDD, tareas, técnicas, evaluación, CRISP-DM y SEMMA

10 · Big Data (final)
3 V, Big Analytics, MAD, Hadoop, megatendencias y comparación con BI y minería

Grupo: Valentín Figún, Matías Morales y Paula Rocío Haunau · Docente: María Silvina Scarpin · Octubre 2026

Antes de empezar

Qué entra

Tema	Qué estudiar
Temas 6 y 7 — Redes de Petri	Teoría **+ práctica**: árbol de alcanzabilidad, propiedades, máquina de testigos y método matricial
Tema 8 — Business Intelligence (BI)	Solo teoría
Tema 9 — Minería de datos y KDD	Solo teoría
Tema 10 — Big Data	Solo teoría. **Entra en el final, no en el 2do parcial**

Big Data (tema 10) entra en el final. Queda en el resumen como material para el final.

No entra: la práctica de los TP (caso CoffeeTime, TP integrador de fútbol, comercio minorista, abandono de compra, las 7 tareas de modelado del TP6). Tampoco hay ejemplos puntuales, casos de empresas ni datos sueltos de un autor o de un estudio; los ejemplos resueltos de Redes de Petri sí quedan, porque esa práctica entra.

Cómo leer las marcas

- ▤ = sale del material de la cátedra, de los TP o de los apuntes de clase.
- ! = no verificado con el material de la cátedra.
- ✓ / ✗ = correcto / incorrecto.
- → = explicación en criollo.

Trampas que ya están corregidas

1. El apunte de clase dice **"una red viva es cíclica"**. **Está mal**: vivacidad y ciclicidad son cosas distintas.
2. El cuadro **KDD / SEMMA / CRISP-DM** del TP8 tenía un error. Se corrigió con el artículo de la cátedra (Azevedo y Santos). Ver 3.13.
3. Los **videos** de los temas 8 y 10 no se pudieron revisar. La guía de PowerData sí.
4. El libro de BI escribe "Standard Query Language" (SQL) y "Object Data Base Connector" (ODBC). Lo habitual es **Structured Query Language** y **Open Database Connectivity**. Usá estos; si te preguntan, sabé que el libro los escribe distinto.

0 Datos para memorizar

Dato	Valor
Creador de las Redes de Petri	**Carl Adam Petri** (alemán), tesis de **1962**: *Kommunikation mit Automaten*
Holt y Commoner	**1970**, "Events and Conditions": usan las RdP para sistemas concurrentes
Estructura de una Red de Petri	**C = (P, T, I, O)**: lugares, transiciones, función de entrada, función de salida
Red marcada	**M = (C, μ)**
Matriz de incidencia	**$C = C^+ - C^-$** (posterior menos previa). Filas = transiciones, columnas = lugares
Ecuación de disparo	**$M'(p) = M(p) - Pre(p, t) + Post(t, p)$**
Red segura	**1-acotada** (binaria): ningún lugar tiene más de 1 marca
Ecuación de estado	**$M' = M + f(\sigma)\cdot C$** ($f(\sigma)$ = cuántas veces se dispara cada transición)
Transición habilitada (método matricial)	**$M \geq e_j \cdot C^-$**
ω en el árbol	La red **no es acotada**
Subclases de RdP	**4**: grafo de estados (máquina de estados), grafo marcado, red de libre elección, red simple
Primero en usar "Business Intelligence"	**Howard Dresner** (Gartner)
BI según Gartner	Proceso **interactivo** para **explorar** y **analizar** información **estructurada** de un **área**, normalmente en un *datawarehouse*
ROI simple	Valor para el negocio / costo del proyecto
ROI completo	**NPV / inversión inicial × 100**
Proceso ETL	**60 % a 80 %** del tiempo de un proyecto de BI; **5 subprocesos**
***Datawarehouse* según Inmon**	Orientado a un área, integrado, indexado en el tiempo, no volátil
FASMI (OLAP)	*Fast, Analysis, Shared, Multidimensional, Information*
Modelo relacional	**E. F. Codd, 1970**
Las dimensiones responden	¿Qué? ¿Quién? ¿Por qué? ¿Dónde? ¿Cuándo?
Término KDD	Desde **1989**
Pasos del proceso KDD	**9**
Fases del KDD según la lectura	**6**
CRISP-DM	**6 fases**; DaimlerChrysler, SPSS y NCR
SEMMA	**5 fases**: *Sample, Explore, Modify, Model, Assess*; SAS Institute
KDD según Fayyad	**5 etapas**: selección, preprocesamiento, transformación, minería, interpretación/evaluación
Big Data (final)	**3 V**: volumen, velocidad, variedad
Metodología MAD	Magnética, Ágil, Detallada
Megatendencias del Big Data	**4**: Movilidad, Cloud, Social Media, Analytics
Hadoop	**HDFS** + **MapReduce**; código abierto desde **2006**, nace de Google

1 Redes de Petri (Temas 6 y 7)

En una frase: una Red de Petri es un **dibujo con reglas matemáticas** que muestra cómo funciona un sistema donde **pasan varias cosas a la vez**.

1.1 Qué son y para qué sirven

- Las creó **Carl Adam Petri** en su tesis de **1962**, *Kommunikation mit Automaten* ("Comunicación con autómatas"), en Alemania. Trataba de cómo se comunican partes **asíncronas** (que no van al mismo ritmo). El proyecto "Systemics" aportó la notación.
- En **1970**, **Holt y Commoner** ("Events and Conditions") las usan para sistemas con partes **concurrentes**.
- Sirven para modelar cuatro cosas típicas de los sistemas distribuidos:
  - **Concurrencia**: cosas que pasan a la vez.
  - **Sincronización**: esperar a que otro termine.
  - **Exclusión mutua**: de a uno por vez.
  - **Conflictos**: hay que elegir entre dos.
- **Su antecedente son las máquinas de estado** (estado + transición, con entradas y salidas *a/b*). Problema: no sirven bien para **acciones simultáneas**. Si juntás varias, los estados se multiplican y el diagrama no se entiende.
- → Las Redes de Petri (RdP) resuelven eso porque tienen **paralelismo inherente**: la concurrencia ya viene "de fábrica".
- Al analizar la red ves dos cosas: su **estructura** (cómo está armada) y su **comportamiento dinámico** (cómo se mueve). Con eso evaluás el sistema y proponés mejoras.
- **Definición de la cátedra**: representaciones gráficas que modelan sistemas con flujo de información y muestran su estructura y su comportamiento dinámico. Se pueden ver como **generadores de lenguaje o autómatas formales** (teoría de grafos). Sirven para diseñar, especificar y simular *hardware* o *software*.
- **Tres ventajas de modelar con RdP** (presentación "Formalización"):
  1. Se **entienden fácil**: son gráficas y precisas.
  2. Se pueden **analizar con teoría** (árboles de marcados, relación entre estructura y comportamiento).
  3. Se arman *bottom-up* o *top-down*: así diseñás sistemas cuyo comportamiento conocés o podés verificar.
- **Extensiones**: cambios en la estructura (más potencia o comodidad) y **redes de Petri temporizadas** (para medir tiempos y prestaciones).
- **En programación concurrente**: transición = proceso; lugar = condición para que el proceso corra; marca = la condición se cumple.
- Apunte de clase: sirven para ver cómo funciona un sistema, qué procesos tiene y por qué estados pasa. Se usan como **autómatas**. Cualquier proceso se puede dibujar con una RdP.

1.2 Elementos y representación gráfica

Elemento	Dibujo	Qué representa
Lugar o plaza	Círculo	Condición o estado ("cómo está")
Transición	Barra	Evento o suceso ("qué pasa")
Arco dirigido	Flecha con peso (sin número = pesa 1)	Une lugar → transición (lugar de entrada) o transición → lugar (lugar de salida). **Nunca** lugar con lugar ni transición con transición
Marca, testigo o *token*	Punto negro dentro del lugar	La condición se cumple. Un lugar con marcas está **activo**

- La red es un **multígrafo dirigido bipartito**:
  - **Multígrafo**: puede haber varios arcos entre dos nodos.
  - **Dirigido**: las flechas tienen sentido.
  - **Bipartito**: hay dos tipos de nodos (lugares y transiciones) y solo se conectan entre tipos distintos.
- Transición **sensibilizada** (habilitada): todos sus lugares de entrada tienen marca. **Validada**: además ocurre el evento.
- Representación **gráfica** y **matricial**: son dos formas de escribir lo mismo. De una sale la otra, y es única.

1.3 Definición formal

- **Estructura**: **C = (P, T, I, O)**
  - **P**: conjunto finito y no vacío de lugares.
  - **T**: conjunto finito y no vacío de transiciones.
  - **I**: **función de entrada** (qué lugares entran a cada transición).
  - **O**: **función de salida** (qué lugares salen de cada transición). La lectura la describe como un mapeo de transiciones en **bolsas de sitios**; O: T × P → N es la **función de incidencia posterior**.
- **Marcado** μ: cuántas marcas tiene cada lugar (números enteros ≥ 0). Se escribe como vector μ = (μ1, ..., μn), con n = cantidad de lugares. → **El marcado es el estado de la red.**
- **Red marcada**: **M = (C, μ)** = estructura + marcas. Los marcados posibles son infinitos (pero se pueden numerar).
- **Tipos de red**:
  - **Ordinaria**: sus funciones de incidencia solo toman los valores **0 y 1** (todos los arcos son de **peso unitario**).
  - **Generalizada**: sus funciones de incidencia pueden tomar **cualquier valor entero ≥ 0**.
  - **Pura** o **no reflexiva**: ninguna plaza es a la vez entrada y salida de una misma transición (fórmula en 1.8).
- Notación del apunte: I(t) = lugares de entrada a t; O(t) = lugares de salida de t; I'(p) = transiciones que entran al lugar p; O'(p) = transiciones que salen de p; V(p, t) y V(t, p) = pesos de los arcos.

1.4 Ejecución (reglas de disparo)

→ **Regla de oro:** una transición se dispara si sus entradas tienen marcas suficientes. Al dispararse, **"come" marcas de las entradas y "deja" marcas en las salidas**.

1. **Habilitación**: t está habilitada si cada lugar de entrada tiene al menos tantas marcas como el peso del arco: **M(p) ≥ I(p, t)**. Una **transición fuente** (sin entradas) está siempre habilitada.
2. **Disparo**: se sacan marcas de las entradas (según el peso) y se ponen en las salidas (según el peso). Si hay varias habilitadas, cuál va primero es **arbitrario**.
3. **Nuevo marcado**: **M'(p) = M(p) − Pre(p, t) + Post(t, p)**. → "Lo que había, menos lo que se comió, más lo que dejó". Una **transición sumidero** (sin salidas) borra marcas de la red.

- Las marcas son **indivisibles**: una marca la usa una sola transición. Por eso, disparar una transición puede **deshabilitar** a otra que compartía la misma entrada. Fuera de eso, los disparos son **asíncronos**.
- **Grado de habilitación**: cuántas veces puede dispararse una transición a la vez.
- **Inmediatamente alcanzable**: llegás disparando **una** transición.
- **Alcanzable**: existe una secuencia de disparos **σ** que lleva de Mi a Mk.
- **Conjunto de alcanzabilidad R(M)**: todos los marcados a los que se puede llegar desde M. En las fórmulas de la lectura aparece como **M(R, M0)**.
- **Vocabulario de la lectura**: dice **activada** en vez de habilitada (cada lugar de entrada tiene al menos un elemento) y **descarga** en vez de disparo (elimina un elemento de cada lugar de entrada y agrega uno a cada lugar de salida).

1.5 Árbol de alcanzabilidad

En una frase: es el **mapa de todos los estados** a los que puede llegar la red desde M0.

- Cada **nodo** es un marcado. Cada **flecha** lleva el nombre de la transición disparada.
- **Cómo se arma**: empezás en M0, disparás cada transición habilitada, anotás el marcado nuevo y repetís.
- Para que el árbol no sea infinito, **dejás de expandir en los nodos frontera**:
  - a) **Marcado muerto**: no hay ninguna transición habilitada.
  - b) **Nodo duplicado**: ese marcado ya apareció antes.
  - c) Un marcado igual a uno anterior **pero con más marcas en algún lugar** (y habilita las mismas transiciones): ahí escribís **w** (infinito). → Significa que la red **no es acotada**.
- **Máquina de testigos** (MT): versión **más corta** del árbol.
  - Cada estado se escribe con los **nombres de los lugares que tienen marcas** (repetido tantas veces como marcas tenga).
  - Los estados van en **óvalos**, unidos por flechas con el nombre de la transición.
  - → Conviene cuando hay **muchos lugares y pocas marcas**: no tenés que escribir todos los lugares.

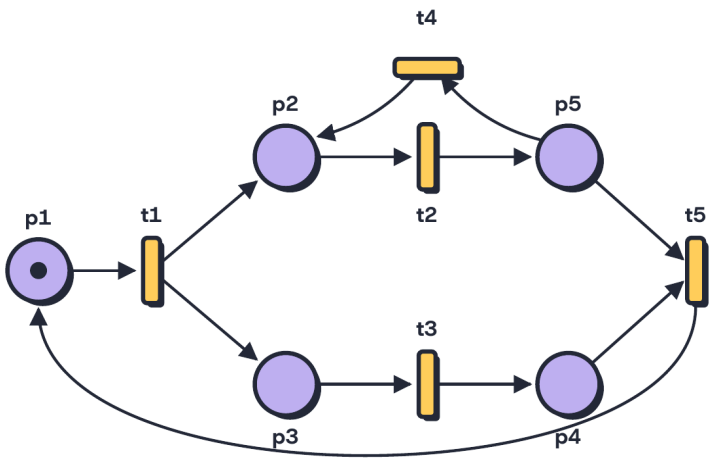
1.6 Representación matricial

→ Tres matrices, tres ideas:

Matriz	Qué guarda	En criollo
C^- (incidencia previa)	$C^-[j, i] = I(pi, tj)$: las precondiciones	Lo que cada transición **consume**
C^+ (incidencia posterior)	$C^+[j, i] = O(pi, tj)$: las postcondiciones	Lo que cada transición **produce**
$C = C^+ - C^-$ (incidencia)	Diferencia entre las dos	El **efecto neto**: cuánto gana o pierde cada lugar

- Según la lectura: **filas = transiciones, columnas = lugares**.
- Una transición tj se escribe con el vector **ej** (1 en la posición j, 0 en el resto).
  - tj está **habilitada** si $\mathbf{M \geq ej \cdot C^-}$.
  - Al dispararla: $\mathbf{M' = M + ej \cdot C}$.
- Para una **secuencia** σ = tj1 tj2 … tjk: $\mathbf{M' = M + f(\sigma) \cdot C}$, con $\mathbf{f(\sigma) = ej1 + ej2 + \ldots + ejk}$ = el **vector de disparo** (cuántas veces se dispara cada transición). Ejemplo de la cátedra: σ = t1, t2, t3 → f(σ) = (1 1 1 0 0) → M' = (0 0 0 1 1).

Ejemplo resuelto (el de la lectura) — P = {p1…p5}, T = {t1…t5}, M0 = (1, 0, 0, 0, 0). I(t1) = {p1}, O(t1) = {p2, p3}; I(t2) = {p2}, O(t2) = {p5}; I(t3) = {p3}, O(t3) = {p4}; I(t4) = {p5}, O(t4) = {p2}; I(t5) = {p4, p5}, O(t5) = {p1}.



Red del ejemplo de la lectura. M0 = (1, 0, 0, 0, 0): una marca en p1.

	C^- (p1 p2 p3 p4 p5)	C^+ (p1 p2 p3 p4 p5)	C (p1 p2 p3 p4 p5)
t1	1 0 0 0 0	0 1 1 0 0	−1 1 1 0 0
t2	0 1 0 0 0	0 0 0 0 1	0 −1 0 0 1
t3	0 0 1 0 0	0 0 0 1 0	0 0 −1 1 0
t4	0 0 0 0 1	0 1 0 0 0	0 1 0 0 −1
t5	0 0 0 1 1	1 0 0 0 0	1 0 0 −1 −1

La resolución completa (árbol, máquina de testigos, método matricial y propiedades) está en 1.12, Ejemplo 1.

1.7 Estructuras básicas

Estructura	Qué modela	Cómo se ve
Secuencial	Una cosa después de otra	t2 solo se dispara después de t1
Selección	Elegir qué proceso hacer	Un lugar con dos transiciones de salida
Atribución	Llegar al mismo lugar desde dos procesos distintos	Dos transiciones que llegan al mismo lugar

Estructura	Qué modela	Cómo se ve
Distribución	Arrancar procesos en paralelo	Una transición con varios lugares de salida
Conjunción	Juntar (sincronizar) procesos paralelos	Una transición con varios lugares de entrada
Sincronización	Esperar a que todo esté listo	t1 se habilita solo si **todas** sus entradas tienen marca
Concurrencia	Dos cosas a la vez, sin molestarse	t2 y t3 se disparan a la vez e independientemente
Conflicto	Dos quieren lo mismo	t1 y t2 habilitadas, pero disparar una deshabilita a la otra

→ **Distribución "abre"** (una transición → varias salidas); **conjunción "cierra"** (varias entradas → una transición).

1.8 Propiedades

→ Las propiedades sirven para **detectar fenómenos de interés o errores de funcionamiento** en el sistema que modela la red (bloqueos, recursos infinitos, conflictos...). Hay dos grupos:

- **Estructurales**: dependen de la **estructura topológica** (cómo está dibujada la red) y son **independientes del marcado inicial**.
- **De comportamiento**: **dependen del marcado inicial M0**.

La presentación "Redes_de_petri" trabaja seis: **vivacidad, ciclicidad, limitación, conservación, conflictividad y exclusión mutua**. El resumen agrega **acotada** y **completamente controlable**. La lectura destaca dos: **supervivencia** (ausencia de estancamientos) y **seguridad** (capacidad limitada de la memoria).

Notación: **M(R, M0)** = conjunto de marcados alcanzables desde M0.

Propiedades estructurales

Propiedad	Definición	→ En criollo
Pura	Ninguna transición tiene un lugar que sea a la vez de entrada y de salida: **∀tj ∈ T, ∀pi ∈ P: Pre(pi, tj) · Post(tj, pi) = 0**	Ninguna flecha "va y vuelve" entre el mismo lugar y la misma transición
Estructuralmente acotada	Acotada para **cualquier** marcado inicial finito. Un **lugar** p es **no acotado estructuralmente** si existe un marcado M y una secuencia σ desde M tal que p no está acotado	Arranque como arranque, nada crece sin fin
Estructuralmente viva	Existe **algún** marcado inicial con el que es viva	Hay al menos una forma de arrancarla sin que se trabe
Estructuralmente conservativa	La cantidad (ponderada) de marcas se mantiene para **cualquier** marcado inicial	Arranque como arranque, los recursos no cambian
Completamente controlable	**Cualquier marcado es alcanzable desde cualquier otro**	Desde cualquier estado llego a cualquier estado

Propiedades de comportamiento

Alcanzabilidad — → "¿Puedo llegar a ese estado?"

- Es la **base fundamental para estudiar las propiedades dinámicas**.
- Cada disparo cambia la distribución de las marcas; una secuencia de disparos σ = t1, t2, ..., tn da una secuencia de marcados.
- Mn es alcanzable desde M0 sii existe σ tal que **M0 [σ> Mn**.

Vivacidad — → "Nada se traba para siempre"

- Sirve para **caracterizar el bloqueo total o parcial** del sistema.
- **Transición viva**: desde cualquier marcado alcanzable existe una secuencia de disparos que **la incluye**. La lectura lo escribe: ∀m ∈ M(R, M0) ∃σ: M σ→ M0 t.q. t ⊂ σ.
- **Red viva**: **todas** sus transiciones son vivas. Entonces, en el conjunto de alcanzabilidad **no hay ningún marcado con bloqueo total (*deadlock*)**.

- **Parcialmente viva**: desde cualquier marcado alcanzable hay **al menos una transición disparable** y **otra no viva**. Tiene **posibilidad de evolución global**, aunque algunas transiciones no puedan dispararse.
- **No viva**: se llega a un marcado muerto. Ejemplo de la lectura: con t1, t2, t1, t2 no hay bloqueo, pero con t1, t3, t4 la red queda **bloqueada**.
- Versión de la lectura con "descargas": un **marcado vivo** permite, sin importar las descargas hechas, descargar cualquier transición con alguna secuencia adicional → la red **nunca se estancará**.

Ciclicidad o reversibilidad — → "Siempre puedo volver al inicio"

- Comportamiento **globalmente cíclico**: desde **cualquier marcado sucesor** de M0 existe una secuencia de disparos que **vuelve a M0**: **$\forall M \in M(R, M0), \exists \sigma$ tal que $M\ \sigma\rightarrow M0$**.
- Garantiza que **no existen subconjuntos finales de estados**: grupos de marcados **mutuamente alcanzables entre sí** desde los cuales **M0 no es alcanzable**.
- Ejemplo de la lectura: una red **pseudoviva** y **no reversible**, porque el marcado inicial no se obtiene jamás.

Acotamiento o limitación — → "Ningún lugar se llena de más"

- Asegura que el sistema tiene un **número finito de estados** (si cada lugar es una variable de estado y su marcado, el valor de esa variable).
- Un lugar p es **k-acotado** sii $M(p) \leq k$ para cualquier $M \in M(R, M0)$. La **cota del lugar p** es el **menor** k que lo cumple.
- Red **k-acotada** o **k-limitada**: todos sus lugares lo son: **$\forall p \in P$ y $\forall M \in M(R, M0), M(p) \leq k$**. Ejemplo de la diapositiva: red **3-limitada**.
- **Garantiza la finitud de los marcados alcanzables**: una red k-limitada **puede implementarse con recursos finitos**.
- Si la red genera más marcas de las que permite su acotación, **el modelado es erróneo**.
- Versión de la lectura con "descargas": un **marcado acotado** es uno en el que existe un entero positivo n tal que ningún lugar recibe más de n elementos en ninguna secuencia de descarga.

Seguridad — → "Cada lugar: marca sí o no"

- Red **1-acotada** = **segura** = **binaria**: su marcado es binario (cada lugar está marcado o no).
- En la lectura: un marcado acotado en el que ningún lugar recibe más de un elemento es un **marcado seguro**. Si cada lugar es un registro que guarda una palabra de computadora y el marcado inicial es seguro, **no se excede la capacidad de memoria** de los registros.

Conservación — → "Las marcas ni se crean ni se destruyen" (como recursos)

- El **número de recursos disponibles no puede variar** durante la ejecución.
- **Conservación estricta**: el número total de testigos es constante. Es una relación **muy fuerte**.
- Por eso se suele usar **conservación respecto de un vector peso** w: la suma ponderada **Σ wi · mi** es constante. Ejemplo de la diapositiva: w = (1, 1, 1, 2, 2).

Conflictividad — → "Hay que elegir una" (decisión no determinista)

- **Conflicto estructural**: un lugar tiene **más de una transición de salida**. Se ve en el dibujo.
- **Conflicto efectivo** para M0: ti y tj lo están si se cumplen las dos condiciones:
  1. existe un marcado alcanzable que las **sensibiliza simultáneamente**, **y**
  2. al disparar una, el marcado que queda **no habilita** a la otra.
- → El efectivo depende del marcado: las dos están habilitadas a la vez y **compiten por el mismo testigo**.

Exclusión mutua — → "De a uno por vez"

- Entre **transiciones**: un conjunto $Te \subseteq T$ es mutuamente exclusivo si disparar cualquier $ti \in Te$ **deshabilita a todas las demás**.
- Entre **plazas**: dos plazas están en exclusión mutua si **nunca pueden estar marcadas a la vez** en ningún marcado alcanzable.
- Ejemplo de la diapositiva: las plazas 4 y 5 y las transiciones Π1 y Π2 son mutuamente exclusivas (R = recurso disponible; R1 y R2 = recurso tomado por Π1 o por Π2). El modelo del semáforo está en 1.9.

Tabla resumen

Propiedad	Pregunta que responde	Detecta
Vivacidad	¿Se pueden disparar siempre todas las transiciones?	Bloqueos (*deadlock*)
Ciclicidad	¿Puede volver al estado inicial?	Sistemas que no se "reinician"

Propiedad	Pregunta que responde	Detecta
Limitación / acotada	¿Las marcas por plaza tienen un tope k?	Necesidad de recursos infinitos
Conservación	¿Se mantiene la cantidad (ponderada) de marcas?	Creación o pérdida de recursos
Conflictividad	¿Hay transiciones que compiten por una marca?	Decisiones / no determinismo
Exclusión mutua	¿Hay plazas o transiciones que no coexisten?	Uso de recursos compartidos
Completamente controlable	¿Todo marcado es alcanzable desde todo otro?	Estados inalcanzables

1.9 Modelos clásicos de concurrencia

- **Exclusión mutua (semáforo)**: cuando varios procesos comparten un recurso y mientras uno lo usa los demás no pueden, hay que implementar un **mecanismo de espera**. Se usa un lugar (sitio) que representa la condición **"el recurso compartido está libre"**, con **una marca**. Ese lugar actúa como **semáforo**: sincroniza el acceso de los procesos. El primero que lo toma quita la marca y los demás esperan. Sirve para cualquier cantidad de procesos y **no tiene prioridades**.
- **Productor y consumidor**: también hay un recurso compartido, pero no para que lo usen los procesos, sino como **mecanismo de comunicación** entre ellos. Un lugar "depósito" (*buffer*) une a los dos procesos. Sin límite, el depósito puede crecer para siempre si el consumidor se para. Con un **buffer de capacidad finita** se agregan "buffers llenos" y "buffers vacíos"; → **siempre suman la capacidad total** (por ejemplo, 3).
- **Lectores y escritores**: muchos pueden **leer a la vez**; **escribir es de a uno**. Se usa un semáforo con **m marcas** y arcos de peso **m**: leer toma 1 marca, escribir toma las m.
- **Cinco filósofos**: cada uno necesita los dos tenedores de al lado para comer. Si todos agarran primero el mismo tenedor, nadie come: **estancamiento**. Soluciones para que la red sea viva: que "comer" tome **los dos tenedores a la vez** (conjunción), o un lugar "sillas" con **4 marcas** que limite cuántos intentan comer. ! Son las soluciones habituales; la del grupo está en imagen.

1.10 Ventajas, desventajas, aplicaciones, subclases y métodos de análisis

Ventajas	Desventajas
Fáciles de interpretar	**No permiten modelar prioridades**
Manejan procesos independientes	El análisis se complica en sistemas complejos
Más exactas que un diagrama de estados	Cuanto más grande el modelo, más recursos consume
Modelan recursos compartidos (exclusión mutua, por ejemplo una impresora)	Hay muchas **subclases** para problemas específicos
Se arman *top-down* o *bottom-up*	
Modelan procesos concurrentes	

Aplicaciones: sistemas en **tiempo real**, sistemas operativos y compiladores, *hardware* y *software*, producción industrial (redes de libre elección), diagramas de flujo de datos (DFD), **protocolos de comunicación** y bases de datos.

Subclases → versiones con reglas más estrictas, más fáciles de analizar:

Subclase	Regla	Puede / no puede
Grafo de estados o máquina de estados (GE o ME)	Cada **transición**: **1 entrada y 1 salida**	✓ conflictos y alternativas · ✗ paralelismo, concurrencia, sincronización. Estrictamente conservativa
Grafo marcado o de sincronización (GM)	Cada **lugar**: **1 entrada y 1 salida**	✓ paralelismo, concurrencia, sincronización · ✗ conflictos y decisiones
Red de libre elección (RLE)	Si un lugar es entrada de varias transiciones, es su **única** entrada	Concurrencia y conflicto, pero limitado: las transiciones en conflicto están habilitadas todas o ninguna
Red simple (RS)	Cada transición tiene como máximo **un lugar de entrada compartido** con otra	—

→ El **grafo de estados** se fija en las **transiciones** (elige, pero no paraleliza); el **grafo marcado** se fija en los **lugares** (paraleliza, pero no elige). Son opuestos.

Métodos de análisis:

- **Árbol de alcanzabilidad**: da mucho detalle del comportamiento. Sirve para validar el modelo, verificar un diseño, elegir entre propuestas o predecir. **Problema**: puede volverse **enorme e inmanejable**.
- **Ecuaciones matriciales o de estado**: prometen, pero tienen tres problemas:
  1. La matriz C **no muestra toda la estructura** de la red.
  2. El vector de disparo **no dice el orden** de los disparos.
  3. Que M' = M + f(σ)·C tenga solución es condición **necesaria pero no suficiente** para que el marcado sea alcanzable.

Modelos de redes (final de la presentación "Redes_de_petri"; son de investigación operativa): arista, nodo, capacidad, fuente y sumidero.

- **Ruta más corta**: el camino de menor distancia entre origen y destino.
- **Árbol de expansión mínima**: conectar todos los nodos al menor costo.
- **Flujo máximo**: pasar lo máximo posible entre origen y destino, respetando capacidades.
- **Flujo de costo mínimo**: cubrir la demanda al menor costo.

1.11 Verificación y ambientes de simulación

- Ejecutar la red = **simular**. Eso da una **verificación** del modelo. Una **validación** necesita algo más formal (las técnicas matemáticas se acercan a una "prueba").
- Si el modelo es grande, a mano no se puede: hacen falta herramientas que lo ejecuten solas (por ejemplo **HPetriSim**, el de los ejercicios).
- **Ambientes gráficos**: ves todo rápido, pero definir la red es tedioso y en redes grandes el dibujo se vuelve confuso.
- **Ambientes estructurales** (intérprete): perdés lo visual, pero la red escrita como pseudocódigo se parece al código (lenguajes como ADA o Modula).

1.12 Práctica que entra en el parcial: resolver una red paso a paso

Entra: **árbol de alcanzabilidad**, **características y propiedades**, y **resolver una red con máquina de testigos y método matricial**. Los tres ejemplos están verificados por computadora.

Receta para el examen (6 pasos)

1. **Leer la red**: lugares, transiciones, arcos (y sus pesos) y M0. Escribir I(t) y O(t) de cada transición.
2. **Matrices**: C^- (entradas), C^+ (salidas) y **$C = C^+ - C^-$**. **Filas = transiciones, columnas = lugares**.
3. **Árbol de alcanzabilidad**: desde M0, por cada transición habilitada calculá el marcado nuevo y numeralo (M1, M2…). Cortá en los **nodos frontera** (ver 1.5). Con ω: $\omega + 1 = \omega$ y $\omega - 1 = \omega$.
4. **Máquina de testigos**: juntá los duplicados y dibujá el **grafo de marcados**. Cada óvalo lleva los lugares marcados (repetidos si tienen más de una marca).
5. **Método matricial**: comprobá una secuencia σ con **$M' = M + f(\sigma)\cdot C$**. Como la ecuación no dice el orden, revisá que cada transición esté habilitada en su momento (**$M \geq e_j \cdot C^-$**).
6. **Propiedades**: leelas del árbol y del grafo con esta tabla:

Propiedad	Cómo la ves en el árbol o en la máquina de testigos
Viva	No hay marcados muertos y, desde cualquier estado, cada transición puede volver a dispararse
Parcialmente viva	No hay marcados muertos, pero alguna transición deja de poder dispararse
No viva	Aparece un marcado muerto (bloqueo total)
Acotada (k-acotada)	No aparece ω; k = el máximo de marcas que llega a tener un lugar
Segura	k = 1: ningún lugar pasa de una marca
No acotada	Aparece ω en algún lugar
Cíclica (reversible)	Desde todos los estados se puede volver a M0
Conservativa	La suma de marcas es igual en todos los marcados (o la suma ponderada con un vector peso)
Conflicto	Estructural: un lugar con 2 o más transiciones de salida. Efectivo: en algún marcado las dos están habilitadas y disparar una deshabilita la otra

Propiedad	Cómo la ves en el árbol o en la máquina de testigos
Concurrencia	Dos transiciones habilitadas a la vez que no comparten entradas
Exclusión mutua de lugares	Dos lugares que nunca están marcados a la vez
Pura	Ningún lugar es entrada y salida de la misma transición

Ejemplo 1 — red acotada (la de la lectura, ver 1.6)

P = {p1…p5}, M0 = (1, 0, 0, 0, 0). t1: p1 → p2, p3; t2: p2 → p5; t3: p3 → p4; t4: p5 → p2; t5: p4, p5 → p1. Las matrices están en 1.6.

Árbol de alcanzabilidad:

```
M0 (1,0,0,0,0)
└─ t1 → M1 (0,1,1,0,0)
   ├─ t2 → M2 (0,0,1,0,1)
   │  ├─ t3 → M4 (0,0,0,1,1)
   │  │  ├─ t4 → (0,1,0,1,0)  duplicado de M3
   │  │  └─ t5 → (1,0,0,0,0)  duplicado de M0
   │  └─ t4 → (0,1,1,0,0)  duplicado de M1
   └─ t3 → M3 (0,1,0,1,0)
      └─ t2 → (0,0,0,1,1)  duplicado de M4
```

Máquina de testigos (5 estados, 8 arcos):

Desde	Transición	Hacia
p1	t1	p2 p3
p2 p3	t2	p3 p5
p2 p3	t3	p2 p4
p3 p5	t3	p4 p5
p3 p5	t4	p2 p3
p2 p4	t2	p4 p5
p4 p5	t4	p2 p4
p4 p5	t5	p1

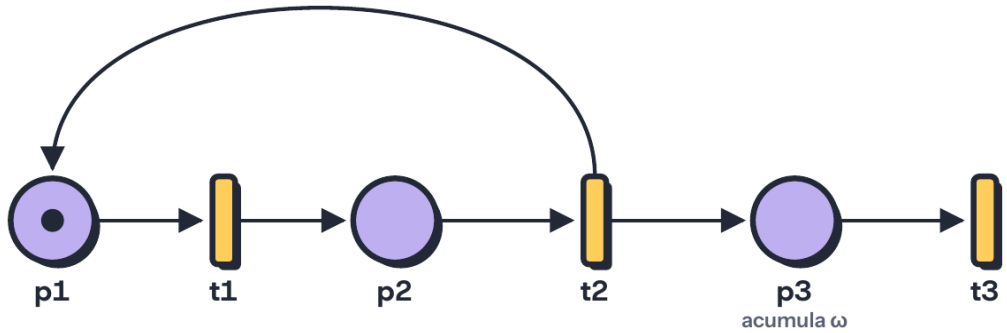
Método matricial: σ = t1 t3 t2 t5 → f(σ) = (1 1 1 0 1). f(σ)·C = suma de las filas t1, t2, t3 y t5 de C = (0 0 0 0 0) → **M' = M0**: la secuencia vuelve al inicio. t5 está habilitada en M4: $e_5 \cdot C^- = (0\ 0\ 0\ 1\ 1) \leq (0\ 0\ 0\ 1\ 1)$.

Propiedades:

- **Viva** (sin marcados muertos; desde cualquier estado se vuelve a todos).
- **Segura** (1-acotada), **cíclica**, **pura**.
- **No es estrictamente conservativa** (M0 tiene 1 marca y el resto 2), pero sí respecto del vector peso (2 1 1 1 1).
- **Conflicto** estructural en p5 (t4 y t5) y efectivo en M4.
- **Concurrencia**: t2 y t3 en M1; t3 y t4 en M2.
- **Exclusión mutua de lugares**: p2 y p5, p3 y p4, y p1 con todos los demás.

Ejemplo 2 — red no acotada (con ω)

P = {p1, p2, p3}, M0 = (1, 0, 0). t1: p1 → p2; t2: p2 → p1, p3; t3: p3 → (nada, es una transición sumidero).



Red no acotada. M0 = (1, 0, 0). t3 es una transición sumidero.

	C^- (p1 p2 p3)	C^+ (p1 p2 p3)	C (p1 p2 p3)
t1	1 0 0	0 1 0	−1 1 0
t2	0 1 0	1 0 1	1 −1 1
t3	0 0 1	0 0 0	0 0 −1

Árbol de alcanzabilidad:

```
M0 (1,0,0)
└─ t1 → M1 (0,1,0)
   └─ t2 → (1,0,1) cubre a M0 (igual en p1 y p2, más en p3) → M2 (1,0,ω)
      ├─ t1 → M3 (0,1,ω)
      │  ├─ t2 → (1,0,ω)  duplicado de M2
      │  └─ t3 → (0,1,ω)  duplicado de M3
      └─ t3 → (1,0,ω)  duplicado de M2
```

Máquina de testigos: p1 —t1→ p2 —t2→ p1 p3ω; p1 p3ω —t1→ p2 p3ω y —t3→ p1 p3ω; p2 p3ω —t2→ p1 p3ω y —t3→ p2 p3ω.

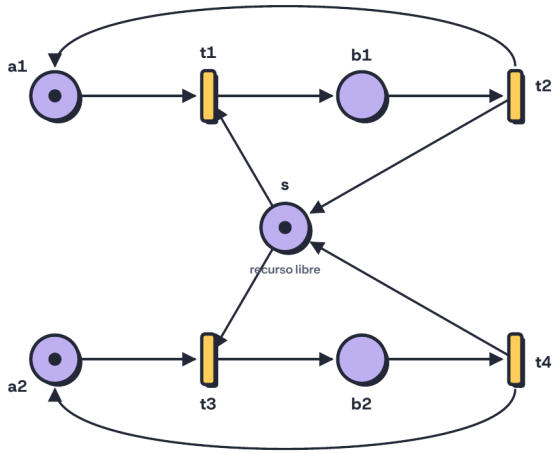
Método matricial: σ = t1 t2 t1 t2 t3 → f(σ) = (2 2 1) → M' = (1 0 0) + 2·(−1 1 0) + 2·(1 −1 1) + (0 0 −1) = **(1 0 1)**. Paso a paso: (0 1 0), (1 0 1), (0 1 1), (1 0 2), (1 0 1).

Propiedades:

- **No acotada** (p3 llega a ω; p1 y p2 son 1-acotados).
- **Viva**.
- **Cíclica**: desde (1, 0, k) disparás t3 k veces y volvés a M0. Ojo: el árbol con ω no alcanza para afirmarlo, hay que razonarlo.
- **No conservativa**, **pura**, **sin conflicto** (ningún lugar tiene dos transiciones de salida).
- **Exclusión mutua de lugares**: p1 y p2 (siempre p1 + p2 = 1).

Ejemplo 3 — exclusión mutua de dos procesos (semáforo)

Lugares: a1 y a2 (proceso esperando), b1 y b2 (proceso usando el recurso), s (recurso libre). M0 = (a1, b1, a2, b2, s) = (1, 0, 1, 0, 1). t1: a1, s → b1; t2: b1 → a1, s; t3: a2, s → b2; t4: b2 → a2, s.



Exclusión mutua de dos procesos. M0 = (a1, b1, a2, b2, s) = (1, 0, 1, 0, 1).

	C⁻ (a1 b1 a2 b2 s)	C⁺ (a1 b1 a2 b2 s)	C (a1 b1 a2 b2 s)
t1	1 0 0 0 1	0 1 0 0 0	−1 1 0 0 −1
t2	0 1 0 0 0	1 0 0 0 1	1 −1 0 0 1
t3	0 0 1 0 1	0 0 0 1 0	0 0 −1 1 −1
t4	0 0 0 1 0	0 0 1 0 1	0 0 1 −1 1

Árbol: M0 (1,0,1,0,1) → t1 → M1 (0,1,1,0,0) → t2 → duplicado de M0; M0 → t3 → M2 (1,0,0,1,0) → t4 → duplicado de M0.

Máquina de testigos: a1 a2 s —t1→ b1 a2 —t2→ a1 a2 s; a1 a2 s —t3→ a1 b2 —t4→ a1 a2 s.

Método matricial: σ = t1 t2 t3 → f(σ) = (1 1 1 0) → M' = M0 + (0 0 −1 1 −1) = **(1 0 0 1 0)** = M2.

Propiedades:

- **Viva**, **segura**, **cíclica**, **pura**.
- Conservativa respecto del vector peso (1 2 1 2 1).
- **Conflicto** estructural y efectivo en s: en M0, t1 y t3 están habilitadas y disparar una deshabilita la otra.
- **Exclusión mutua**: b1 y b2 nunca están marcados a la vez.

Errores típicos al resolver

- ✗ Seguir expandiendo un nodo **duplicado** → ✓ se corta ahí.
- ✗ Poner ω sin compararlo con un **antecesor del mismo camino**, o "restarle" a ω → ✓ ω − 1 = ω.
- ✗ Armar la matriz con **filas = lugares** → ✓ filas = transiciones.
- ✗ Creer que si M' = M + f(σ)·C tiene solución, la secuencia se puede disparar → ✓ es **necesaria pero no suficiente**.
- ✗ En la máquina de testigos, no repetir el nombre de un lugar con **dos marcas** → ✓ se repite.

2 Business Intelligence (Tema 8)

En una frase: BI es **usar los datos de la empresa para tomar mejores decisiones**, de forma continua.

2.1 Definición

- **Business Intelligence** (BI) = "inteligencia de negocio". Objetivo: ayudar a la organización a ser más **competitiva**, de forma **sostenible y continuada**, dándole información para **tomar decisiones**.
- Lo popularizó **Howard Dresner** (consultor de Gartner) como "término paraguas" para métodos que mejoran las decisiones usando **hechos** (lo que ya pasó).
- → Idea central: **datos → información → conocimiento**.

Definición de Gartner (la más ajustada): BI es un **proceso interactivo** para **explorar** y **analizar información estructurada** de un **área** (normalmente en un ***datawarehouse***), para descubrir **tendencias o patrones**, sacar ideas y conclusiones. Incluye **comunicar** lo que se descubre y **hacer los cambios**. Las áreas pueden ser clientes, proveedores, productos, servicios y competidores.

Parte de la definición	→ Qué quiere decir
Proceso interactivo	Se hace **todo el tiempo**, no una sola vez. Así ves tendencias y cambios
Explorar	Primer vistazo: entender qué pasa y encontrar relaciones que no conocías
Analizar	Ver cómo se relacionan las variables (si un cliente hace esto, ¿uno parecido hará lo mismo?)
Información estructurada y *datawarehouse*	Tablas relacionadas, con registros y atributos, guardadas en un **almacén de datos**
Área de análisis	Todo proyecto tiene un objeto (clientes, productos) y un objetivo (bajar costos, subir ventas)
Comunicar y efectuar cambios	Lo descubierto tiene que llegar a quien puede cambiar algo

- **Definición del TDWI** (The Data Warehousing Institute): término paraguas para procesos, herramientas y tecnologías que convierten **datos en información, información en conocimiento** y planes para manejar el negocio. Tiene dos partes:
  - ***Back end*** ("trastienda"): el *datawarehousing*.
  - ***Front end*** ("mostrador"): consultas, informes, análisis y visualización.

2.2 De los datos a las decisiones

- Los **datos** de las transacciones (qué se vendió, cuándo, quién, cómo se pagó) se convierten en **información operativa** (ventas del día, ticket medio, ventas por artículo).
- Esa información sirve para **decisiones**:
  - **Operativas**: reponer, asignar turnos.
  - **Estratégicas**: qué hacer cuando bajan las ventas. ¿Viene menos gente o cada cliente gasta menos?
- Con el tiempo aparecen **tendencias** y **relaciones entre productos**, que permiten promociones y mejor ubicación.

2.3 Quién lo necesita

- Compras, ventas, negociación con bancos, marketing y personal. → En resumen: **todo el que decide**. Las decisiones pueden ser **operativas o estratégicas**.

2.4 Beneficios

Tipo	→ Qué son	Ejemplos
Tangibles (más ingresos)	Se miden en plata	Segmentar clientes, reducir el abandono, análisis de la cesta de la compra, medir campañas, encontrar clientes rentables
Tangibles (menos costos)	Se miden en plata	Negociar con proveedores, inventarios *just-in-time*, detectar fraude, menos deudas incobrables, "una sola versión de la verdad"

Tipo	→ Qué son	Ejemplos
Intangibles	No se miden fácil	Mejor atención y satisfacción del cliente, información más actual y precisa, más integración, ventaja competitiva
Estratégicos	Ayudan a decidir el rumbo	A qué clientes, mercados o productos ir; decisiones más rápidas y basadas en hechos

2.5 Componentes básicos

Los 6 componentes de todo proyecto de BI:

1. **Problema del negocio** a responder.
2. **Equipo** (o persona) que analiza.
3. **Información interna** de los sistemas de la organización.
4. **Información externa** a la organización (mercado, proveedores, tarifas).
5. Una **base de datos**: el *datawarehouse*.
6. Una **aplicación de BI** para analizar y visualizar.

Nota técnica 1 — Sistemas de información:

- Las organizaciones necesitan información para **registrar transacciones**, para **decidir y controlar** y para **nuevos negocios** (vender información).
- Los sistemas sirven para **controlar, coordinar y decidir** en la **planificación, la gestión y las operaciones**.
- Preguntas **estructuradas** (respuesta sí/no o un número: ¿entregamos a tiempo?) vs. **no estructuradas** (¿lanzamos el producto Y en el mercado Z?).
- **ERP** (*Enterprise Resources Planning*): integra módulos con el concepto de **dato único**. Si las aplicaciones no están integradas, se pasan datos con **interfases**.

2.6 Retorno de la inversión (ROI)

→ El ROI responde: **¿lo que gano vale lo que gasto?**

- **ROI simple = valor para el negocio / costo del proyecto**. El costo es fácil de medir; el valor es lo difícil.
- **Los 8 pasos de Bill Whittemore**:
  1. Definir el problema u oportunidad con objetivos **específicos, medibles, alcanzables, adecuados y con plazo**.
  2. Juntar requerimientos.
  3. Construir el proyecto.
  4. Identificar y medir los beneficios.
  5. Fijar el punto de partida de costos e ingresos.
  6. Calcular el **TCO** (*Total Cost of Ownership*, costo total de propiedad): *hardware*, *software*, consultoría, personal, lanzamiento, mantenimiento y formación.
  7. Calcular **ROI = NPV / inversión inicial × 100**.
  8. Seguir y corregir.
- **NPV** (*Net Present Value*, valor actual neto) = suma de los flujos de caja (CF, *Cash Flow*) de cada año, descontados a la tasa r, **menos** la inversión inicial.

2.7 Modelización del negocio

- → **"Lo que no se mide, no se puede gestionar"**. Primero definís **qué** medir y **cómo**: el **modelo de negocio** y sus métricas.
- **Modelo de negocio**: una **versión simplificada de la realidad** para **documentar, probar y desarrollar teorías** sobre cómo funciona el negocio y **experimentar** qué pasa si cambiás algo. Tiene que estar **vivo**, como el negocio.
- **Silos de información**: departamentos que no comparten información (por falta de integración o por política). → Lo mejor para un departamento no siempre es lo mejor para la empresa.
- **Cómo se arma**: con metodologías como **contabilidad analítica o de costos, EFQM** (*European Foundation for Quality Management*), **Six Sigma, análisis de procesos, modelos financieros y análisis de ratios**; buscando áreas críticas, factores que influyen en el resultado y la estructura de la organización.

2.8 Indicadores clave (KPI)

- **KPI** (*Key Performance Indicators*): números que dicen **si la organización cumple sus objetivos** y cuánto avanza.
- Un KPI tiene que:
  - **Reflejar los objetivos**.
  - Ser **crítico para el éxito**.
  - Ser **cuantificable y comparable**.
  - Permitir **acciones correctivas**.
- Pocos, alineados entre departamentos y definidos con los responsables de cada área.
- Cada KPI tiene **nombre, definición, forma de cálculo y objetivo**.

2.9 Modelo de datos

- **Modelo relacional** (E. F. **Codd**, **1970**): tablas y relaciones.
  - **PK** (*Primary Key*, clave primaria): identifica cada registro.
  - **FK** (*Foreign Key*, clave externa): relaciona tablas.
  - Se consulta con **SQL** (*Structured Query Language*; ver la trampa 4 del principio).
  - El **modelo entidad-relación** muestra las tablas y cómo se relacionan.
- Orden: primero el modelo de negocio; después **qué medir (hechos)** y **cómo mirarlo (dimensiones)**.
- Las dimensiones responden **qué, quién, por qué, dónde y cuándo**.

→ **Hechos = los números que medís. Dimensiones = desde dónde los mirás.**

- **Tabla de hechos** (*fact table*): lo que se mide (por ejemplo, el total del ticket) + las claves de las dimensiones.
- **Tablas de dimensiones**: el contexto para agrupar y filtrar (tiempo, centro, empleado, forma de pago).
- **Dimensiones degeneradas**: no necesitan tabla propia (número de ticket, identificador de caja).
- **Dimensión tiempo**: la fecha se parte en día de la semana, del mes, del año, mes, trimestre, año, vacaciones y fin de semana. Esos datos (y los feriados) **no están** en el sistema transaccional: hay que agregarlos.

	Esquema estrella	**Esquema copo de nieve (*snowflake*)**
Dimensiones	**Una tabla por dimensión**, desnormalizada	Dimensiones **normalizadas**, partidas en tablas relacionadas (Zona separada de Centro)
Relaciones	Solo hechos ↔ dimensiones	También dimensión ↔ dimensión
Redundancia	Sí (la zona se repite en cada centro)	No
A favor	Más simple y rápido de consultar	Ocupa menos (a veces la diferencia es poca)
En contra	Ocupa más	Más complejo

→ La **estrella** es "plana" (una tabla por dimensión); el **copo de nieve** se "ramifica" (las dimensiones se parten en más tablas).

- **Constelación de hechos** (o esquema **galaxia**): varias estrellas con distintas tablas de hechos que comparten dimensiones.
- **Granularidad** = nivel de detalle. → **Más granularidad = más detalle** (analizar **líneas** de ticket es más granular que analizar tickets). Cada nivel responde unas preguntas y no otras. **Cada vez que agregás (sumás), perdés información**. Conviene construir al **máximo detalle** si el volumen lo permite.
- **Jerarquías**: año → trimestre → mes → día; familia → subfamilia → artículo; zona → centro; categoría → empleado. Sirven para subir y bajar de nivel.
- **Multidimensionalidad**: analizar por **varias dimensiones a la vez** (ventas de un artículo por centro y por mes).
- Si fabricante y artículo están en la misma dimensión no se pueden cruzar → van en dimensiones distintas.
- → **Cada modelo de datos responde un número limitado de preguntas**, y cada modelo responde preguntas distintas.

2.10 Componentes de BI (capítulo 4 del libro)

→ **El camino de los datos: fuentes de información → proceso ETL → *datawarehouse* (con su metadata) → motor OLAP → herramientas de visualización**. En un proyecto real, el orden de trabajo es otro: primero se definen **objetivos, alcance y modelos de negocio**.

Fuentes de información

- **Sistemas operacionales o transaccionales**: aplicaciones a medida, ERP, CRM (relación con clientes), SCM (cadena de suministro).
- **Sistemas departamentales**: previsiones, presupuestos, hojas de cálculo.
- **Fuentes externas**, a veces compradas (estudios de mercado, datos de población).
- La información puede ser estructurada, semiestructurada o **no estructurada** (correos, cartas, informes, videos).

Calidad de datos

- → **Si entra basura, sale basura.** Los errores del *datawarehouse* **se contagian a toda la organización** y llevan a malas decisiones; los usuarios **dejan de confiar** en el proyecto.
- Los errores vienen de los **sistemas transaccionales**, del **proceso ETL** o del propio ***datawarehouse***. Conviene **corregirlos en el origen** (que el usuario elija de una lista en vez de escribir libre), no solo en el ETL.
- La calidad es un **problema de negocio, no solo técnico**.
- **7 características** de datos de calidad: **precisión, integridad, coherencia, totalidad, validez, disponibilidad y accesibilidad**.

Proceso ETL (*Extract, Transform, Load*: extracción, transformación y carga)

- → Es "la cocina" del BI: se lleva **entre el 60 % y el 80 %** del tiempo del proyecto. Tiene **5 subprocesos**:

Subproceso	→ Qué hace
1. Extracción	Saca los datos de las fuentes: datos **en bruto**. A mano (rutinas, por ejemplo en COBOL) o con herramientas ETL (lo más rentable)
2. Limpieza	Revisa la calidad, saca duplicados, corrige errores, completa vacíos: datos **limpios**
3. Transformación	Ordena y **resume** según los modelos (cambios de formato, códigos, valores calculados y **agregados**). Acá se fija la **granularidad**
4. Integración	Verifica que los datos coincidan con las definiciones del *datawarehouse* y los carga (por ejemplo, que los totales de ventas coincidan con el origen)
5. Actualización	Define **cada cuánto** se hacen nuevas cargas

- **Almacén de datos intermedio** (*data staging*): una "sala de espera" entre la extracción y lo demás, mientras se limpian los datos. Junta datos de varias fuentes. **Los usuarios finales nunca entran**.
- **Datos "sucios"**: valores por defecto (código 999), campos vacíos, valores raros o contradictorios, campos con varios usos, claves reutilizadas, identificadores repetidos.
- **Etapas de la limpieza**: **depurar** (*parsing*: separar nombre y apellido), **corregir** (*correcting*), **estandarizar** (*standardizing*), **relacionar** (*matching*: encontrar duplicados) y **consolidar** (*consolidating*: unir registros relacionados).

Datawarehouse (almacén de datos)

- → Es **el lugar único donde están todos los datos listos para analizar**: **consistentes, integrados, históricos y preparados**. Usar planillas en su lugar trae errores, trabajo repetido, "entornos paralelos" y **distintas versiones de la misma realidad**.
- **Hugh J. Watson**: "una colección de información creada para soportar las aplicaciones de toma de decisiones". ***Datawarehousing*** = todo el proceso: extraer, transformar, cargar y dar acceso a los usuarios.
- **Bill Inmon — 4 características**:
  - **Orientado a un área** (un problema de negocio).
  - **Integrado** (medidas, códigos y formatos comunes).
  - **Indexado en el tiempo** (guarda historia).
  - **No volátil** (los usuarios no lo modifican; se actualiza cada tanto).
- **Ralph Kimball**: da acceso a la información, es consistente, se puede separar y combinar por cada medida, incluye herramientas de consulta y es "el lugar donde publicamos la información".
- Guarda los datos para **maximizar flexibilidad, facilidad de acceso y administración**. Se actualiza **mensual, semanal o diariamente**. El concepto *right time* dice que cada situación pide su propio plazo.

Data Mart y estrategias de construcción

- **Data Mart**: un "mini *datawarehouse*" para una **comunidad de usuarios** (un departamento, un nivel o un grupo con objetivos comunes) y pocas áreas (por ejemplo, marketing y ventas). **Más chico**: menos datos, menos modelos, menos usuarios. Surgieron porque el *datawarehouse* corporativo era caro, lento e inflexible.
  - **Dependiente**: se alimenta del *datawarehouse* corporativo.
  - **Independiente**: se alimenta directo de las fuentes; puede mantener los **silos de información**.

	Inmon	Kimball
Estrategia	Primero el *datawarehouse* **corporativo**, y de ahí salen los Data Marts (de arriba hacia abajo)	Armar **Data Marts** por área, sin un *datawarehouse* central
A favor	Integrado y escalable	Barato y fácil; la más común
En contra	Caro, lento, puede fracasar	Riesgo de silos y de dejar los criterios para después

→ **Inmon = "primero lo grande"**; **Kimball = "primero lo chico"**. Según Watson, **las dos sirven** si se hacen bien. También existen la **híbrida** y la **federada**.

- **Metadata** o **diccionario de datos**: "información sobre la información" (qué significa cada tabla y atributo, de dónde viene, cómo se transformó). Obliga a que todos usen **las mismas palabras** ("margen bruto" tiene que estar definido).
- **ODS** (*Operational Data Store*): junta datos de varias fuentes para decisiones **operativas** (del día a día). Su información es **volátil**, se actualiza en **tiempo real** y tiene como máximo dos o tres meses. Suele alimentar al *datawarehouse*.

OLAP (*On-Line Analytical Processing*, procesamiento analítico en línea)

- La tecnología más usada para analizar el *datawarehouse*: análisis **multidimensional** en distintos **niveles**, desde el resumen total hasta el máximo detalle.
- **FASMI** (resumen de las 12 reglas de Codd según el OLAP Council): ***Fast*** (rápido), ***Analysis*** (lógica de negocio y estadística), ***Shared*** (compartido y seguro), ***Multidimensional*** e ***Information*** (manejar toda la información).
- Se representa con **cubos**: cada celda guarda un **hecho** (por ejemplo, unidades vendidas de un libro a un cliente en un año).

Operación	→ Qué hace
Rotar (*slicing*)	Girar el cubo: cambiar el orden de las dimensiones (de clientes a libros)
Seleccionar (*dicing*)	Quedarte con algunas celdas (cliente 2, libros 1 y 2, año 1)
Agregar (*roll-up*)	Subir al resumen (total de libros)
Bajar al detalle (*drill-down*)	Bajar por una jerarquía (por materias)

Tipo	Cómo accede	Ventaja / desventaja
ROLAP (relacional)	Directo a la base relacional, normalmente sobre un modelo estrella; traduce las consultas a SQL	Sin límite de tamaño y más flexible / más lento
MOLAP (multidimensional)	A una base multidimensional con datos precalculados	Muy rápido, para soluciones chicas de un departamento / si cambian las dimensiones, hay que recargar el cubo
HOLAP (híbrido)	Resúmenes en la multidimensional y detalle en la relacional	Junta lo mejor de los dos
DOLAP (de escritorio)	Cubo en la memoria de la computadora del usuario	El usuario recibe solo lo que le interesa

- Alternativa al OLAP: herramientas de **lógica asociativa** (por ejemplo QlikView): guardan cada valor una sola vez y consultan sin dimensiones fijas.

Herramientas de BI: generadores de informes; consultas e informes para el usuario final; herramientas OLAP; ***dashboards*** (indicadores operativos o tácticos de **un área**) y ***scorecards*** (nivel **estratégico**, indicadores relacionados, **toda la organización**, como el *Balanced Scorecard* de Kaplan y Norton); planificación y simulación; minería de datos; minería de texto; visualización y GIS (sistemas de información geográfica).

Usuarios (Eckerson y Howson)

- **Productores** de información (alrededor del **20 %**): estadísticos con minería de datos, autores de informes y usuarios avanzados.
- **Consumidores** (la mayoría): directivos, gestores, clientes y proveedores que usan cuadros de mando e informes, cada vez más por web.
- → Se distinguen **roles, no personas**: el mismo ejecutivo puede usar un informe fijo y un cuadro de mando en tiempo real. Por eso hay que saber qué necesita cada rol antes de elegir la herramienta.

2.11 Guías del TP7 — respuestas

Pregunta	Respuesta modelo
¿Definición más ajustada de BI?	La de Gartner: proceso interactivo para explorar y analizar información estructurada (en un *datawarehouse*) y descubrir tendencias o patrones. Convierte datos en información y conocimiento para decidir con hechos
¿Cuándo aplicar BI?	**Siempre, de forma continua**. Sobre todo con mercados que cambian rápido, cuando algo anda raro en el negocio o cuando quienes preparan la información están desbordados
¿A qué organizaciones va dirigida?	A cualquiera que tome decisiones. Urgente en estructuras complejas, con muchos clientes o con procesos "artesanales"
¿Qué beneficios aporta?	Tangibles, intangibles y estratégicos (ver 2.4)
¿Cómo unificar información de distintos entornos?	Juntarla en un *datawarehouse* (copia, sin tocar los transaccionales), en tablas relacionadas, y cruzarla con herramientas de BI: "una sola versión de la verdad"
Concepto y utilidad del modelo de negocio	Versión simplificada de la realidad para documentar y probar teorías. Sirve para ver qué pasa si cambiás algo y para evitar silos
¿Qué es el modelo relacional?	Tablas y relaciones (Codd, 1970) con PK y FK, consultado con SQL
Factores del modelado de datos	Partir del modelo de negocio; definir hechos y dimensiones; ver qué datos hay en los transaccionales y cuáles agregar (calendarios, feriados)
Estrella frente a copo de nieve	Ver tabla 2.9
Granularidad y multidimensionalidad	Nivel de detalle (decide qué preguntas podés responder) y análisis por varias dimensiones a la vez

3 Minería de datos (Tema 9)

En una frase: la minería de datos es **buscar automáticamente patrones escondidos** en muchos datos, para poder **predecir**.

3.1 Datos, información y conocimiento

- **Datos**: registros de lo que pasó.
- **Información**: lo que sale cuando le encontrás utilidad a los datos.
- **Conocimiento**: reglas de cómo una cosa afecta a otra. "El conocimiento es poder".
- **Minería de datos** (*Data Mining*, DM): métodos y algoritmos para la **extracción automática** de información resumida que muestra **relaciones escondidas** en grandes volúmenes de datos, con capacidad **predictiva**. Mezcla estadística y **aprendizaje automático** (inteligencia artificial).
- → **Analogía**: una **montaña** (los datos) con **diamantes** escondidos entre las piedras (el conocimiento).
- Trabaja con **datos estáticos** (una foto del pasado que no cambia mientras analizás). **No confundir con monitoreo**: el monitoreo usa datos que cambian en tiempo real y **reconoce** patrones conocidos, no **descubre** nuevos.
- Apunte de clase: la define igual que al KDD (ver 3.2), de forma automática y para ayudar a decidir. Diferencia con BI según la clase: BI es más estático, saca conclusiones de datos estructurados que ya tenés.

3.2 Proceso KDD

- **KDD** (*Knowledge Discovery in Databases*, descubrimiento de conocimiento en bases de datos): se usa desde **1989**. Es una **inducción no supervisada** con dos partes: buscar regularidades interesantes y escribir reglas que las expliquen.
- **Definición**: extracción **no trivial** de información **implícita**, **previamente desconocida** y **potencialmente útil** a partir de un conjunto de datos.

Las cuatro ideas del KDD:

Idea	→ Qué exige
Lenguaje de alto nivel	Que **una persona lo entienda**. Por eso las **redes neuronales** quedan afuera del KDD (son una "caja negra"), aunque sirvan como método de minería
Precisión	Los datos tienen ruido; se mide **qué tan seguro** es el resultado. Si la certeza es baja, no es conocimiento
Interés	Solo vale lo **nuevo, útil y no obvio** para el usuario
Eficiencia	Que el tiempo y la memoria crezcan de forma **polinomial** (razonable) con los datos

- Mezcla aprendizaje automático, estadística, reconocimiento de patrones, inteligencia artificial, bases de datos, visualización, sistemas de apoyo a la decisión y recuperación de información.
- → **KDD vs. minería de datos**: el **KDD es todo el proceso**; la **minería es un solo paso** adentro del KDD (el de descubrir). Es la parte fundamental (la única que encuentra patrones), pero está **subordinada** al KDD.

Los 9 pasos del KDD (interactivo e iterativo: podés volver atrás):

Bloque	Paso	→ Qué hacés
Preparar	1. **Comprensión del dominio**	Entender el negocio y qué quiere el usuario
	2. **Creación del conjunto de datos objetivo**	Elegir variables y ejemplos, muestrear
	3. **Preprocesado**	Sacar ruido, tratar faltantes, normalizar
	4. **Transformación y reducción**	Quedarte con lo útil, menos variables. **Paso crítico**: decide si sale bien o mal
Minar	5. **Elección del tipo de sistema**	Clasificación, regresión, agrupamiento o detección de desviaciones
	6. **Elección del algoritmo**	Con qué algoritmo buscar
	7. **Minería de datos**	Buscar el conocimiento. Sale bien si los pasos anteriores salieron bien

Bloque	Paso	→ Qué hacés
Aprovechar	8. **Interpretación**	Entender lo encontrado; se puede volver al paso 1
	9. **Consolidación**	Incorporar o documentar el conocimiento, resolviendo contradicciones

- **Fayyad** (según el artículo de la cátedra) resume el núcleo en **5 etapas**: **selección, preprocesamiento, transformación, minería de datos e interpretación/evaluación**. Si sumás la comprensión del dominio al principio y la consolidación al final, llegás a los 9 pasos.

Diagrama: **BD → Selección → Datos objetivo → Preprocesado → Datos preprocesados → Transformación → Datos transformados → Minería de datos → Patrones → Interpretación / Evaluación → Conocimiento**.

- **Por qué creció el análisis de datos** (3 razones):
  1. **Computadoras más potentes**.
  2. **Muchísimos más datos** (el ritmo de adquisición de datos crece sin parar).
  3. **Nuevos métodos** de aprendizaje.
- **Aprendizaje automático vs. minería**: el aprendizaje automático usa un conjunto **chico y elegido**; la minería parte de una base **grande** que se armó para **otra cosa**.

3.3 Fases del KDD según la lectura (6 estados)

1. **Recolección de datos**: fuentes internas y externas, muchas transaccionales. Conviene una fuente **unificada, accesible y separada** del trabajo transaccional. Depende de la fuente (**OLAP** u **OLTP**, *On-Line Transaction Processing*; *datawarehouse* o copia; **ROLAP** o **MOLAP**) y del usuario:
   - **Picapedreros o granjeros**: sacan informes periódicos y controlan valores.
   - **Exploradores**: buscan patrones nuevos.
   - Información externa: censos, datos de la industria, clima, calendarios, bases compradas.
2. **Selección, limpieza y transformación**: sacar datos erróneos o contradictorios (**limpieza**) e irrelevantes (**criba**), casi siempre con estadística (histogramas, muestreo vertical u horizontal, redefinir atributos).
3. **Minería de datos**: datos en disco, muchísimas variables, evidencia positiva, datos imperfectos.
   - **Minería dirigida**: sabés qué buscás (predecir).
   - **No dirigida**: no sabés qué buscás.
4. **Evaluación y validación**:
   - 1.ª fase: probar la precisión con **ejemplos nuevos e independientes**.
   - 2.ª fase: **prueba piloto** (por ejemplo, un *mailing* a un grupo de clientes).
5. **Interpretación y difusión**: el modelo puede necesitar implementación (fraude con tarjetas en tiempo real), interpretación (zonas geográficas) o difusión (cerveza y congelados se compran juntos → ponerlos en **estantes lejanos** para que el cliente recorra el local).
6. **Actualización y monitorización**: un modelo que hoy sirve deja de servir si cambia el contexto. Hay que revalidarlo con datos nuevos.

3.4 Datos atípicos y faltantes

→ **Atípicos** (*outliers*) = valores muy raros. **Faltantes** (*missing values*) = valores que no están.

Acción	Atípicos	Faltantes
Ignorar	Con algoritmos robustos (árboles)	Con algoritmos robustos (árboles)
Filtrar la columna	Extremo; mejor una columna "normal / atípico"	Extremo; mejor una columna sí/no "existía / no existía"
Filtrar la fila	**Sesga los datos** (suelen ser casos especiales)	**Sesga los datos**
Reemplazar el valor	Por nulo, máximo, mínimo o media; o predecirlo	Por la media; o predecirlo
Discretizar	Muy alto, alto, medio, bajo, muy bajo: el atípico cae en un extremo	—

Acción	Atípicos	Faltantes
Segmentar	—	Un modelo por grupo según los datos que haya, y después se combinan
Esperar	—	Mejorar la calidad y esperar los datos

- **Por qué faltan datos**:
  - **Relevantes**: que falte dice algo (no dar el teléfono = no quiere que lo molesten).
  - **No existentes**: no puede haberlos (un cliente nuevo no tiene 12 meses de consumo).
  - **Incompletos**: se perdieron al unir fuentes distintas.

3.5 Evolución histórica

Etapa	Pregunta típica	Tecnología	Característica
Recolección (años 60)	Beneficios totales de los últimos 4 años	Computadoras, cintas, discos	Mira al pasado, datos estáticos
Acceso a los datos (años 80)	Ventas en Cataluña la última Navidad	Bases relacionales (SQL), ODBC	Mira al pasado, dinámico por registro
***Datawarehouse* y apoyo a decisiones (años 90)**	Ventas en Andalucía, bajando hasta la tienda	OLAP, bases multidimensionales	Mira al pasado, en varios niveles
Minería de datos	Tendencia de venta en Castilla el próximo año	Algoritmos avanzados, multiprocesadores	**Mira al futuro (prospectivo), proactivo**

→ Las tres primeras preguntan **"¿qué pasó?"**; la minería pregunta **"¿qué va a pasar?"**.

3.6 Qué no es minería de datos

No es estadística:

Eje	Minería de datos	Estadística clásica
Automatización	Arma el modelo **sola**	La maneja un **estadístico**
Enfoque	**Exploratorio** (busca)	**Confirmatorio** (prueba hipótesis)
Inteligencia artificial	La usa	Teoría de la probabilidad
Dimensionalidad	Mejor con **muchas variables**	Le cuesta con muchas variables
Supuestos	**Menos exigente**	Los datos deben cumplir requisitos

Apunte de clase: la estadística toma **muestras** y saca conclusiones de la población; la minería trabaja con **toda la base** (y usa estadística).

No es OLAP: OLAP **navega** rápido por los datos (análisis multidimensional) pero **no genera información nueva**. Sus arquitecturas (MOLAP, ROLAP y otras) están en 2.10.

3.7 Los tres retos

1. **Falsa interpretación**: es fácil engañarse con estadística (los resultados valen para grupos, no para individuos). Con software de minería es aún más fácil "hacer creíble una falsedad".
2. **Correlación no es causalidad — Florida**: en Florida la gente muere a edad más alta que en el resto de Estados Unidos. ¿Vivir ahí alarga la vida? **No**: es que ahí se van a vivir los jubilados (**efecto de selección**). → La minería **genera hipótesis** desde los datos (es **explorativa, no explicativa**): hay que validarlas con datos nuevos. Además no puede hacer experimentos.
3. **Tiempo, espacio y privacidad**:
   - Variables que cambian durante el período.
   - **Granularidad del tiempo**: con datos mensuales no podés predecir por semana.
   - **Privacidad**: si cruzás las bases del teléfono, el banco y el súper, armás un perfil completo de una persona. La ley no acompañó.

3.8 Tareas de la minería de datos

→ **Predictiva / supervisada** = sabés qué querés predecir. **Descriptiva / no supervisada** = buscás qué hay.

Tarea	→ Qué hace	Tipo
Clasificación	Pone cada dato en una **clase ya definida**	Supervisado / predictivo
Regresión	Predice un **número** (valor real, continuo)	Supervisado / predictivo
Agrupamiento (*clustering*)	Arma grupos parecidos sin saber de antemano cuáles	No supervisado / descriptivo
Condensación (descripción de conceptos)	Describe un grupo en **pocas palabras**	No supervisado / descriptivo
Detección de desviaciones	Encuentra cambios importantes respecto de lo normal	No supervisado / descriptivo
Modelado de dependencias	Encuentra qué variables dependen de cuáles	No supervisado / descriptivo

Proceso de minería (4 estados): **preprocesado** → **selección de características** (las variables que más influyen) → **algoritmo de extracción** (el modelo) → **evaluación y validación**.

3.9 Predictivo frente a descriptivo

- **Predictivo (supervisado)**: predice una **etiqueta** que ya conocés en los datos viejos. Dos fases: **entrenamiento** (aprende con datos etiquetados) y **prueba** (lo probás con el resto).
- **Descriptivo (no supervisado)**: descubre patrones en los datos actuales.
- **Taxonomía**: interpolación, predicción secuencial, aprendizaje supervisado, aprendizaje no supervisado y abducción. En lo supervisado:
  - **Clasificación**: clases separadas. **Categorización**: pueden superponerse.
  - Clase con dos valores = ***concept learning***. Clase continua = **estimación**.
- **Reglas de asociación** (tipo "el que compra X compra Y"):
  - **Confianza** = casos con antecedente **y** consecuente / casos con el antecedente. → "¿Qué tan seguido se cumple?"
  - **Soporte** = casos (o %) donde se aplica la regla. → "¿Qué tan común es?"
  - Algoritmo tipo **Apriori**, en dos fases: **A**, buscar combinaciones frecuentes (*large itemsets*) con soporte suficiente; **B**, convertirlas en reglas y quedarse con las de confianza suficiente.
  - También hay asociaciones entre jerarquías, **negativas** ("80 % de quienes compran pizza congelada no compra lentejas") y con valores continuos (se pasan a rangos).
- **Combinar hipótesis**:
  - ***Boosting***: el **mismo** algoritmo sobre distintas partes de los datos.
  - ***Voting***: **distintos** algoritmos sobre todos los datos.

3.10 Métodos y técnicas

Métodos: agrupamiento (segmentación estática o dinámica), asociación, **secuenciamiento** (asociación donde importa el **tiempo**), reconocimiento de patrones, **previsión** (*forecasting*, series temporales), simulación (por ejemplo CAD-CAM), optimización (ganar más o gastar menos con restricciones) y clasificación (*scoring*).

Supervisados	No supervisados
Árboles de decisión	Detección de desviaciones
Inducción neuronal	Segmentación
Regresión	Agrupamiento (*clustering*)
Series temporales	Reglas de asociación
	Patrones secuenciales

Técnicas:

- **Estadísticas**:
  - **ANOVA** (análisis de la varianza): ¿los promedios de los grupos son distintos?

    - **Ji cuadrado**: ¿dos variables son independientes?
    - **Componentes principales**: reduce la cantidad de variables.
    - Análisis de **clusters**: arma grupos.
    - **Análisis discriminante**: clasifica en grupos ya definidos.
    - **Regresión lineal** (la más básica; variables continuas) y **logística** (acepta variables discretas).
- **Árboles de decisión**: parten los datos en grupos más chicos.
    - **CART**: parte en **2** (validación cruzada, índice de Gini).
    - **CHAID** (*Chi Squared Automatic Interaction Detector*): parte en **más de 2** (test Ji cuadrado).
- **Reglas de asociación**: "cesta de la compra", reglas SI ... ENTONCES.
- **Redes neuronales**: copian la idea del cerebro (estudios desde 1930), con capas de neuronas que aprenden patrones; supervisadas o no. Problema: **no dan una ecuación que explique el modelo** (caja negra).
- **Algoritmos genéticos**: mutación y cruce (como la evolución) para **optimizar**; se usan al principio para **elegir variables**.
- **Lógica difusa**: los grupos tienen bordes suaves, no cortes exactos.
- **Series temporales**: ciclos, tendencias y temporadas para predecir, si no hay cambios de fondo.
- **Redes bayesianas**: aprenden dependencias y causas, combinan conocimiento con datos, evitan el sobreajuste y manejan datos incompletos.
- **Inducción de reglas** y **sistemas expertos** (con motor de inferencia).

3.11 Evaluación de la minería

- **Tres medidas clave** de una herramienta: **precisión** (¿acierta?), **explicación** (¿se entiende?) e **integración** (¿se mete en el negocio sin copiar datos?).

Medida de precisión	→ Qué es
Precisión	% de predicciones correctas
Tasa de error	Lo contrario de la precisión. Útil con precisiones muy altas: pasar de 99 % a 99,5 % **reduce el error a la mitad**
Tasa de error en rechazo	Descartás las predicciones dudosas (rechazando el 80 % se puede duplicar la precisión)
Error cuadrático medio	Para números; castiga más los errores grandes
Elevación (*lift*)	Cuánto mejora respecto de elegir al azar: 30 % / 10 % = **3** (el modelo es 3 veces mejor que el azar)
Beneficio / ROI	La mejor medida: cuánto gana el negocio

- **Explicación**: reglas generadas solas, OLAP integrado, evaluación automática del modelo.
- **Integración**: usar los datos como están, guardar el modelo como metadatos, preparar los predictores, manejar datos sucios, valores perdidos y **escalabilidad**.

3.12 Apuntes de clase (14/9)

- **Aplicaciones**: retener clientes, patrones de compra, detectar fraude, manejar riesgo (a quién prestarle), segmentar.
- **Ciclo de un proyecto** (9 pasos): aprender del negocio → recolectar → limpiar y transformar → definir meta y modelo → elegir algoritmos → generar reportes → generar predicciones → aplicar los resultados → actualizar los modelos.
- **CRISP-DM** (*Cross-Industry Standard Process for Data Mining*): proceso confiable y repetible, pensado para gente con pocos conocimientos. **6 fases**: comprensión del negocio, comprensión de los datos, preparación de los datos, modelado, evaluación e implantación.
- **Bodega de datos**: base pensada para consultas, **consolidada, consistente, orientada a un tema, histórica y de solo lectura**. Es el punto de partida de la minería y no cambia mientras minás.
- **Minería vs. análisis de datos**: el análisis no suele ser automático ni con tanto volumen.
- **Minería vs. aprendizaje automático**: el aprendizaje automático es la parte de la inteligencia artificial que hace programas que aprenden; la minería lo usa para predecir.

3.13 Preguntas teóricas del TP8 (respuestas del grupo)

Consigna	Respuesta clave
1. Los 9 pasos con insumo y producto; qué pasa si falla el preprocesado	Cada paso usa lo que produjo el anterior. Si falla el **preprocesado**, el **modelo clasificador** aprende el ruido como si fuera un patrón, los faltantes mal tratados sesgan la muestra y los atípicos distorsionan. La evaluación puede parecer buena si los datos de prueba tienen el mismo defecto. **El modelo no sirve**
2. Minería fundamental pero subordinada al KDD	"Minería sin KDD es una operación algorítmica **ciega**" (no sabe qué buscar, con qué calidad ni si lo encontrado vale). "KDD sin minería es un proceso **inconcluso**" (datos limpios, pero sin patrones)
3. Minería vs. estadística; Florida	Ver 3.6 y 3.7
4. Minería vs. OLAP vs. monitoreo	Minería **genera** información nueva sobre datos **estáticos** (descubre, es proactiva). OLAP **navega** sobre datos **históricos resumidos** cuando el usuario consulta (*drill-down*, *roll-up*, *slice & dice*). Monitoreo **verifica** datos en **tiempo real** y reacciona (alertas)
5. Mapa de tareas	Supervisado: clasificación y regresión. No supervisado: agrupamiento, dependencias, desviaciones y condensación
6. Redes neuronales y lenguaje de alto nivel	Predicen bien, pero el conocimiento queda en miles de **números (pesos)**: es una **caja negra** que no se puede explicar. Choca con la exigencia de conocimiento **entendible** del KDD
7. Faltantes y atípicos con sesgo	Ver 3.4: filtrar filas **sesga**; usar la media **reduce la varianza**; discretizar **pierde precisión**; segmentar puede **sobreajustar**
8. Ensayo	Más potencia de *hardware* + más detalle de tiempo + privacidad: cuanto más detalle y más fuentes cruzadas, más preciso el perfil de cada persona. Marco legal: Ley 25.326 de Protección de Datos Personales (Argentina) y GDPR (Reglamento General de Protección de Datos, Unión Europea)
9. KDD, CRISP-DM y SEMMA	Ver tablas abajo

Eje	KDD	CRISP-DM	SEMMA
Origen	**Académico** (1989, Fayyad)	**Consorcio de empresas**: DaimlerChrysler, SPSS y NCR; ligado a SPSS Clementine	**SAS Institute**; ligado a SAS Enterprise Miner
Fases	9 (5 en el núcleo de Fayyad)	6, en orden **no rígido**	5: *Sample, Explore, Modify, Model, Assess*; el muestreo es **opcional**
Iteración	Muy iterativo, vuelve desde cualquier fase	Ciclo con mucha retroalimentación	Más en línea recta, con ajustes técnicos
Orientación al negocio	Arranca por el dominio; foco en la validez científica	**La más orientada al negocio**	Técnica; supone que los objetivos ya están definidos
¿Incluye negocio y despliegue?	Sí (antes y después del núcleo)	Sí, explícitamente	**No explícitamente**; según Azevedo y Santos está implícito, porque no podés muestrear sin entender el negocio

Equivalencia de fases según el artículo de la cátedra (Azevedo y Santos, "KDD, SEMMA and CRISP-DM: a parallel overview"):

KDD	SEMMA	CRISP-DM
Antes del KDD (comprensión del dominio)	—	Comprensión del negocio
Selección	*Sample*	Comprensión de los datos
Preprocesamiento	*Explore*	Comprensión de los datos
Transformación	*Modify*	Preparación de los datos
Minería de datos	*Model*	Modelado
Interpretación / evaluación	*Assess*	Evaluación

KDD	SEMMA	CRISP-DM
Después del KDD (consolidación)	—	Despliegue

- **Conclusión del artículo**: SEMMA y CRISP-DM son **formas de aplicar el proceso KDD**. CRISP-DM parece más completo, pero SEMMA también incluye (sin decirlo) el negocio y la consolidación.
- **Ojo:** el TP8 del grupo puso "preparación de los datos" junto al preprocesado. Según el artículo, el preprocesado va con **comprensión de los datos** y la transformación con **preparación de los datos**.

4 Big Data (Tema 10, entra en el final)

En una frase: Big Data es **la forma de manejar datos tan grandes, rápidos y variados** que los sistemas de siempre no pueden con ellos.

4.1 Mapa conceptual

- **Definición**: ecosistema o paradigma para **capturar, almacenar y analizar** datos de **gran volumen, velocidad y variedad**, que superan a los sistemas tradicionales. Es la base sobre la que se construyen el análisis y la estrategia (apunte de clase).
- **Las 3 V**:
  - **Volumen**: muchísimos datos.
  - **Velocidad**: llegan muy rápido.
  - **Variedad**: de todo tipo (texto, fotos, sensores, redes).
- → La guía de PowerData avisa: **"Big" no es lo importante**. El volumen es solo una parte. Las empresas quieren saber no solo qué pasa, sino **qué va a pasar**, y lo más cerca posible del **tiempo real**.
- **Por qué importa**: cambia la industria, el negocio y la sociedad, y da **ventaja competitiva**. Hoy puede valer más encontrar al **cliente que más influye** sobre otros que al que más compra.
- **Nace de 3 necesidades nuevas del mercado**:
  1. **Personalización máxima** del cliente.
  2. Pasar **de la transacción a la interacción**.
  3. **Nuevos dispositivos** (celulares, domótica, autos con sensores).
- **Necesita Big Analytics**:
  - Análisis **predictivo** y **clusterización** (agrupar) de clientes.
  - Trabaja con **datos en crudo, al nivel más bajo de detalle**, con modelos más ágiles.
  - Lo manejan el **Data Scientist** y el **Data Analyst** (aparece el perfil de **Data Science**).
  - Viene del **BI tradicional y el Data Warehouse**, que tenían **modelos rígidos, poco ágiles y sin tiempo real**: cargaban los modelos tan lento que cuando terminaban ya no servían.
  - Se apoya en el **Analytic Data Warehouse (ADW)**. → El ADW **no reemplaza** al *data warehouse*: cada uno cubre algo distinto y **conviven** en un **modelo híbrido DWH + ADW**.
- **Metodología MAD**:
  - **Magnética**: atrae todo tipo de datos.
  - **Ágil**: los carga y se adapta rápido.
  - **Detallada**: análisis estadístico fino.
- **Origen de Hadoop**: **Google** no podía indexar la web tan rápido como hacía falta. Aplicó **"divide y vencerás"**: muchas computadoras chicas, cada una procesa un pedazo, pero funcionan como una sola. En **2006** la comunidad de **código abierto** crea Hadoop; después **Yahoo** lo impulsa y lo adoptan empresas como **Facebook**. Permite, por ejemplo, una regresión lineal sobre millones de registros históricos con un **ROI muy rápido**.
- **Hadoop tiene dos partes**:
  - **HDFS** (*Hadoop Distributed File System*): **guarda** los archivos repartidos en muchas máquinas.
  - **MapReduce**: **procesa** en paralelo.
  - Es **código abierto** y usa ***commodity hardware*** (equipos comunes y baratos).
- **4 megatendencias**:
  - **Movilidad**: acceso a los datos desde cualquier lugar y desde dispositivos que no son de la empresa (más difícil de controlar).
  - **Cloud**: no comprás la infraestructura; baja la inversión inicial y podés **prever el costo de crecer**.
  - **Social Media**: gustos y preferencias para captar y fidelizar clientes.
  - **Analytics**: analizar cualquier tipo de dato, sin patrones de búsqueda fijos.
- **Tiempo real**:
  - ***Data Stream***: analiza **datos en movimiento** (mientras llegan).
  - **CEP** (*Complex Event Processing*): **detecta eventos ya definidos** (por ejemplo, operaciones sospechosas con tarjetas).

- Ejemplos de CEP de la guía: un banco que mira en tiempo real lo que pasa con las **tarjetas de crédito** en cajeros y comercios; **sensores de maquinaria** que avisan antes de que se rompa algo.

- **Cómo implementarlo**:
  1. Primero **conocer y medir el valor** que le da al negocio (ver límites, expectativas y restricciones).
  2. **Las metas eligen la tecnología** (no al revés): para eventos en tiempo real, **CEP**; para análisis predictivo, bases **MPP** (*Massively Parallel Processing*, procesamiento masivamente paralelo) sobre todo el histórico.
  3. Perfiles que conozcan el negocio (Data Scientist, Data Analyst).
  4. Herramientas según el tipo de análisis.
- **Privacidad**: en Google "no todo es gratis": el precio es tu privacidad. Las empresas tienen que equilibrar los datos que analizan con lo que sus clientes **toleran**.
- → **Resumen**: Big Data **genera** innovación y ventaja competitiva, pero **plantea** el desafío de **seguridad y privacidad**.

4.2 BI, minería de datos y Big Data

Aspecto	BI	Minería de datos	Big Data
Qué es	Procesos y herramientas que convierten datos en información para decidir	Descubrir patrones, relaciones y tendencias ocultas	Paradigma para capturar, almacenar y analizar datos masivos
Pregunta central	¿Qué pasó y cómo vamos?	¿Qué patrones hay en los datos?	¿Qué va a pasar y qué descubrimos con todos los datos?
Tiempo	Pasado y presente	Pasado, para descubrir y predecir	Presente y futuro, en tiempo real
Tipo de datos	Estructurados, internos	Estructurados y semiestructurados, ya preparados	Estructurados, semiestructurados y **no estructurados** (redes, sensores, logs)
Volumen	Moderado (lo que aguanta un *datawarehouse*)	De moderado a grande	**Masivo**, infraestructura distribuida
Técnicas	Consultas, reportes, tableros, OLAP, KPI	Clasificación, agrupamiento, asociación, regresión, anomalías	Big Analytics, MapReduce, Data Stream, CEP
Tecnología	*Datawarehouse*, ETL, *reporting*	Algoritmos estadísticos y de aprendizaje automático	Hadoop, ADW, *cloud*, bases MPP
Perfil	Gerentes y analistas de negocio	Analistas de datos, estadísticos	Data Scientist, Data Analyst
Resultado	Informes y tableros	Modelos y patrones	Conocimiento nuevo y servicios personalizados casi en tiempo real
Limitación	Poco ágil, sin tiempo real	Depende de la calidad de los datos	Infraestructura nueva, perfiles caros, privacidad

Matriz de la clase ("Ingeniería de datos"):

	Big Data	Minería de datos	BI
Fin principal	Almacenar y procesar a escala masiva	**Descubrir patrones**	**Optimizar decisiones** de la empresa
Tipo de datos	**Crudos** y variados	**Consolidados**	**Estructurados y depurados**
Perfil	**Ingeniero de datos**	**Científico de datos**	**Analista de BI** o consultor
Foco temporal	**Presente continuo**	**Futuro predictivo**	**Pasado y presente** descriptivo

- → **Cadena de la clase**: **Big Data** junta los datos → la **minería** encuentra patrones → **BI** los convierte en decisiones.
- **No compiten**: conviven en un **modelo híbrido**. BI mira hacia atrás; Big Data apunta hacia adelante; la minería se usa tanto sobre un *datawarehouse* como sobre Big Data.
- El TP dice que la minería mira al "pasado" y la clase dice "futuro predictivo". Si te preguntan: la minería **analiza datos pasados para predecir el futuro**.

5 Repaso final

5.1 Cómo se conectan los temas

- **Redes de Petri** → modelan **cómo se comporta** un sistema concurrente (procesos, estados, recursos). Es **diseño**.
- **BI, minería y Big Data** → trabajan con los **datos** que generan esos sistemas, para **decidir**: Big Data junta y procesa → la minería descubre patrones → BI los convierte en indicadores y decisiones.
- **Puntos de contacto**:
  - El *datawarehouse* (BI) es el punto de partida de la minería.
  - OLAP aparece en BI y en minería (que **no** es OLAP).
  - La **granularidad** aparece en el modelo de datos de BI y en el tercer reto de la minería.
  - La **privacidad** aparece en minería y en Big Data.

5.2 Errores frecuentes en el examen

- ✗ "Una red viva siempre es cíclica." ✓ Son cosas **distintas**: una red puede ser viva y nunca volver a M0.
- ✗ "Red segura = red que no se traba." ✓ Segura = **1-acotada**. Que no se trabe es **vivacidad**.
- ✗ "$C = C^- - C^+$." ✓ **$C = C^+ - C^-$**.
- ✗ "Un arco puede unir dos lugares." ✓ Siempre une **lugar con transición** (grafo bipartito).
- ✗ "BI es un análisis que se hace una vez." ✓ Es un **proceso continuo** (interactivo).
- ✗ "El esquema estrella está normalizado." ✓ La estrella está **desnormalizada**; el **copo de nieve** está normalizado.
- ✗ "Más granularidad = menos detalle." ✓ **Más granularidad = más detalle** (líneas de ticket > tickets).
- ✗ "Un Data Mart es más grande que un *datawarehouse*." ✓ Es **más chico** y para un grupo de usuarios.
- ✗ "KDD y minería de datos son lo mismo." ✓ La minería es **un paso** del KDD.
- ✗ "OLAP descubre patrones nuevos." ✓ OLAP **navega**; la minería **descubre**.
- ✗ "Si dos cosas están correlacionadas, una causa la otra." ✓ **Correlación no es causalidad** (Florida).
- ✗ "Sacar las filas con faltantes no tiene costo." ✓ **Sesga** los datos.
- ✗ "La regresión es descriptiva." ✓ Es **predictiva / supervisada** (predice un número).
- ✗ "Las redes neuronales cumplen con el lenguaje de alto nivel del KDD." ✓ Son una **caja negra**: no lo cumplen, aunque sirvan como método.
- ✗ "Big Data reemplaza al *datawarehouse*." ✓ **Conviven** (modelo híbrido DWH + ADW).
- ✗ "SEMMA incluye la comprensión del negocio." ✓ SEMMA **la da por hecha**; CRISP-DM es la más orientada al negocio.

5.3 Preguntas integradoras con respuesta modelo

1. **¿Por qué la minería de datos depende del *datawarehouse* de BI?** Porque la minería necesita datos **consolidados, limpios e históricos**, separados de los sistemas transaccionales. Eso es justo lo que da el **datawarehouse** cargado con **ETL**. La lectura dice que el análisis es mucho más fácil si la fuente es unificada, accesible y separada del trabajo transaccional. Por eso el *datawarehouse* es "el punto de partida" de la minería.
2. **Compará OLAP, minería de datos y Big Data. OLAP** navega por datos históricos resumidos en varias dimensiones, **sin generar información nueva**. La **minería** descubre **sola** patrones nuevos y predice. **Big Data** es el **contexto** de datos enormes, rápidos y variados (hasta no estructurados) que necesita infraestructura distribuida (**Hadoop**) y análisis en tiempo real (**CEP**, **Data Stream**).
3. **¿Qué tienen en común la granularidad de un modelo estrella y el tercer reto de la minería?** En los dos casos, el **nivel de detalle** decide qué preguntas podés responder. En BI, si analizás tickets no podés analizar productos; en minería, con datos mensuales no podés predecir por semana. **Cada vez que resumís, perdés información**.

5.4 Autopreguntas

- ¿Qué es un nodo frontera y cuáles son los tres tipos?
- Dada una red, ¿podés armar C^-, C^+ y C sin mirar, con filas = transiciones?
- ¿Cuándo se escribe ω en el árbol y qué propiedad indica?
- ¿Cómo pasás del árbol de alcanzabilidad a la máquina de testigos?
- ¿Por qué $M' = M + f(\sigma)\cdot C$ no alcanza para asegurar que una secuencia se puede disparar?
- ¿Cómo ves en el grafo de marcados que una red es cíclica?

- ¿Qué diferencia hay entre una red viva, parcialmente viva y no viva?
- ¿Cuáles son los 6 componentes de un proyecto de BI?
- ¿Qué es una dimensión degenerada? Dame dos ejemplos.
- ¿Por qué el fabricante va en una dimensión distinta del artículo?
- ¿Cuáles son los 9 pasos del KDD y cuál es el crítico?
- ¿Qué hace un "picapedrero" y qué hace un "explorador"?
- ¿Qué es la elevación (*lift*) y cómo se calcula?
- ¿Qué es la metodología MAD y qué significa cada letra?
- ¿Qué diferencia hay entre Data Stream y CEP?

Glosario de siglas y abreviaturas

Redes de Petri

Sigla	Desarrollo	Original
RdP	Red de Petri	—
M0	Marcado inicial	—
C^-	Matriz de incidencia previa	—
C^+	Matriz de incidencia posterior	—
MT	Máquina de testigos	—
GE	Grafo de estados	—
ME	Máquina de estados	—
GM	Grafo marcado	—
RLE	Red de libre elección	—
RS	Red simple	—
DFD	Diagrama de flujo de datos	—

Business Intelligence

Sigla	Desarrollo	Original
BI	Inteligencia de negocio	*Business Intelligence*
KPI	Indicador clave de desempeño	*Key Performance Indicator*
ROI	Retorno de la inversión	*Return on Investment*
NPV	Valor actual neto	*Net Present Value*
TCO	Costo total de propiedad	*Total Cost of Ownership*
CF	Flujo de caja	*Cash Flow*
ETL	Extracción, transformación y carga	*Extract, Transform, Load*
OLAP	Procesamiento analítico en línea	*On-Line Analytical Processing*
OLTP	Procesamiento de transacciones en línea	*On-Line Transaction Processing*
MOLAP	OLAP multidimensional	*Multidimensional OLAP*
ROLAP	OLAP relacional	*Relational OLAP*
HOLAP	OLAP híbrido	*Hybrid OLAP*
DOLAP	OLAP de escritorio	*Desktop OLAP*
FASMI	Rápido, análisis, compartido, multidimensional, información	*Fast, Analysis, Shared, Multidimensional, Information*
ODS	Almacén de datos operacional	*Operational Data Store*
CRM	Gestión de la relación con clientes	*Customer Relationship Management*
SCM	Gestión de la cadena de suministro	*Supply Chain Management*
GIS	Sistemas de información geográfica	*Geographic Information Systems*
DWH	Almacén de datos	*Data Warehouse*

Sigla	Desarrollo	Original
ERP	Planificación de recursos empresariales	*Enterprise Resources Planning*
PK	Clave primaria	*Primary Key*
FK	Clave externa	*Foreign Key*
SQL	Lenguaje de consulta estructurado	*Structured Query Language*
ODBC	Conectividad abierta de bases de datos	*Open Database Connectivity*
DAX	Expresiones de análisis de datos	*Data Analysis Expressions*
IDC	International Data Corporation, consultora	—
TDWI	The Data Warehousing Institute	—
EFQM	Fundación Europea para la Gestión de la Calidad	*European Foundation for Quality Management*

Minería de datos

Sigla	Desarrollo	Original
DM	Minería de datos	*Data Mining*
KDD	Descubrimiento de conocimiento en bases de datos	*Knowledge Discovery in Databases*
CRISP-DM	Proceso estándar intersectorial para minería de datos	*Cross-Industry Standard Process for Data Mining*
SEMMA	Muestrear, Explorar, Modificar, Modelar, Evaluar	*Sample, Explore, Modify, Model, Assess*
ML	Aprendizaje automático	*Machine Learning*
IA	Inteligencia artificial	—
ANOVA	Análisis de la varianza	*Analysis of Variance*
CART	Árboles de clasificación y regresión	*Classification And Regression Trees*
CHAID	Detector automático de interacciones por Ji cuadrado	*Chi Squared Automatic Interaction Detector*
k-NN	k vecinos más cercanos	*k Nearest Neighbors*
IQR	Rango intercuartílico	*Interquartile Range*
PII	Información de identificación personal	*Personally Identifiable Information*
GDPR	Reglamento General de Protección de Datos, de la Unión Europea	*General Data Protection Regulation*
CAD-CAM	Diseño y fabricación asistidos por computadora	*Computer-Aided Design / Manufacturing*

Big Data

Sigla	Desarrollo	Original
ADW	Almacén de datos analítico	*Analytic Data Warehouse*
MAD	Magnética, Ágil, Detallada	—
HDFS	Sistema de archivos distribuido de Hadoop	*Hadoop Distributed File System*
CEP	Procesamiento de eventos complejos	*Complex Event Processing*
MPP	Procesamiento masivamente paralelo	*Massively Parallel Processing*

Otras

Sigla	Desarrollo
TP	Trabajo Práctico

Sigla	Desarrollo
N°	Número

De dónde sale este resumen

- **Material de la cátedra** (carpeta *Análisis y Diseño de Sistemas II - 2026*): presentaciones "Redes_de_petri" y "Formalización Redes de Petri"; capítulos "Introducción al BI", "BI_modelos", "Componentes de BI" y "experiencias BI_detalle" del libro *Business Intelligence: competir con información*; lectura de minería de Beatriz Beltrán Martínez; artículo "KDD-CRISP-SEMMA" (Azevedo y Santos); guía "PowerData - Del bit... al Big Data". El documento "Data Mining: el arte de anticipar" (Palma y otros) no se volcó porque no aparece en los TP.
- **Material del grupo**: TP6 a TP9, guías de BI, apuntes de clase ("Redes Petri - Análisis y Diseño II", "Apuntes 14/9", "Ingeniería de datos") y el mapa conceptual de Big Data.
- **Verificado por computadora**: matrices, árboles, máquinas de testigos, secuencias y propiedades de los tres ejemplos de Redes de Petri.
- **Sacado por alcance**: TP6 de modelado, CoffeeTime, TP de fútbol, comercio minorista y abandono de compra.
- **Depuración (30/10)**: Big Data pasa al final. Se sacaron los ejemplos y casos puntuales (supermercado, paquetería, Wal-Mart, ROI del libro, K-means de empleados, Play Tennis, experiencias de BI) y los datos sueltos de estudios o encuestas (IDC, TDWI, Watson, Gartner 2005, hospitales). Se conservaron los ejemplos resueltos de Redes de Petri.
- **No disponible**: contenido de los videos de los temas 8 y 10.